ALL ve AML Lösemi Alt Tip Sınıflandırmasında Sızıntısız Değerlendirme ve Platformlar Arası Aktarım

Ara Rapor: Literatür Taraması, Veri Setleri ve Keşifsel Veri Analizi

Enes AY
Öğrenci No. 503020260092
Yapay Zeka Programı, Fen Bilimleri Enstitüsü
Eskişehir Osmangazi Üniversitesi, Eskişehir, Türkiye
enes.ay.910@gmail.com

***Özet*—Akut lenfoblastik (ALL) ve akut miyeloid lösemi (AML) farklı tedaviler gerektirir; Golub vd. mikrodizi veri seti (72 hasta, 7.129 prob) bu iki sınıfı gen ifadesinden ayırmanın klasik kıyas setidir. Veri çok küçük ve çok yüksek boyutlu olduğundan ($p \gg n$), yayımlanmış ve %100'e yakın bazı doğruluklar bilgi sızdırıyor görünen doğrulama tasarımlarına dayanır. Bu ara rapor, makine öğrenmesi (ML) yöntemlerinin sızıntısız karşılaştırmasının temelini atar: (i) belgelenmiş bir arama protokolüyle 38 kaynak incelenmiş, (ii) aynı klinik soruyu taşıyan iki bağımsız açık kohort seçilmiş—çok merkezli MILE çalışması (GSE13159, 1.292 ALL/AML örneği, Affymetrix HG-U133 Plus 2.0) ve Andersson vd. pediatrik kohortu (GSE7186, 121 örnek, iki renkli cDNA dizileri)—ve (iii) tümüyle betiklenmiş bir keşifsel analiz yürütülmüştür. Golub verisinde eksik değer yoktur, ancak yoğunlukların %28,7'si negatiftir; bu durum kırpma ve $\log_2$ dönüşümünü gerekçelendirir. Dönüşümden sonra PC1 tek başına sınıfları AUC 0,984 ile ayırır. Eğitim ve bağımsız set arasında ölçülebilir bir kayma vardır. Gen bazlı t istatistikleri kohortlar arasında koreledir (Spearman $\rho = 0{,}56$ Golub–MILE, $\rho = 0{,}44$ Golub–Andersson); her kohort standartlaştırılana kadar birleşik varyansa sınıf değil, veri seti kimliği hâkimdir. Sabit ayarlı bir fizibilite pilotunda, gen seçimini çapraz doğrulama dışına almak rastgele etiketlerde bile dengeli doğruluğu 0,50 düzeyinden 0,91 düzeyine çıkarmış; kohortlar arası aktarımda AUC 0,93–0,99 kalırken dengeli doğruluk 0,59–0,94 aralığına yayılmıştır. Bu bulgular, kilitli dış test setlerini de içeren final makalesinin tasarımını belirler.**

***Anahtar Kelimeler*—lösemi, gen ifadesi, mikrodizi, keşifsel veri analizi, batch etkisi, iç içe çapraz doğrulama, küçük örneklemle öğrenme**

I. Giriş

Klinik problem. ALL lenfoid, AML miyeloid öncül hücrelerden kaynaklanır. Belirtiler ve kemik iliğindeki blastlar benzer olsa da indüksiyon kemoterapisi, risk sınıflaması ve nakil kararları önemli ölçüde farklıdır; bu yüzden yanlış soy ataması tedaviyi doğrudan etkiler. Rutin uygulamada ayrım morfoloji, sitokimya, immünfenotipleme ve sitogenetiğe dayanır; gen ifadesi profili, bu etiketleri tek ve nesnel bir testle yeniden üretebilen ve alt sınıfları ortaya çıkarabilen bir yöntem olarak önerilmiştir [1], [2]. Bu çalışmada görev *ALL ve AML alt tip sınıflandırması* olarak adlandırılır: iki sınıf da lösemidir, dolayısıyla ders modülünde ALL için kullanılan "non-cancer" etiketi biyolojik olarak yanlıştır ve burada kullanılmaz.

Mikrodizi teknolojisi. DNA mikrodizisi, işaretli cDNA/cRNA'yı sabitlenmiş problara hibritleştirerek binlerce mRNA transkriptinin miktarını paralel olarak ölçer. Affymetrix oligonükleotit dizileri (Golub ve MILE) prob seti başına bir yoğunluk verir; eski MAS 4 "average difference" değeri (perfect-match eksi mismatch) negatif olabilir ve Present/Marginal/Absent (P/M/A) saptama çağrısıyla birlikte gelir. İki renkli noktalı cDNA dizileri (Andersson) örneği (Cy3) ortak bir referans RNA (Cy5) ile birlikte hibritleştirir ve log oran verir.

Araştırma soruları (AS). Proje, yanlışlanabilir dört soruyu sınar:

- **AS1** (yöntem karşılaştırması): 72 Golub örneğinin tamamında sızıntısız 5×5 iç içe tabakalı çapraz doğrulama (CV) altında cezalandırılmış lojistik regresyon, destek vektör makinesi (SVM) ve rastgele orman dengeli doğrulukta farklı mıdır? H_0: ortalama dengeli doğruluklar eşittir; düzeltilmiş yeniden örnekleme t testi [3] ve Holm düzeltmesiyle ikili olarak sınanır.
- **AS2** (protokol): Ders modülündeki tek 38/34 bölmesi, iç içe CV'nin %95 güven aralığı içinde bir tahmin mi verir? Gen seçimini CV dışına almak doğruluğu ne kadar şişirir?
- **AS3** (genellenebilirlik): ALL/AML sinyali kohortlar ve platformlar arasında ortak mıdır; yani gen bazlı test istatistiklerinin korelasyonu $\rho > 0$ ve ilk 100 gen örtüşmesi şanstan büyük müdür? Final raporunda: bir kohortta eğitilen model, kilitli dış setlerde hem sıralamayı (AUC) hem karar eşiğini (dengeli doğruluk $\geq 0{,}90$) koruyor mu?
- **AS4** (bonus): Derin model (MLP/otokodlayıcı) ve tablosal transformer (TabPFN), aynı protokolde en iyi klasik modeli geçer mi?

AS3, Bölüm IV'teki keşifsel analizle kısmen yanıtlanmıştır.

Video: https://youtu.be/VIDEO-LINK-HERE. Kod: https://github.com/mrayenesay/leukemia-all-aml-ml. Bu rapordaki her sayı `scripts/run_eda.py` tarafından üretilir ve LaTeX makrosu olarak alınır; bkz. Bölüm VI.

Bu ara raporun katkıları. (1) 38 kaynağın belgelenmiş taraması (Bölüm II); (2) uyumlaştırılmış iki dış kohort, toplam üç veri seti (Bölüm III); (3) numaralı modelleme çıkarımları içeren betiklenmiş keşifsel veri analizi (EDA) (Bölüm IV); (4) makalenin ana iddialarını sınayan fizibilite pilotu ve önceden belirlenmiş plan (Bölüm V).

II. Literatür Taraması

Arama protokolü. Crossref (dergi makalelerine süzülmüş anahtar kelime araması), Europe PMC (tam metin) ve PubMed/NCBI E-utilities 3 Kasım 2026'da sorgulanmıştır. Keşif 2021–2026 ile sınırlandırılmış; klasik çalışmalar (1995–2020) tanımlayıcıyla eklenmiş ve aynı şekilde doğrulanmıştır. Sorgulardan bazıları: *"golub leukemia gene expression classification"*, *"machine learning cancer classification gene expression data review"* ve tam metin sorgusu *"7129" AND "72 samples" AND (leukemia OR leukaemia) AND classification*. *Dahil etme:* kullanılan veri setleri, ifade verisinde sınıflandırma veya öznitelik seçimi, doğrulama yanlılığı, batch etkileri ya da güncel tablosal öğrenme üzerine hakemli dergi veya konferans makaleleri. Golub sonucu olan makalelerde bildirilen örnek ve gen sayıları kaydedilmiştir. *Dışlama:* konferans özetleri, görüntü tabanlı lösemi çalışmaları, Golub etiketli sonucu doğrulanamayan makaleler ve dizinlenmeyen yayın organları. Başlığına göre taranan 152 kayıttan 24'ünün özeti değerlendirilmiş; 30 çalışma ile 8 yöntem/istatistik kaynağı dahil edilmiştir. 38 kaynağın tamamı hakemlidir ve 11'i 2021 veya sonrasına aittir. DOI'ler Crossref ile doğrulanmış; 31 çalışmaya tam metin, 6'sına özet, 1'ine künye düzeyinde başvurulmuş ve aşağıdaki iddialar yapay zekâ desteğiyle bu metinlere göre denetlenmiştir (`reports/literature/claim_audit.md`).

Veri setleri ve erken çalışmalar. Golub vd. [1], 38 örnekte öğrenilip 34 bağımsız örneğe uygulanan 50 genli ağırlıklı oylama öngörücüsüyle sınıf keşfi ve sınıf tahminini tanıtmıştır. Armstrong vd. [4], MLL translokasyonlu lenfoblastik lösemilerin ayrı bir ifade sınıfı oluşturduğunu göstermiştir. MILE, protokolleri 11 laboratuvarda standartlaştırmış [5]; 18 sınıfta altın standartla %92,2 çapraz doğrulanmış uyuma, bağımsız ileriye dönük kohortta %88,1'e ulaşmıştır [2]. Andersson vd. [6], ardışık 121 çocukluk çağı lösemisini k en yakın komşuyla sınıflandırmıştır. CuMiDa [7] bu tür veri setlerini kıyaslama için derler.

Sınıflandırıcılar ve gen seçimi. SVM'ler [8] mikrodizi sınıflandırmasına erken dönemde uygulanmış [9], [10]; SVM-RFE genlerin özyinelemeli geriye doğru elenmesini getirmiştir [10]. Dudoit vd. [11] basit diyagonal diskriminant analizi ve k-NN'nin karmaşık yöntemlerle yarıştığını bulmuş, Tibshirani vd. [12] en yakın küçültülmüş merkezleri önermiş, Díaz-Uriarte ve Alvarez de Andrés [13] gen seçiminde rastgele ormanları [14] kullanmıştır. Statnikov vd. [15] 11 veri setinde çok kategorili SVM'leri en güçlü bulmuş; elastic net [16] ise ilişkili öngörücüleri gruplayan seyrek modeller sunmuştur. 132 makalelik bir derleme hibrit öznitelik seçimini en sık araştırma yönü olarak saptamış (%34,9) [17]; bir başkası seçimi filtre, sarmalayıcı, gömülü ve hibrit olarak gruplamıştır [18].

Doğrulama yanlılığı ve batch etkileri. Genleri CV'den önce tüm örneklerde seçmek iyimser hata oranları üretir [19]; hiperparametreleri değerlendirme katlarında ayarlamak da öyle. İç içe CV bu yanlılığı önler ve benzetimde neredeyse yansız, hafif kötümser tahminler vermiştir [20]; seçim ölçütünün varyansı ise sorun olmaya devam eder [21]. Yeniden örnekleme tahminleri üzerindeki testler, örtüşen eğitim setlerini hesaba katmalıdır; [3] düzeltmesi rastgele alt örnekleme için türetilmiştir, çoklu veri setlerinde ise sıra testleri önerilir [22]. Batch etkileri ifade verisine hâkim olabilir [23] ve deneysel Bayes konum/ölçek yöntemiyle (ComBat) düzeltilebilir [24].

Güncel çalışmalar. 105 çalışmadan 12.029 transkriptomda AML, ALL dahil diğer tüm örneklerden, çalışma-ayrık bölmelerde de ayrılabilmektedir [25]; swarm learning böyle verilerin benzetimli çok merkezli bölümlerinde tek düğümlü modelleri geçmektedir [26]. Golub etiketli güncel sonuçlar çok yüksektir [27]–[30]. Ancak makalelerin protokol anlatımına göre [27], [30] genleri CV döngüsünden önce seçmekte, [29] aynı veride seçim ve ayar yapan rastgele ayırmalar kullanmakta (ve Golub'da bulunmayan CML, CLL ve sağlıklı sınıflarını listelemekte), [28] ise seçimin her katta tekrarlanıp tekrarlanmadığını belirtmemektedir. Orta büyüklükte, düşük boyutlu tablosal kıyaslarda ağaç toplulukları derin ağları geçmektedir [31]; bu rejim $p \gg n$ mikrodizileri kapsamaz. FT-Transformer 11 veri setinin çoğunda en iyi derin model olmuş, ama her zaman artırılmış ağaçları geçememiştir [32]; TabPFN 10.000 örnek ve 500 özniteliğe kadar ayarlanmış ağaç topluluklarını geçmiş [33], GenePT ise gen metin özetlerini dil modeliyle gömmüştür [34].

Boşluk. Tablo I'deki dört güncel çalışmada doğruluklar %97 ile neredeyse %100 arasındadır; sabit veya dış doğrulama kullanan önceki çalışmalar ise daha düşük değerler bildirir (ör. 34 testte 2 hata [12], seçim yanlılığı düzeltildikten sonra yaklaşık %5 hata [19]). Sayıları karşılaştırmak güçtür: protokoller LOOCV, k kat CV, sabit bölme ve rastgele ayırmaları karıştırır; bazı çalışmalar genleri tüm veride seçer [10], [27], [30] ve dört güncel çalışmanın hiçbiri güven aralığı bildirmez. Çoğu başka veri setlerini de değerlendirir, ancak ayrı ayrı: okuduğumuz Golub tabanlı sınıflandırma makalelerinde hiçbir sınıflandırıcı veya gen listesi bağımsız bir lösemi kohortuna ya da platforma aktarılmamaktadır. Bu proje, tek bir sızıntısız iç içe protokol, aralık tahminleri ve iki dış kohortta aynı işlem hattıyla bu sorunları ele alır.

III. Veri Setleri

Tablo II üç veri setini özetler; sınıf dağılımları Ek C'de (Şekil 7) verilmiştir.

Golub (ana veri seti). Golub vd. [1] (DOI 10.1126/science.286.5439.531); özgün Broad Institute dosyalarının Kaggle kopyasından alınmıştır ("Gene expression data set (Golub et al.)", lisans CC0). Platform: Affymetrix Hu6800/HuGeneFL (GEO GPL80), 7.129 prob seti (58 AFFX kontrolü; 6.434 tanesi bir gen sembolüne eşlenir), P/M/A çağrılı MAS 4 average difference. Hastaların çoğu çocuktur (47 ALL'nin tamamı ve 25 AML'nin 10'u) ve 72 örneğin 62'si kemik iliğidir; bağımsız set daha heterojendir (periferik

Tablo I
Literatür özeti (alt küme; 30 çalışmalık tam tablo Ek A'dadır). Sızıntı riski, bildirilen protokol sırasına ilişkin bizim okumamızdır.

Kaynak (yıl)	Veri seti	Ön işleme / öznitelik seçimi	Yöntem	Doğrulama	En iyi sonuç	Sızıntı riski
[1] (1999)	Golub 38/34	sınıf korelasyonuyla (SNR) gen seçimi	50 genli ağırlıklı oylama	LOOCV + sabit bağımsız test	test: 29/34 tahmin, tümü doğru	düşük (seçim eğitimde)
[11] (2002)	Golub, NCI60, lenfoma	kırpma, log, tek değişkenli filtre	DLDA, k-NN, ağaçlar	150 tekrarlı 2:1 bölme	DLDA ortanca hata 0	düşük
[19] (2002)	kolon, Golub	CV içinde ve dışında seçim	SVM-RFE; Fisher + ileri seçim	dış 10 kat, .632+	seçim yanlılığı yaklaşık %5	– (sızıntıyı inceler)
[27] (2022)	Golub + 3	GNN tabanlı sıralama	SVM	10 kat CV	doğruluk 0,971 (2 gen)	muhtemelen yüksek (seçim CV'den önce)
[28] (2022)	Golub + 2	topluluk sarmalayıcı (k-NN)	yığılmış DNN	k kat CV	doğruluk %99,6	belirsiz (seçim sırası)
[29] (2022)	"Golub" (UCI)†	PSO (2.323 gen)	optimize CNN	rastgele 70/30, 80/20	doğruluk %99,9	yüksek (CV yok)
[30] (2024)	Golub + CuMiDa	RF önemi $\geq 0{,}04$	süper öğrenici	10 kat CV + %20 test	doğruluk 0,98	yüksek (sıralama CV'den önce)

†Makale, Golub verisinde bulunmayan CML, CLL ve sağlıklı sınıflarını da listelemektedir.

kan, çocukluk çağı AML'si, farklı referans laboratuvarları) [1]. Referans bölme 38 eğitim (27 ALL / 11 AML) ve 34 bağımsız örnek (20 / 14) içerir; genel oran %65/%35'tir.

MILE (benzer veri seti 1). Microarray Innovations in LEukemia, aşama 1, GEO GSE13159 (DOI 10.1200/JCO.2009.23.4732, 10.1111/j.1365-2141.2008.07261.x) [2], [5]. 18 sınıfta 2.096 tanı örneği içerir; örnekler 11 laboratuvarda standart protokollerle Affymetrix HG-U133 Plus 2.0 (GPL570, 54.675 prob seti) üzerinde profillenmiş ve kantil normalize sinyalden türetilmiştir [35]. 14 ALL ve AML sınıfı ikili etikete eşlenmiş; CLL, CML, MDS ve lösemik olmayan örnekler dışlanmıştır. Geriye 1.292 örnek kalır (750 ALL / 542 AML; 1.211 kemik iliği, 81 periferik kan). *Seçilme nedeni:* aynı klinik soru, çok daha büyük çok merkezli kohort, Affymetrix teknolojisi ve ön eğitime (bonus B1) yetecek büyüklük.

Andersson (benzer veri seti 2, bonus B4). İsveç'in Lund kentinden ardışık 121 çocukluk çağı akut lösemisi, GEO GSE7186 (DOI 10.1038/sj.leu.2404688) [6]: 87 B soylu ALL, 11 T hücreli ALL ve 23 AML (6 normal kemik iliği kontrolü dışlanmıştır). GEO'ya göre 108 örnek kemik iliği, 13 örnek periferik kandır. Platform: Swegene Human 27K RAP iki renkli noktalı cDNA dizisi (GPL4861, 21.370 raportör). Değerler lowess normalize $\log_2$(örnek/Universal Human Reference) oranlarıdır; hastane bazında merkezlenmiş ve %40 varlık ölçütüyle önceden süzülmüştür, bu nedenle değerlerin %7,19'u eksiktir. *Seçilme nedeni:* aynı soru ama farklı teknoloji, tümüyle pediatrik seri ve gerçek eksik değerler.

Kilitli dış test setleri (final). Sonuçların yalnızca görülmüş veriye uymadığını göstermek için iki bağımsız set final değerlendirmesine kadar kapalı tutulmuştur: (i) MILE aşama 2 (GEO GSE13164, Roche AmpliChip Leukemia, GPL7473, 1.480 prob seti): bu serideki 1.152 örneğin 693'ü akut lösemidir (436 ALL / 257 AML; metaveriden sayılmış, ifade değerlerine bakılmamıştır) [2]; (ii) TARGET-ALL-P2 ve TARGET-AML (NCI GDC, açık erişimli STAR sayımları), mikrodiziden RNA-seq'e geçişi sınar. TARGET'ta sınıf ile proje karıştığından bu set yalnızca dışarıda eğitilmiş modelin testinde kullanılacaktır. Golub'un 34 bağımsız örneği EDA'da incelenmiş, ama hiçbir modele girmemiştir.

Lisanslar. NCBI, GEO verilerine kısıtlama koymaz, ancak veri sahiplerinin hakları olabilir; tüm setler atıfla akademik araştırmada kullanılmıştır.

Tablo II
Üç veri setinin karşılaştırması.

	Golub	MILE	Andersson
Kaynak	[1], Kaggle (CC0)	GSE13159	GSE7186
Platform	Hu6800 (GPL80)	U133 Plus 2.0 (GPL570)	27K cDNA (GPL4861)
Teknoloji	tek renk oligo	tek renk oligo	iki renk cDNA
Ölçü	MAS4 avg. diff.	aralık ölçekli log	$\log_2$ oran
Popülasyon	çoğunlukla pediatrik	çok merkezli	pediatrik
Örnek n	72	1.292	121
Öznitelik p	7.129	54.675	21.370
ALL / AML	47 / 25	750 / 542	98 / 23
Bölme	38 eğitim / 34 test	yok	yok
Eksik değer	0	%0,08	%7,19
Gen (sembol)	5.268	20.848	9.677

Uyumlaştırma. Problar GEO platform açıklamalarıyla (GPL80/GPL570/GPL4861) HGNC sembollerine eşlenmiştir. Belirsiz problar ("`A///B`") çıkarılmış, gen başına birden çok prob en yüksek ortalama ifadeli proba indirgenmiştir. Sonuçta 5.268, 20.848 ve 9.677 gen elde edilir; 5.207 gen Golub ve MILE'da, 3.487 gen Golub ve Andersson'da, 3.469 gen üçünde ortaktır.

IV. Keşifsel Veri Analizi

Tüm analizler Python'da (pandas, SciPy, scikit-learn [36], seaborn) `scripts/run_eda.py` ile, tohum 42 kullanılarak yürütülmüştür. *Sızıntı notu:* bu bölümdeki denetimli gen sıralamaları yalnızca veriyi betimler. Modeller için öznitelik seçmekte asla yeniden kullanılmamalıdır; aksi hâlde [19] seçim yanlılığı yeniden üretilir.

A. Veri kalitesi

Golub. 513.288 değer arasında 0 eksik veya sonsuz değer vardır; bu nedenle modüldeki "INF'yi ortalamayla doldur" adımının özgün dosyalarda etkisi yoktur (yalnızca pozitif olmayan değerlerin log'u alındığında önem kazanır, kırpma bunu önler). Buna karşılık değerlerin %28,7'si negatif, %32,7'si 20'nin altında, %0,83'ü 16.000'in üstündedir (aralık -28.400 ile 71.369; Şekil 1a). Negatif average difference, mismatch sinyali perfect-match sinyalini aştığında, yani transkript yokken ortaya çıkar. Çağrılar bunu doğrular: ölçümlerin %70,2'si

Absent, %28,2'si Present ve %1,6'sı Marginal'dır. Ortanca değer Absent için 33, Present için 662'dir (Şekil 1c) ve 1.971 prob hiç Present çağrısı almaz. Dizi başına Present oranı %19,1 ile %40,5 arasında değişir ve görünür bir sınıf örüntüsü yoktur (Şekil 1b). **Etiket eşleme:** hasta sütunları sayısal sırada *değildir* (eğitim sırası 1–27, 34–38, 28–33). Bu yüzden etiketler hasta numarasıyla birleştirilmiş; betik eğitim kimliklerinin tam 1–38, test kimliklerinin 39–72 ve sınıf sayılarının 27/11 ile 20/14 olduğunu doğrular.

MILE ve Andersson. GEO, MILE değerlerini normalize sinyal olarak tanımlasa da her dizi tam olarak 0,00–1,00 aralığını kaplar. Bir dizinin ArrayExpress örnek tablosuyla karşılaştırılması, değerlerin $\log_2$ sinyalin monoton (Spearman 1,000) ve neredeyse doğrusal bir fonksiyonu olduğunu gösterir (Pearson 0,998; doğrusal sinyalle 0,51): bunlar dizi başına aralık ölçekli log yoğunluklardır, bu nedenle ek log dönüşümü uygulanmaz. 45 prob seti tüm dizilerde boştur ve çıkarılmıştır (tüm değerlerin %0,08'i); sonsuz değer yoktur. Andersson'da değerlerin %7,19'u eksiktir: 12.084 raportörde en az bir boşluk, 2.841 raportörde %20'den fazla eksik vardır; bir dizide değerlerin %24,3'ü yoktur (Ek C, Şekil 15). Bu nedenle imputasyon gereklidir ve eğitim katlarının içinde öğrenilmelidir.

B. Dağılımlar ve dönüşüm

Değerler ders rehberinde verilen $[20, 16000]$ penceresine kırpılmış ve $\log_2$ dönüşümü uygulanmıştır (Dudoit vd. [11] 100 tabanı, aynı tavanı ve 10 tabanlı log kullanmıştır). Birleşik çarpıklık 7,08 değerinden 0,55 değerine düşer; gen ortalaması ile standart sapma arasındaki Spearman korelasyonu 0,95 değerinden 0,18 değerine iner (Ek C, Şekil 8). Dönüşüm, aksi hâlde birkaç yüksek yoğunluklu genin uzaklık tabanlı yöntemlere (SVM, k-NN, PCA) hâkim olmasına yol açacak ortalama–varyans bağımlılığının çoğunu giderir. Kırpmadan sonra değerlerin yaklaşık üçte biri tabanda ($\log_2 20$) toplanır; bu, yoğunlukta bir sivrilme olarak görünür. [11] filtresi (maks/min >5 ve maks$-$min >500) 7.129 probun 3.859'unu korur; 100 tabanıyla 3.571'ini korur ki bu, [11] çalışmasındaki gen sayısının tam olarak aynısıdır. MILE (aralık ölçekli log) ve Andersson ($\log_2$ oran, ortanca $-0{,}04$) zaten log ölçeğindedir.

C. Boyut indirgeme

Merkezlenmiş, filtrelenmiş $\log_2$ veri üzerindeki PCA (Şekil 2) varyansın dağınık olduğunu gösterir: PC1 %10,8, ilk on PC %49,6 açıklar ve %80 için 37 PC gerekir. Yine de PC1 tek başına ALL ve AML'yi AUC 0,984 ile sıralar; yani sınıf farkı en büyük tekil varyasyon kaynağıdır. t-SNE (perplexity 10) [37] iki belirgin grup gösterir (siluet 0,40; 10 boyutlu PCA uzayında 0,17) ve bağımsız örnekler (siyah kenarlı) eğitim örnekleriyle karışır. MILE'da (en değişken 5.000 prob) en iyi tek PC AUC 0,987 verir. Andersson'da PC1 %17,5 açıklar ve AUC 0,999 verir.

D. Ayırt edici genler

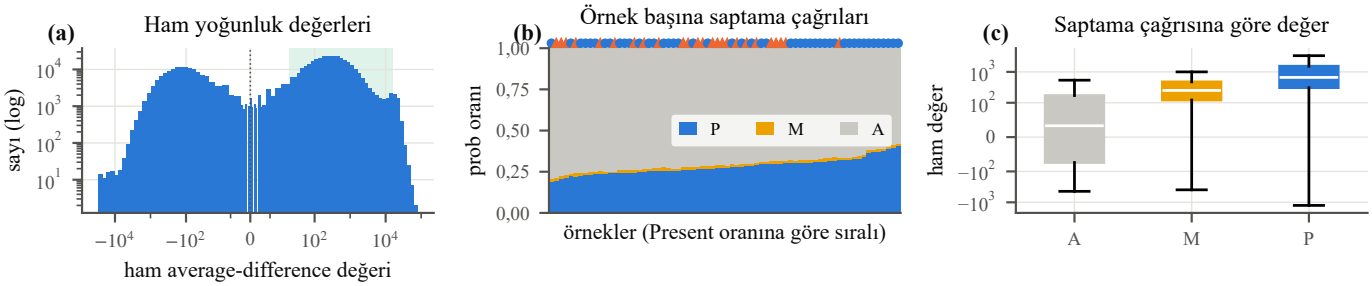
Her gen için Welch t testi, Mann–Whitney U testi (ikisi de Benjamini–Hochberg FDR [38] ile) ve Golub'un sinyal-gürültü oranı (SNR) hesaplanmıştır. Golub'da 3.859 genden 945'i $q < 0{,}05$ düzeyinde anlamlıdır ($q < 0{,}01$'de 567; Mann–Whitney ile 1.014); 462 gen AML'de, 483 gen ALL'de yüksektir. SNR ve t genleri neredeyse aynı sıralar ($\rho = 0{,}999$; Ek C). Üst sıradaki genler (Ek C, Tablo V) bilinen biyolojiyle uyumludur: miyeloid genler (CST3, CD33, MPO, ZYX, MGST1) AML'de, lenfoid/B hücre genleri (TCF3, CD79B, CD19, DNTT, VPREB1, CCND3) ALL'de yüksektir. CST3, ZYX ve CD33, [1] çalışmasının 50 bilgilendirici geni arasında da yer alır. Örneklerin ilk 30 gen üzerinde hiyerarşik kümelenmesi (Ek C, Şekil 6) sınıfları geri kazanır (düzeltilmiş Rand indeksi ARI = 0,89). Andersson'da ARI yalnızca 0,41'dir: T-ALL örnekleri AML'nin yanında kümelenir, çünkü ALL'de yüksek genlerin çoğunu süren B hücre programından yoksundurlar. 1.292 örnekle MILE prob setlerinin %69,1'i anlamlıdır, kümeleme yine sınıfları geri kazanır (ARI 0,86) ve sıralamanın başında LEF1 (lenfoid) ile MGST1, CFD, APLP2 (miyeloid) yer alır.

E. Eğitim ve bağımsız set (batch etkisi)

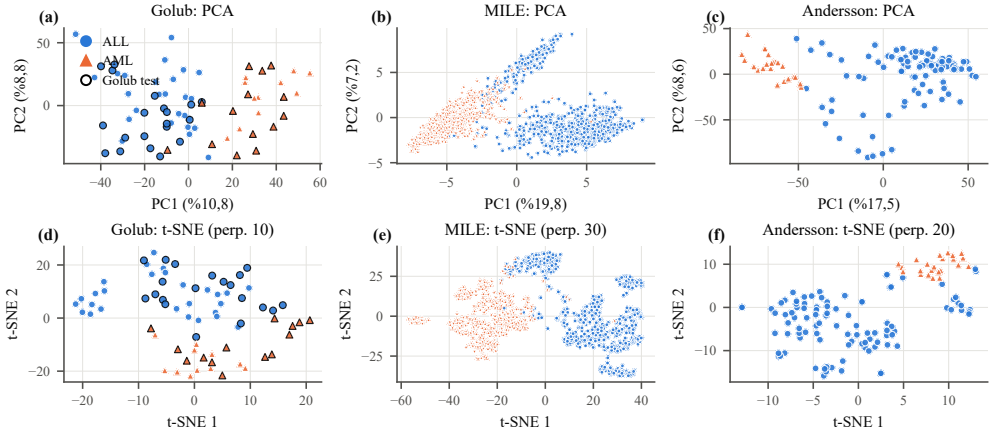
Ortalama Present oranı eğitim setinde %29,0, bağımsız sette %27,3'tür (Mann–Whitney $p = 0{,}071$). Dizi parlaklığının vekili olan 75. yüzdelik yoğunluk bağımsız sette daha düşüktür (ortanca 421; eğitimde 482, $p = 0{,}016$; Ek C, Şekil 5). Batch etkisini sınıf bileşiminden ayırmak için eğitim ve test her sınıfın *içinde*, gen bazlı Kolmogorov–Smirnov testleriyle karşılaştırılmıştır. Kayma yoksa genlerin %5'inde $p < 0{,}05$ beklenir. ALL için %17,7 (FDR sonrası 28 gen anlamlı), AML için %8,0 (0 gen) gözlenmiştir. Yani orta düzeyde, ALL'ye özgü bir kayma vardır. Bu, bağımsız örneklerin daha heterojen toplanmasıyla tutarlıdır ve tek bir 34 örneklik test skorunun CV tahminlerinden sapmasının nedenlerinden biri olabilir (**AS2**); yine de [11] bu bölmede belirgin bir doğruluk kaybı görmemiştir.

F. Kohortlar arası karşılaştırma

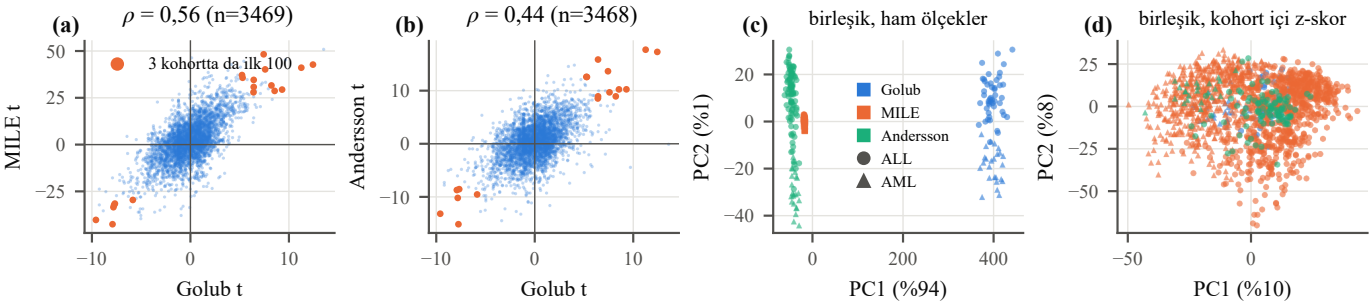
Ortak genlerde gen bazlı t istatistikleri kohortlar arasında pozitif koreledir (Şekil 3a,b): Golub–MILE $\rho = 0{,}56$, Golub–Andersson $\rho = 0{,}44$, MILE–Andersson $\rho = 0{,}67$. İlk 100 genden 33'ü Golub ve MILE'da (hipergeometrik $p = 3{,}6 \times 10^{-28}$; %100 aynı yönde), 28'i Golub ve Andersson'da ($p = 1{,}5 \times 10^{-21}$) ortaktır. 18 gen üç kohortun da ilk 100 geni arasındadır (CST3, CD33, CTSA, POU2AF1, CD79A, PYGL, PCBD1, NPY, ASAH1, MAPKAPK3, CD19, CSTA). Ancak *ölçekler* uyumsuzdur: ortanca ifade üç log ölçekte 7,31, 0,46 ve $-0{,}03$'tür. Uyumlaştırma yapılmayan birleşik PCA'da PC1 varyansının η^2 = %99,8 kadarını kohort, yalnızca %0,0 kadarını sınıf açıklar (Şekil 3c). Kohort içi gen bazlı z-skorlamadan sonra kohort %0,0, sınıf %61,4 açıklar (Şekil 3d). Biyoloji kohortlar arasında taşınır, ölçüm ölçeği taşınmaz; bu yüzden kohortlar arası modeller, test etiketleri kullanılmadan kestirilen kohort içi standardizasyon veya ComBat [24] kullanacaktır. Sınıf oranları kohortlar arasında farklı olduğundan bu düzeltmeler sınıf sinyalini de silebilir; bu ayrıca kontrol edilecektir.



Şekil 1. Golub veri kalitesi. (a) Simetrik log eksende ham average-difference değerleri; gölgeli bant [20, 16000] kırpma penceresidir. (b) Dizi başına Present/Marginal/Absent çağrı oranları (üstteki işaretler: sınıf). (c) Saptama çağrısına göre ham değer: Absent çağrıları negatif veya sıfıra yakın değerlerle örtüşür.



Şekil 2. Üç kohortun denetimsiz gömmeleri (üst: PCA, alt: t-SNE; renk/işaret: sınıf). Golub bağımsız set örnekleri siyah kenarlıdır. Tüm kohortlarda baskın bir ALL/AML ekseni görülür; varyans grafikleri Ek C'dedir.



Şekil 3. Ortak genlerde kohortlar arası uyum. (a,b) Golub'un MILE ve Andersson ile gen bazlı Welch t istatistikleri (turuncu: üç kohortta da ilk 100 gen). (c) Uyumlaştırılmamış birleşik PCA sınıfları değil kohortları ayırır; (d) kohort içi z-skorlama ALL/AML eksenini ortaya çıkarır (renk: kohort, işaret: sınıf).

G. Numaralı bulgular ve modelleme çıkarımları

1) *Negatif ve taban düzeyi yoğunluklar* (%28,7 < 0) ⇒ ölçeğe duyarlı her modelden önce [20, 16000] kırpma ve $\log_2$.
2) $p \gg n$ (7.129 öznitelik, 72 örnek) ⇒ öznitelik seçimi (varyans veya kat değişimi filtresi, ardından tek değişkenli k-best) her eğitim katının *içinde*; k iç CV'de ayarlanır.
3) *Güçlü düşük boyutlu sinyal* (PC1 AUC 0,984) ⇒ neredeyse kusursuz skorlar olasıdır; yöntemler arası farklar küçük kalacağından güven aralıkları ve eşleştirilmiş testler şarttır (**AS1**).
4) *Sınıf dengesizliği* (65/35, MILE 750/542, Andersson 98/23) ⇒ tabakalı katlar, `class_weight=balanced`; doğruluğun yanında dengeli doğruluk, F1 ve ROC-AUC. SMOTE kullanılırsa yalnızca eğitim katlarında.
5) Golub'da *eğitim/test kayması* ⇒ 38/34 sonucu ve iç içe CV ayrı raporlanır, fark açıklanır (**AS2**).
6) *Eksik değerler* (Andersson) ve *ölçek duyarlılığı* ⇒ LR, SVM ve sinir ağları için kat içi ortanca/k-NN imputasyonu ve kat içi z-skorlama (ağaçlar ölçekten bağımsızdır).

Tablo III
Aktarım pilotu. DD: dengeli doğruluk; ham, z, sıra: normalizasyon. Sabit model, ayar yok.

Eğitim → test	AUC (z)	DD ham	DD z	DD sıra
Golub → MILE	0,97	0,50	0,89	0,69
Golub → Andersson	0,97	0,50	0,94	0,70
MILE → Golub	0,93	0,84	0,93	0,64
MILE → Andersson	0,99	0,92	0,93	0,52
Andersson → Golub	0,97	0,50	0,59	0,50
Andersson → MILE	0,99	0,50	0,74	0,50

7) *Ortak biyoloji, farklı ölçekler* ($\rho > 0$, anlamlı örtüşme, PC1'e kohort hâkim) ⇒ kohortlar arası aktarımda 3.469 ortak gende kohort içi standardizasyon (**AS3**). Soy heterojenliği (T-ALL) olası bir hata kaynağıdır ve ayrıca incelenecektir.

V. Fizibilite Pilotu, Final ve Makale Planı

Fizibilite pilotu. Planın ana iddialarının sınanabilir olduğunu görmek için hiperparametreleri önceden sabitlenmiş küçük bir deneme yapılmıştır (`scripts/run_feasibility.py`). Bu bir model karşılaştırması değildir: sonuçlara göre ayar yapılmamış, kilitli setler kullanılmamıştır. *Sızıntı.* 38 Golub eğitim örneğinde doğrusal SVM ve 50 genle, gen seçimi katların içinde yapıldığında dengeli doğruluk (DD) 0,91, CV'den önce tüm örneklerde yapıldığında 1,00 çıkmıştır. Etiketler karıştırıldığında (200 permütasyon) gerçek bilgi olmamasına rağmen dışarıda seçim 0,91, içeride seçim şans düzeyinde 0,50 vermiştir: sızıntılı protokol, sinyal yokken de yüksek skor üretebilir. *Aktarım.* Tek kohortta eğitilen sabit lojistik regresyon (100 gen) diğer kohortlarda denenmiştir (Tablo III; Golub yalnızca 38 eğitim örneğidir). Kohort içi z-skorla AUC 0,93–0,99 kalırken DD 0,59–0,94 aralığına yayılır. Ham ölçekte altı yönün 4'ünde model tek sınıfa yığılır (DD 0,50), ancak bu ölçek farkından beklenen bir sonuçtur. Etiket kullanmayan z-skor çoğu yönü düzeltir, Andersson'la eğitimde yetersiz kalır; örnek içi sıra dönüşümü, [25]'deki RNA-seq aktarımının aksine burada yardımcı olmaz (Andersson değerleri referansa oran olduğundan bu beklenebilir). Özetle *sıralama taşınıyor, karar eşiği taşınmıyor*: yalnızca AUC raporlamak klinik kullanılabilirliği olduğundan iyi gösterebilir. T-ALL'de hata daha yüksektir (MILE→Andersson %27,3, B soylu ALL'de %12,6, $n = 11$; Golub→MILE %6,9 ve %3,3, $n = 174$). Tek çalışmadır ve kohort içi z-skor hedef setin sınıf oranına bağlıdır; bu sonuçlar ön bulgudur.

Makale hedefi ve özgün katkı. Çalışma "en iyi modeli" aramaz; ALL/AML ayrımının kolay olduğunu kabul eder ve *bildirilen başarının ne kadarının protokolden geldiğini ve başarının platform değişince nerede kırıldığını* ölçer. Katkılar: (K1) aynı işlem hattında sızıntının şişirme miktarı; (K2) iç içe CV ve güven aralıklarıyla yöntem karşılaştırması; (K3) kilitli dış setlerde sıralama ile karar eşiğinin ayrı değerlendirilmesi ve etiketsiz düzeltmelerin sınanması; (K4) $n = 72$ düzeyinde TabPFN ve derin modeller. [25] AML'yi diğer tüm örneklerden ayırır ve MILE'ı kapsıyor olabilir; bizim görevimiz ikili ALL/AML, odağımız protokol şişmesi ve eşik aktarımıdır. Birincil sonlanım noktaları önceden sabittir: kilitli setlerde %95 güven aralıklı DD ve AUC. Kilitli setler model seçimi bittikten sonra bir kez açılır; olumsuz sonuç da aynen raporlanır. **Hedef konferans:** IEEE EMBC 2027 adaydır (son tarih 24 Ocak 2027; 4 sayfa içerik + 1 sayfa kaynak, en çok 20 kaynak; resmî sayfa, 6 Kasım 2026). Öğretim üyesinin yazılı onayı alınacak, makale İngilizce yazılacak ve tek konferansa gönderilecektir. Final tarihinde başvuru kapalıysa bildirileri IEEE Xplore'da yayımlanan başka bir konferans seçilecektir.

Yöntemler (henüz sonuç yok). Farklı tümevarımsal yanlılıkları kapsayan üç ML yöntemi: (M1) yorumlanabilir katsayılı seyrek doğrusal model olan *elastic-net cezalı lojistik regresyon* [16]; (M2) mikrodiziler için tarihsel referans olan, doğrusal ve RBF çekirdekli *SVM* [9], [10]; (M3) etkileşimleri modelleyen ve permütasyon önemi sunan [13], [14] *rastgele orman*. Modüldeki karar ağacı taban modeldir.

İşlem hattı ve doğrulama. Veriye bağlı her adım her katta yeniden öğrenilir (Ek B, Şekil 4; arama uzayları da oradadır). (a) 38/34 bölme: 38 örnekte 5 katlı tabakalı CV ile ayar, model seçiminden sonra 34 örnekte *bir kez* değerlendirme; (b) 72 örnekte iç içe CV: dış 5 kat, 5 tohum (42, 7, 123, 2024, 31337), iç 5 katlı arama, tüm yöntemlerde aynı dış katlar. MILE ve Andersson aynı protokolü izler.

Metrikler ve istatistik. Doğruluk, dengeli doğruluk, kesinlik, duyarlılık, özgüllük, F1, ROC-AUC ve karışıklık matrisleri; 25 dış katta ortalama ± SS ve düzeltilmiş yeniden örnekleme t'sinden [3] yaklaşık %95 güven aralıkları; kohort içinde Holm düzeltmeli ikili testler, kohortlar arası betimsel ortalama sıralar [22], sabit bölmede McNemar; ROC/PR, kayıp ve k–performans eğrileri, ablasyon, gen önemi ve çalışma süresi.

Bonuslar. *B1:* MLP ve otokodlayıcı + sınıflandırıcı (erken durdurma ve mimari iç katlarda, isteğe bağlı MILE ön eğitimi). *B2:* TabPFN [33] ($\leq$ 500 genin kat içi seçiminden sonra) ve GenePT tarzı gömmeler [34]. *B3:* yukarıdaki konferans gönderimi. *B4:* Andersson. **Takvim:** 1–2. haftalar Golub iç içe CV ve sızıntı deneyi; 3–4 MILE/Andersson ve aktarım; 5–6 B1/B2, yorumlanabilirlik, kilitli setler; 7 makale, video, B3. **Riskler:** $n = 72$'de varyans; batch/platform etkileri; sinir ağı aşırı uyumu; TabPFN'in doğrulanmış aralığı; gen metinlerinden hastalık bilgisi sızması (B2); konferans takvimi.

VI. Tekrarlanabilirlik ve Sonuç

`python run_all.py` bu PDF'i ham veriden yeniden üretir (tohum 42, sabit `requirements.txt`); metindeki her sayı kodun yazdığı bir LaTeX makrosudur. Üç kohort da güçlü bir ALL/AML sinyali taşır; engeller $p \gg n$, eğitim/test kayması ve platform farklarıdır. Pilot, makalenin iki ana iddiasının ölçülebilir olduğunu gösterir; final **AS1**–**AS4**'ü kilitli setlerle sınayacaktır.

Yapay Zekâ Kullanım Beyanı

Anthropic'in Claude (Opus 5.5) modeli kod, literatür arama, okuma, iddia denetimi ve metin taslağında yardımcı olmuştur. Yazar içeriği gözden geçirmiş ve sorumluluğu üstlenmektedir (tam beyan ayrıca sunulmuştur).

Kaynaklar

[1] T. R. Golub, D. K. Slonim, P. Tamayo *et al.*, "Molecular classification of cancer: Class discovery and class prediction by gene expression monitoring," *Science*, vol. 286, no. 5439, pp. 531–537, 1999, doi: 10.1126/science.286.5439.531.

[2] T. Haferlach, A. Kohlmann, L. Wieczorek *et al.*, "Clinical utility of microarray-based gene expression profiling in the diagnosis and subclassification of leukemia: Report from the International Microarray Innovations in Leukemia Study Group," *Journal of Clinical Oncology*, vol. 28, no. 15, pp. 2529–2537, 2010, doi: 10.1200/JCO.2009.23.4732.

[3] C. Nadeau and Y. Bengio, "Inference for the generalization error," *Machine Learning*, vol. 52, no. 3, pp. 239–281, 2003, doi: 10.1023/A:1024068626366.

[4] S. A. Armstrong, J. E. Staunton, L. B. Silverman, R. Pieters, M. L. den Boer, M. D. Minden, S. E. Sallan, E. S. Lander, T. R. Golub, and S. J. Korsmeyer, "MLL translocations specify a distinct gene expression profile that distinguishes a unique leukemia," *Nature Genetics*, vol. 30, no. 1, pp. 41–47, 2002, doi: 10.1038/ng765.

[5] A. Kohlmann, T. J. Kipps, L. Z. Rassenti *et al.*, "An international standardization programme towards the application of gene expression profiling in routine leukaemia diagnostics: the Microarray Innovations in LEukemia study prephase," *British Journal of Haematology*, vol. 142, no. 5, pp. 802–807, 2008, doi: 10.1111/j.1365-2141.2008.07261.x.

[6] A. Andersson, C. Ritz, D. Lindgren *et al.*, "Microarray-based classification of a consecutive series of 121 childhood acute leukemias: prediction of leukemic and genetic subtype as well as of minimal residual disease status," *Leukemia*, vol. 21, no. 6, pp. 1198–1203, 2007, doi: 10.1038/sj.leu.2404688.

[7] B. C. Feltes, E. B. Chandelier, B. I. Grisci, and M. Dorn, "CuMiDa: An extensively curated microarray database for benchmarking and testing of machine learning approaches in cancer research," *Journal of Computational Biology*, vol. 26, no. 4, pp. 376–386, 2019, doi: 10.1089/cmb.2018.0238.

[8] C. Cortes and V. Vapnik, "Support-vector networks," *Machine Learning*, vol. 20, no. 3, pp. 273–297, 1995, doi: 10.1007/BF00994018.

[9] T. S. Furey, N. Cristianini, N. Duffy, D. W. Bednarski, M. Schummer, and D. Haussler, "Support vector machine classification and validation of cancer tissue samples using microarray expression data," *Bioinformatics*, vol. 16, no. 10, pp. 906–914, 2000, doi: 10.1093/bioinformatics/16.10.906.

[10] I. Guyon, J. Weston, S. Barnhill, and V. Vapnik, "Gene selection for cancer classification using support vector machines," *Machine Learning*, vol. 46, no. 1–3, pp. 389–422, 2002, doi: 10.1023/A:1012487302797.

[11] S. Dudoit, J. Fridlyand, and T. P. Speed, "Comparison of discrimination methods for the classification of tumors using gene expression data," *Journal of the American Statistical Association*, vol. 97, no. 457, pp. 77–87, 2002, doi: 10.1198/016214502753479248.

[12] R. Tibshirani, T. Hastie, B. Narasimhan, and G. Chu, "Diagnosis of multiple cancer types by shrunken centroids of gene expression," *Proceedings of the National Academy of Sciences*, vol. 99, no. 10, pp. 6567–6572, 2002, doi: 10.1073/pnas.082099299.

[13] R. Díaz-Uriarte and S. Alvarez de Andrés, "Gene selection and classification of microarray data using random forest," *BMC Bioinformatics*, vol. 7, p. 3, 2006, doi: 10.1186/1471-2105-7-3.

[14] L. Breiman, "Random forests," *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001, doi: 10.1023/A:1010933404324.

[15] A. Statnikov, C. F. Aliferis, I. Tsamardinos, D. Hardin, and S. Levy, "A comprehensive evaluation of multicategory classification methods for microarray gene expression cancer diagnosis," *Bioinformatics*, vol. 21, no. 5, pp. 631–643, 2005, doi: 10.1093/bioinformatics/bti033.

[16] H. Zou and T. Hastie, "Regularization and variable selection via the elastic net," *Journal of the Royal Statistical Society Series B: Statistical Methodology*, vol. 67, no. 2, pp. 301–320, 2005, doi: 10.1111/j.1467-9868.2005.00503.x.

[17] E. Alhenawi, R. Al-Sayyed, A. Hudaib, and S. Mirjalili, "Feature selection methods on gene expression microarray data for cancer classification: A systematic review," *Computers in Biology and Medicine*, vol. 140, p. 105051, 2022, doi: 10.1016/j.compbiomed.2021.105051.

[18] F. Alharbi and A. Vakanski, "Machine learning methods for cancer classification using gene expression data: A review," *Bioengineering*, vol. 10, no. 2, p. 173, 2023, doi: 10.3390/bioengineering10020173.

[19] C. Ambroise and G. J. McLachlan, "Selection bias in gene extraction on the basis of microarray gene-expression data," *Proceedings of the National Academy of Sciences*, vol. 99, no. 10, pp. 6562–6566, 2002, doi: 10.1073/pnas.102102699.

[20] S. Varma and R. Simon, "Bias in error estimation when using cross-validation for model selection," *BMC Bioinformatics*, vol. 7, p. 91, 2006, doi: 10.1186/1471-2105-7-91.

[21] G. C. Cawley and N. L. C. Talbot, "On over-fitting in model selection and subsequent selection bias in performance evaluation," *Journal of Machine Learning Research*, vol. 11, pp. 2079–2107, 2010. [Online]. Available: https://www.jmlr.org/papers/v11/cawley10a.html

[22] J. Demšar, "Statistical comparisons of classifiers over multiple data sets," *Journal of Machine Learning Research*, vol. 7, pp. 1–30, 2006.

[23] J. T. Leek, R. B. Scharpf, H. C. Bravo, D. Simcha, B. Langmead, W. E. Johnson, D. Geman, K. Baggerly, and R. A. Irizarry, "Tackling the widespread and critical impact of batch effects in high-throughput data," *Nature Reviews Genetics*, vol. 11, no. 10, pp. 733–739, 2010, doi: 10.1038/nrg2825.

[24] W. E. Johnson, C. Li, and A. Rabinovic, "Adjusting batch effects in microarray expression data using empirical Bayes methods," *Biostatistics*, vol. 8, no. 1, pp. 118–127, 2007, doi: 10.1093/biostatistics/kxj037.

[25] S. Warnat-Herresthal, K. Perrakis, B. Taschler *et al.*, "Scalable prediction of acute myeloid leukemia using high-dimensional machine learning and blood transcriptomics," *iScience*, vol. 23, no. 1, p. 100780, 2020, doi: 10.1016/j.isci.2019.100780.

[26] S. Warnat-Herresthal, H. Schultze, K. L. Shastry *et al.*, "Swarm learning for decentralized and confidential clinical machine learning," *Nature*, vol. 594, no. 7862, pp. 265–270, 2021, doi: 10.1038/s41586-021-03583-3.

[27] W. Xie, W. Li, S. Zhang, L. Wang, J. Yang, and D. Zhao, "A novel biomarker selection method combining graph neural network and gene relationships applied to microarray data," *BMC Bioinformatics*, vol. 23, no. 1, p. 303, 2022, doi: 10.1186/s12859-022-04848-y.

[28] K. Rezaee, G. Jeon, M. R. Khosravi, H. H. Attar, and A. Sabzevari, "Deep learning-based microarray cancer classification and ensemble gene selection approach," *IET Systems Biology*, vol. 16, no. 3–4, pp. 120–131, 2022, doi: 10.1049/syb2.12044.

[29] J. B. Awotunde, A. L. Imoize, O. B. Ayoade, M. K. Abiodun, D.-T. Do, A. Silva, and S. N. Sur, "An enhanced hyper-parameter optimization of a convolutional neural network model for leukemia cancer diagnosis in a smart healthcare system," *Sensors*, vol. 22, no. 24, p. 9689, 2022, doi: 10.3390/s22249689.

[30] S. Selvaraj, A. O. Alsayed, N. A. Ismail, B. P. Kavin, E. M. Onyema, G. H. Seng, and A. Q. Uchechi, "Super learner model for classifying leukemia through gene expression monitoring," *Discover Oncology*, vol. 15, no. 1, p. 499, 2024, doi: 10.1007/s12672-024-01337-x.

[31] L. Grinsztajn, E. Oyallon, and G. Varoquaux, "Why do tree-based models still outperform deep learning on typical tabular data?" in *Advances in Neural Information Processing Systems (Datasets and Benchmarks Track)*, vol. 35, 2022, pp. 507–520, arXiv:2207.08815. [Online]. Available: https://proceedings.neurips.cc/paper_files/paper/2022/hash/0378c7692da36807bdec87ab043cdadc-Abstract-Datasets_and_Benchmarks.html

[32] Y. Gorishniy, I. Rubachev, V. Khrulkov, and A. Babenko, "Revisiting deep learning models for tabular data," in *Advances in Neural Information Processing Systems*, vol. 34, 2021, pp. 18 932–18 943, arXiv:2106.11959. [Online]. Available: https://proceedings.neurips.cc/paper/2021/hash/9d86d83f925f2149e9edb0ac3b49229c-Abstract.html

[33] N. Hollmann, S. Müller, L. Purucker, A. Krishnakumar, M. Körfer, S. B. Hoo, R. T. Schirrmeister, and F. Hutter, "Accurate predictions on small data with a tabular foundation model," *Nature*, vol. 637, no. 8045, pp. 319–326, 2025, doi: 10.1038/s41586-024-08328-6.

[34] Y. Chen and J. Zou, "Simple and effective embedding model for single-cell biology built from ChatGPT," *Nature Biomedical Engineering*, vol. 9, no. 4, pp. 483–493, 2025, doi: 10.1038/s41551-024-01284-6.

[35] W.-m. Liu, R. Li, J. Z. Sun *et al.*, "PQN and DQN: Algorithms for expression microarrays," *Journal of Theoretical Biology*, vol. 243, no. 2, pp. 273–278, 2006, doi: 10.1016/j.jtbi.2006.06.017.

[36] F. Pedregosa, G. Varoquaux, A. Gramfort *et al.*, "Scikit-learn: Machine learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.

[37] L. van der Maaten and G. Hinton, "Visualizing data using t-SNE," *Journal of Machine Learning Research*, vol. 9, pp. 2579–2605, 2008.

[38] Y. Benjamini and Y. Hochberg, "Controlling the false discovery rate: A practical and powerful approach to multiple testing," *Journal of the*

Royal Statistical Society: Series B (Methodological), vol. 57, no. 1, pp. 289–300, 1995, doi: 10.1111/j.2517-6161.1995.tb02031.x.

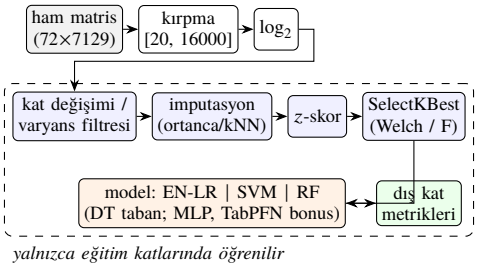
Ek A
Tam literatür tablosu

Tablo IV: Tam literatür özet tablosu (dahil edilen 30 çalışmanın tamamı, kronolojik).

Kaynak	Yıl	Veri seti	Ön işleme/öznitelik seçimi	Yöntem	Doğrulama	En iyi sonuç	Not
[1]	1999	Golub ALL/AML (Affymetrix Hu6800)	Sınıf korelasyonuyla bilgilendirici gen seçimi	Sınıf keşfi + ağırlıklı oylama sınıf öngörücüsü	38 örnekte LOOCV ve sabit 34	LOOCV 36/38 tahmin; test 29/34 tahmin, tümü doğru; 5 belirsiz	Özgün veri seti; çoğunlukla pediatrik
[9]	2000	Yumurtalık, Golub, kolon	bildirilmedi	SVM	Birini dışarıda bırakma ve 38/34	Golub testi 30-32/34 doğru	Teknikler arasında belirgin fark yok
[4]	2002	MLL/ALL/AML lösemileri	bildirilmedi	MLL yeniden düzenlenmiş lösemide ifade profili	bildirilmedi	bildirilmedi	Yaygın 3 sınıflı lösemi kıyas seti
[10]	2002	Lösemi ve kolon mikrodizileri	SVM-RFE gen sıralaması	Doğrusal SVM	LOO ve 38/34	Golub testi 8 veya 16 genle 0/34 hata	Seçimin LOO içinde yapıldığı belirtilmemiş
[11]	2002	Golub, NCI60, lenfoma	Taban 100, tavan 16000, filtre, log10	LDA/DLDA, kNN, ağaçlar, birleştirme	150 tekrarlı 2:1 bölme	DLDA ortanca hata 0 (iki sınıflı lösemi)	Teknik rapor 576 okundu, JASA sürümü değil
[12]	2002	SRBCT ve lösemi	Küçültülmüş merkez yumuşak eşikleme	En yakın küçültülmüş merkezler (PAM)	38 örnekte 10 kat CV ve sabit 34	CV 1/38, test 2/34, 21 gen	En yakın küçültülmüş merkezler
[19]	2002	Kolon ve Golub	CV içinde ve dışında gen seçimi	SVM-RFE; Fisher ve ileri seçim	Dış 10 kat CV; .632+ bootstrap	Seçim yanlılığı yaklaşık %5 (38/34), %2-3 (72 örnek)	Seçim yanlılığı; CV hatası sıfır değil
[15]	2005	Lösemi dahil 11 veri seti	Çeşitli gen seçim yöntemleri	Çok kategorili SVM; kNN/sinir ağları/topluluklar	İki çapraz doğrulama tasarımı	bildirilmedi	Çok kategorili SVM en iyi; GEMS sistemi
[16]	2005	Metodoloji (mikrodizi örneği dahil)	Elastic net cezası	Cezalı regresyon	bildirilmedi	10 kat CV 3/38, test 0/34, 45 gen	0-1 yanıtta kare kayıp
[13]	2006	Golub eğitim 38 x 3.051 + 8 diğer set	RF geriye gen eleme	Rastgele orman; SVM/kNN/DLDA/SC	.632+ bootstrap	SVM 0,014; RF seçimsiz 0,051, seçimle 0,075-0,087	Lösemide RF 2 gen seçiyor
[20]	2006	Yalnızca benzetim (40 örnek, 6.000 öznitelik)	CV içinde ayar	İç içe CV	İç içe ve iç içe olmayan CV	İç içe tahminler gerçek hataya yakın	Neredeyse yansız, hafif kötümser
[6]	2007	121 çocukluk çağı lösemisi (GSE7186)	bildirilmedi	k en yakın komşu öngörücüleri	Bağımsız veri setiyle doğrulama	T-ALL MRD durumu %100 doğrulukla sınıflandı	Dış doğrulama kaynağı (pediatrik)
[24]	2007	İki örnek veri seti	Deneysel Bayes konum/ölçek düzeltmesi	ComBat	uygulanamaz	bildirilmedi	ComBat adı makalede geçmiyor
[5]	2008	MILE ön aşaması (çok laboratuvarlı)	Laboratuvarlar arası standart protokoller	Laboratuvarlar arası tekrarlanabilirlik çalışması	Laboratuvarlar arası karşılaştırma	bildirilmedi	GEO'da GSE13159 ile bağlantılı
[2]	2010	MILE aşama I/II (GSE13159 = aşama I)	Tüm genom HG-U133 Plus 2.0 profili	Tüm çiftler doğrusal SVM	Aşama I CV; aşama II ileriye dönük, özel çip	Aşama I 3x30 kat CV %92,2; aşama II %88,1	Dış doğrulama kaynağı; 11 laboratuvar
[21]	2010	13 kıyas seti ve bir sentetik set	Hiperparametre seçimi	KRR, KLR, GPC	Model seçimi aşırı uyum analizi	bildirilmedi	Seçim varyansı önemli; DOI yok
[23]	2010	Derleme ve dokuz veri setinin yeniden analizi	Batch etkisi tanılaması	Derleme	uygulanamaz	bildirilmedi	Kohortlar arası batch işlemeyi gerekçelendirir
[7]	2019	CuMiDa (78 derlenmiş GEO seti)	Arka plan düzeltmesi + normalizasyon + kalite kontrol	Kıyas ML taban modelleri	bildirilmedi	bildirilmedi	Derlenmiş mikrodizi kıyas deposu
[25]	2020	105 çalışmadan 12.029 örnek	Yüksek boyutlu tüm genom girdi	AML tahmini için ML	100 rastgele 80/20 bölme; çalışma-ayrık; platformlar arası	bildirilmedi	ALL dahil diğer tüm örneklere karşı AML
[26]	2021	>16.400 kan transkriptomu (lösemi dahil)	bildirilmedi	Swarm Learning (merkeziyetsiz ML)	Birleşik verinin benzetimli siloları; genel test düğümü	bildirilmedi	Merkezî model AML'de biraz daha iyi
[32]	2021	11 veri seti, n 20.640 ile 1,2M	bildirilmedi	FT-Transformer / ResNet ve GBDT	Kıyas protokolü	bildirilmedi	Çoğunda en iyi derin model; bazılarında GBDT kazanıyor
[31]	2022	45 veri seti, n>=3.000, d<500	bildirilmedi	Ağaç modelleri ve derin öğrenme	Kıyas protokolü	bildirilmedi	Rejim p»n mikrodizileri kapsamıyor
[17]	2022	132 incelenen çalışma	Öznitelik seçim yöntemleri	Sistematik derleme	uygulanamaz	bildirilmedi	En sık araştırma yönü (%34,9)
[27]	2022	Golub lösemi (72 x 7129) + 3 diğer	GNN tabanlı öznitelik sıralaması birleştirme	SVM sınıflandırıcı	10 kat CV	Lösemi doğruluğu 2 genle 0,971	Seçim 10 kat CV'den önce anlatılıyor
[28]	2022	Golub lösemi (72 x 7129) + DLBCL + prostat	Yumuşak topluluk sarmalayıcı gen seçimi (kNN)	Yığılmış derin sinir ağı	k kat CV (K=5-20)	Lösemi ortalama doğruluğu %99,6	Gen seçimi ile CV sırası belirsiz
[29]	2022	Golub lösemi (72 x 7129; UCI)	PSO 7129 genden 2323'ünü seçti	HORD ile optimize CNN	Rastgele 70/30 ve 80/20 bölmeler	Lösemi doğruluğu %99,9 (karşılaştırma tablosu)	CV yok; CML, CLL, sağlıklı sınıfları bildiriliyor, Golub'da yok
[18]	2023	Mikrodizi ve RNA-seq (derleme)	Öznitelik mühendisliği + ön işleme	ML/DL sınıflandırıcı derlemesi	uygulanamaz	bildirilmedi	MLP, CNN, RNN, GNN, transformer kapsanıyor
[30]	2024	Golub ALL/AML + CuMiDa lösemi	RF öznitelik önemi (FI >= 0,04)	Süper öğrenici (RF üst öğrenici)	%20 testle tabakalı 10 kat CV	AML-ALL doğruluğu 0,98 (Tablo 2)	FI sıralaması CV'den önce yapılmış görünüyor
[33]	2025	10.000 örnek, 500 öznitelik, 10 sınıfa kadar	bildirilmedi	TabPFN temel modeli	Kıyas karşılaştırmaları	bildirilmedi	n yaklaşık 72 sınanmamış

Kaynak	Yıl	Veri seti	Ön işleme/öznitelik seçimi	Yöntem	Doğrulama	En iyi sonuç	Not
[34]	2025	Gen düzeyi ve scRNA-seq görevleri	NCBI özetleri, text-embedding-ada-002	GenePT gömme modeli	Alt görev kıyasları	bildirilmedi	Ön baskı okundu, dergi sürümü değil

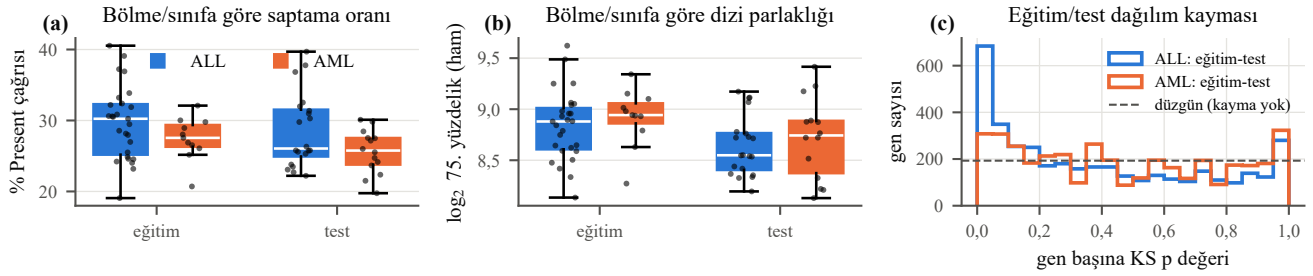
Ek B
Planlanan işlem hattı



Şekil 4. Planlanan sızıntısız işlem hattı. Durumsuz adımlar (kırpma, $\log_2$) bölmeden önce gelebilir; veriden öğrenen her adım (kesikli kutu), her iç ve dış eğitim katında yeniden öğrenilen bir `sklearn Pipeline` aşamasıdır.

Arama uzayları. EN-LR: $C \in [10^{-3}, 10^{2}]$ (log), ℓ_1 oranı $\in \{0{,}1;\ 0{,}5;\ 0{,}9;\ 1\}$. SVM: $C \in [10^{-3}, 10^{3}]$ (log), $\gamma \in [10^{-5}, 10^{-1}]$. RF: ağaç sayısı $\in \{300, 1000\}$, maks. öznitelik $\in \{\sqrt{p};\ 0{,}1p;\ 0{,}3p\}$, min. yaprak $\in \{1, 2, 4\}$. Hepsinde $k \in \{10, \ldots, 500\}$. Izgara arama (EN-LR, SVM), rastgele arama (RF) ve Optuna TPE (sinir ağları) maliyet ve iç CV skoruyla karşılaştırılacaktır.

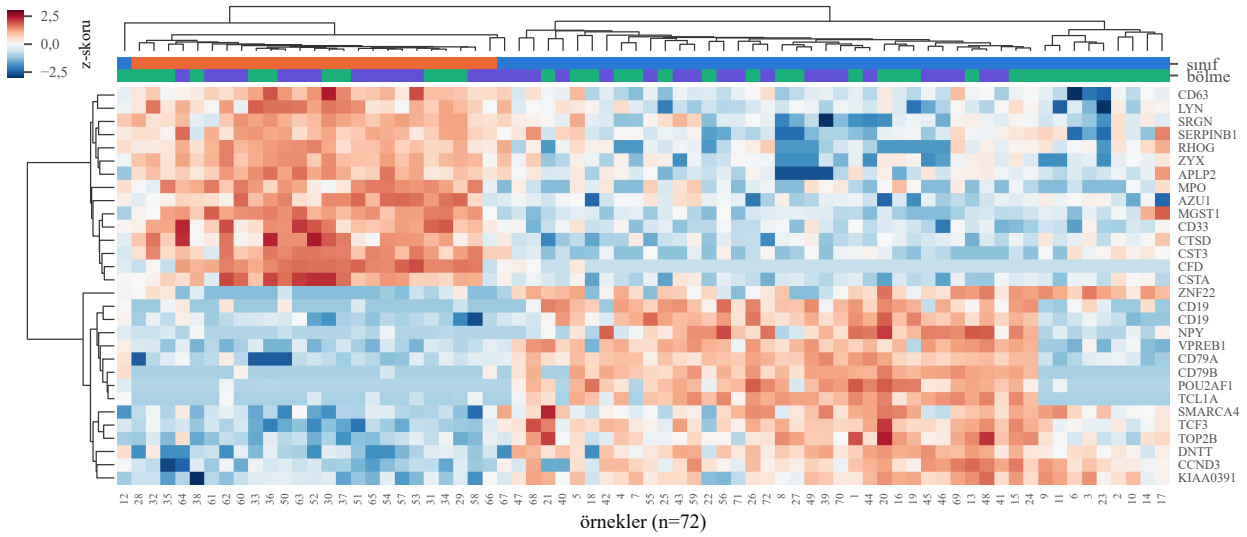
Ek C
Ek EDA şekilleri



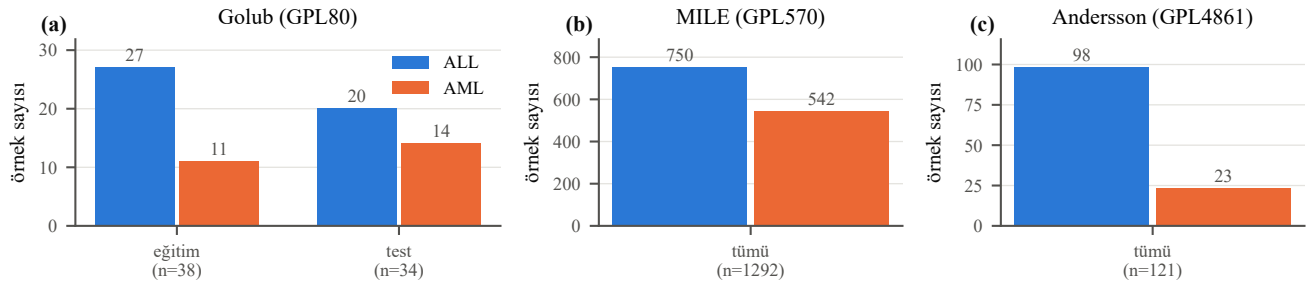
Şekil 5. Golub eğitim ve bağımsız set. (a) Present çağrı oranı ve (b) bölme ve sınıfa göre dizi parlaklığı. (c) Her sınıf içinde eğitim ve testi karşılaştıran gen bazlı KS p değerleri; ALL'de 0 yakınındaki fazlalık dağılım kaymasına işaret eder.

Tablo V
Her kohortta Welch p değerine göre ilk 12 gen (Δ: kohortun log ölçeğinde AML−ALL ortalama farkı; $t > 0$: AML'de yüksek).

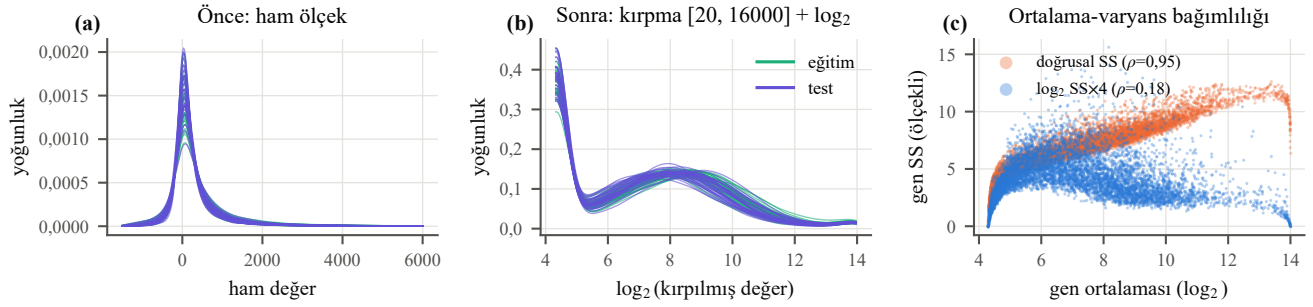
	Golub			MILE			Andersson		
#	gen	Δ	t	gen	Δ	t	gen	Δ	t
1	MGST1	+4,10	+13,5	PNKD	+0,25	+56,8	PILRB	−2,95	−16,0
2	CST3	+5,82	+12,4	LEF1-AS1	−0,35	−59,5	INOC1	−1,61	−15,0
3	TCF3	−2,07	−11,8	LEF1	−0,31	−52,5	NPY	−5,62	−15,1
4	ZYX	+3,83	+11,0	CFD	+0,43	+49,8	–	–	–
5	CD33	+2,26	+11,3	APLP2	+0,21	+49,3	NPR1	−3,31	−14,4
6	APLP2	+2,77	+9,6	LOC101928615	+0,22	+48,8	PCBD1	+2,98	+15,9
7	CD79B	−4,45	−9,2	MGST1	+0,38	+53,2	C17orf58	+2,11	+16,7
8	POU2AF1	−3,09	−9,6	MGST1	+0,41	+50,7	SPG20	+3,07	+13,9
9	DNTT	−4,44	−9,4	LEF1	−0,37	−55,1	LOC201229	−3,50	−14,7
10	CCND3	−2,06	−9,2	CTSA	+0,20	+48,2	CTSC	+2,38	+14,8
11	VPREB1	−4,24	−8,6	FUCA2	+0,24	+47,9	PCBD1	+2,99	+14,6
12	RHOG	+3,17	+8,6	LEF1-AS1	−0,25	−47,3	CD33	+3,87	+17,7



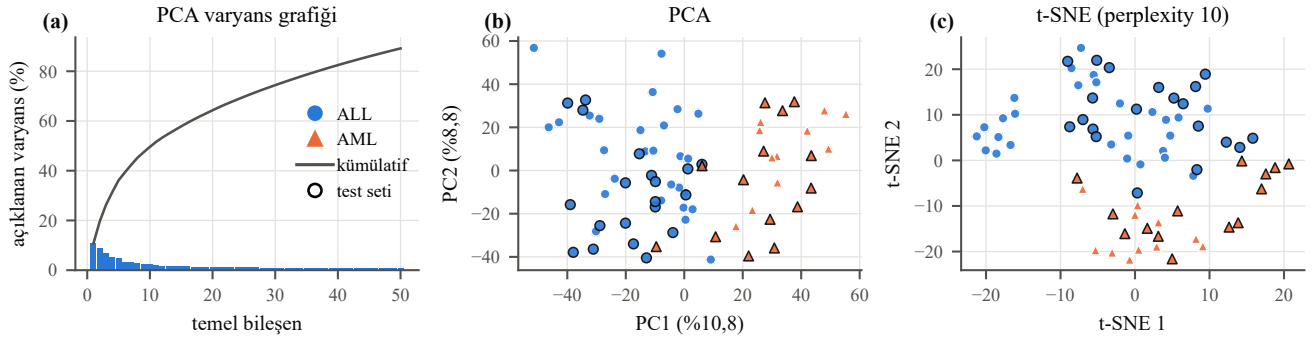
Şekil 6. Golub: AML'de en yüksek 15 ve ALL'de en yüksek 15 genin (Welch t) z-skorlu ifadesi; ortalama bağlantı, 1−Pearson uzaklığı. Sütun çubukları: sınıf (mavi ALL, turuncu AML) ve bölme (yeşil eğitim, mor test). Tabana kırpılmış değerler tekdüze açık mavi bloklar olarak görünür.



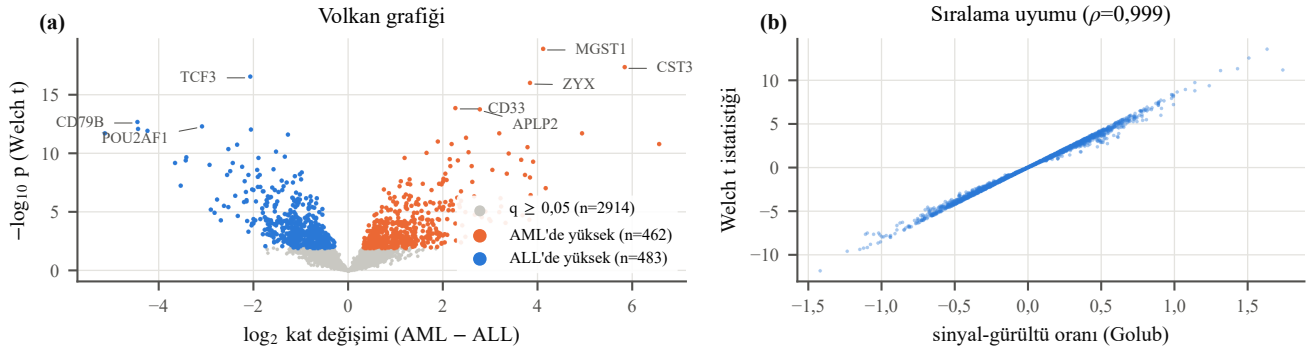
Şekil 7. Sınıf dağılımı. (a) Golub referans bölmesi; (b) 14 ALL/AML alt sınıfının iki etikete eşlenmesinden sonra MILE; (c) normal kontroller çıkarıldıktan sonra Andersson. Tüm setler ALL yönünde dengesizdir.



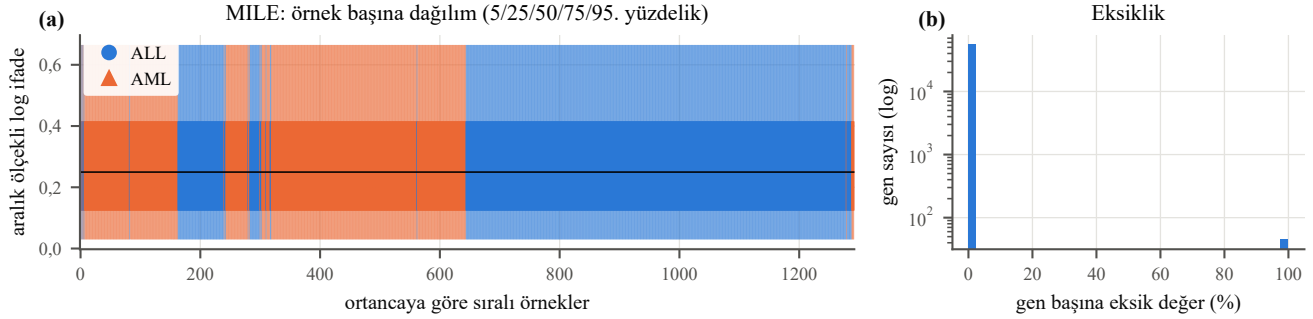
Şekil 8. Dizi başına Golub yoğunlukları: (a) kırpma ve $\log_2$ öncesi, (b) sonrası (renk: referans bölme). (c) Gen standart sapması ve ortalaması: doğrusal ölçekte SS ortalamayla büyür ($\rho = 0{,}95$), $\log_2$ sonrası bağımlılık büyük ölçüde kaybolur ($\rho = 0{,}18$).



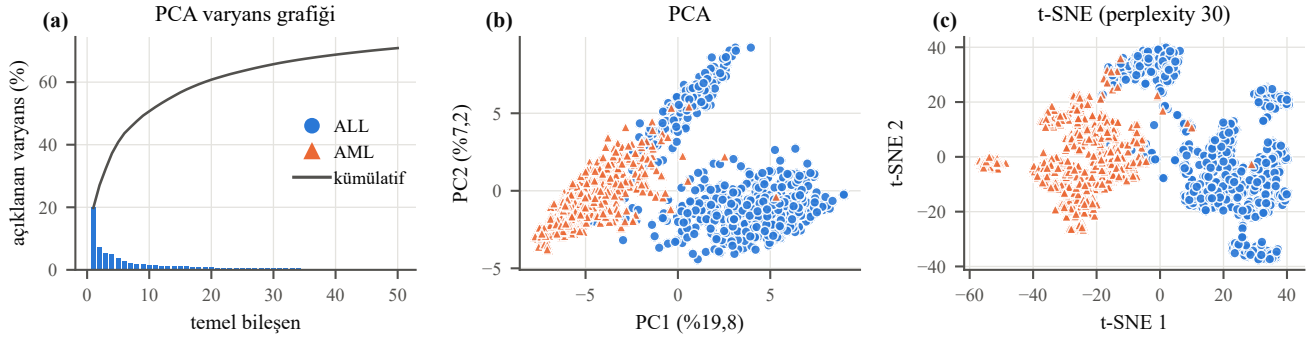
Şekil 9. Golub: PCA varyans grafiği (çubuk: bileşen başına, çizgi: kümülatif), PCA ve t-SNE. PC1 %10,8, on PC %49,6 açıklar; %80 için 37 PC gerekir. Varyans çok sayıda yöne yayılmıştır, yine de PC1 tek başına sınıfları ayırır.



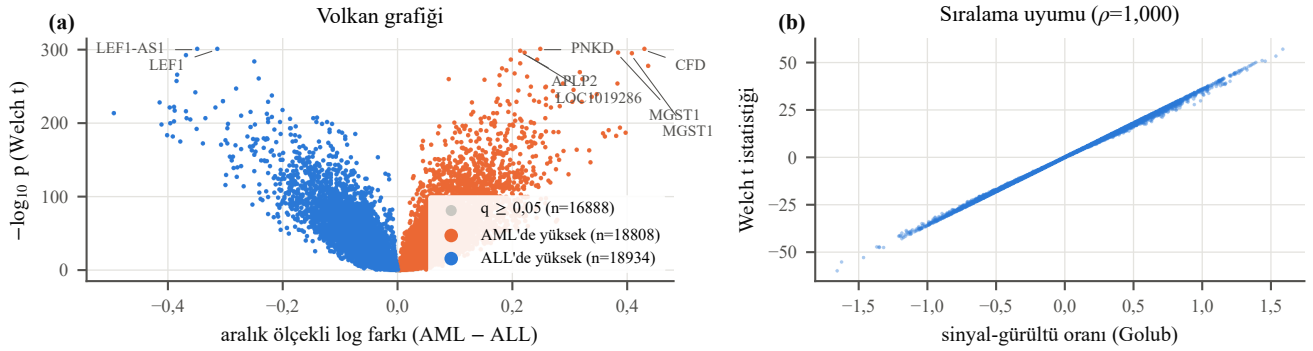
Şekil 10. Golub: (a) Welch testlerinin volkan grafiği (renk: BH $q < 0{,}05$): 462 gen AML'de, 483 gen ALL'de yüksektir; yani farklar tek yönlü değildir. (b) Golub'un sinyal-gürültü oranı ile Welch t genleri neredeyse aynı sıralar ($\rho = 0{,}999$); tek değişkenli filtrede aralarındaki seçim önemsizdir.



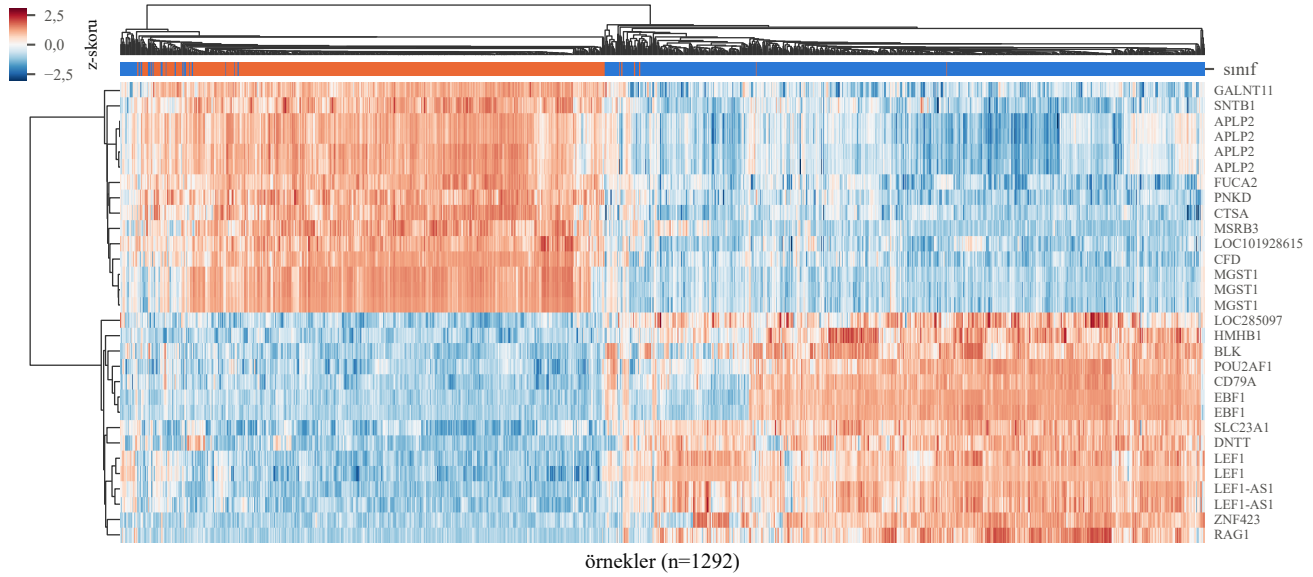
Şekil 11. MILE: (a) aralık ölçekli log değerlerinin dizi başına kantilleri (ortancaya göre sıralı). Kantil normalizasyonundan beklendiği gibi tüm dizilerin kantilleri aynıdır, dizi düzeyinde aykırı değer yoktur. (b) Prob seti başına eksik değer: 45 prob seti tüm dizilerde boştur (çıkarıldı); diğerleri tamdır.



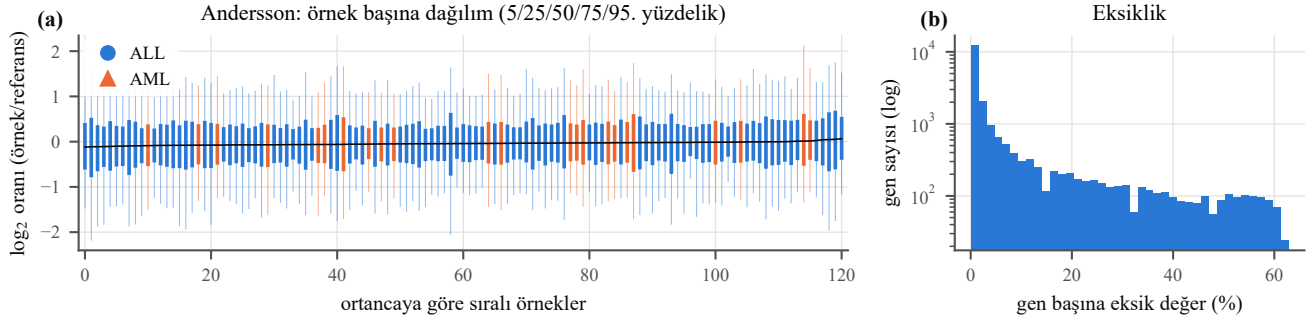
Şekil 12. MILE: PCA varyans grafiği, PCA ve t-SNE (en değişken 5.000 prob). PC1 %19,8 açıklar ve ALL'yi AML'den ayırır (AUC 0,987); t-SNE'de ALL örnekleri, MILE'daki çok sayıda ALL alt tipiyle uyumlu olarak birkaç alt küme oluşturur.



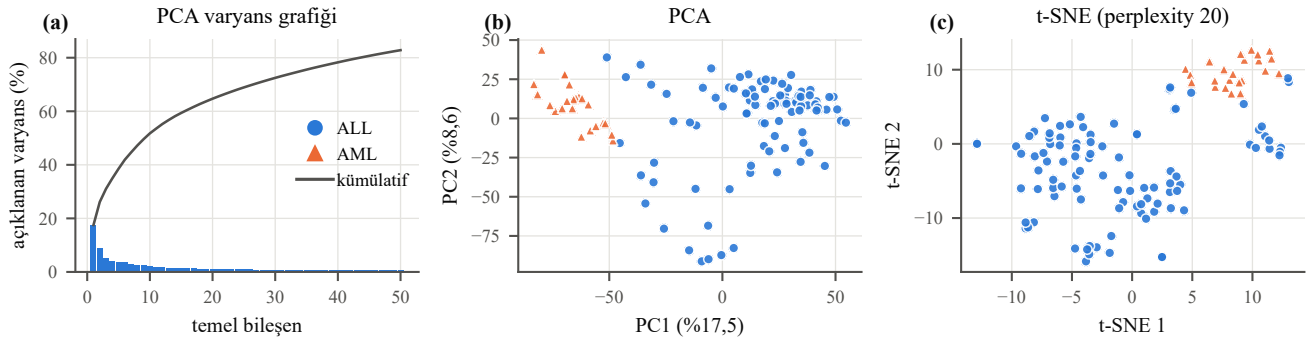
Şekil 13. MILE: (a) volkan grafiği; x ekseni aralık ölçekli log değerlerinin farkıdır, $p < 10^{-300}$ değerleri 300'de çizilmiştir. n = 1.292 ile prob setlerinin %69,1'i $q < 0{,}05$ düzeyine ulaşır; bu nedenle gen seçiminde p değil etki büyüklüğü yol göstermelidir. (b) SNR–t uyumu.



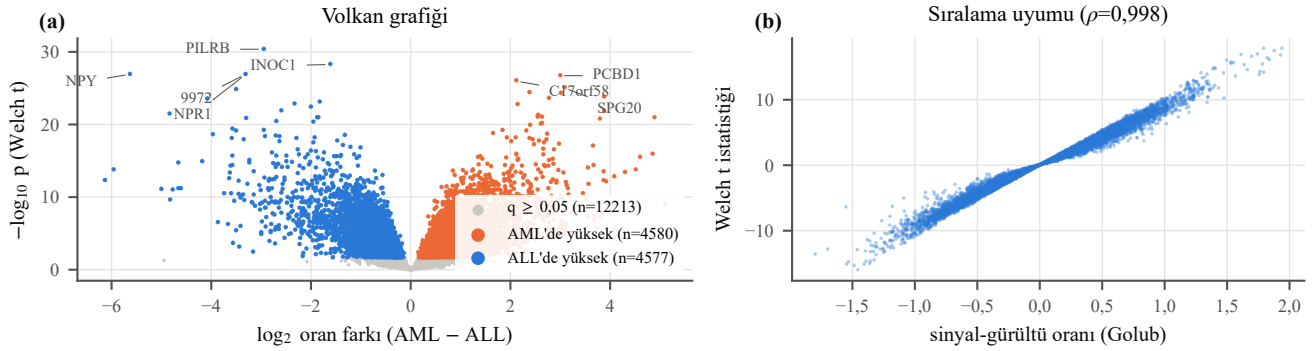
Şekil 14. MILE: ilk 30 genin kümelenmiş ısı haritası. En üst düzeydeki iki küme ALL/AML ile örtüşür (ARI 0,86); ALL içinde bir alt küme B hücre genlerinden (EBF1, CD79A, BLK, POU2AF1) yoksundur, bu T-ALL ile tutarlıdır.



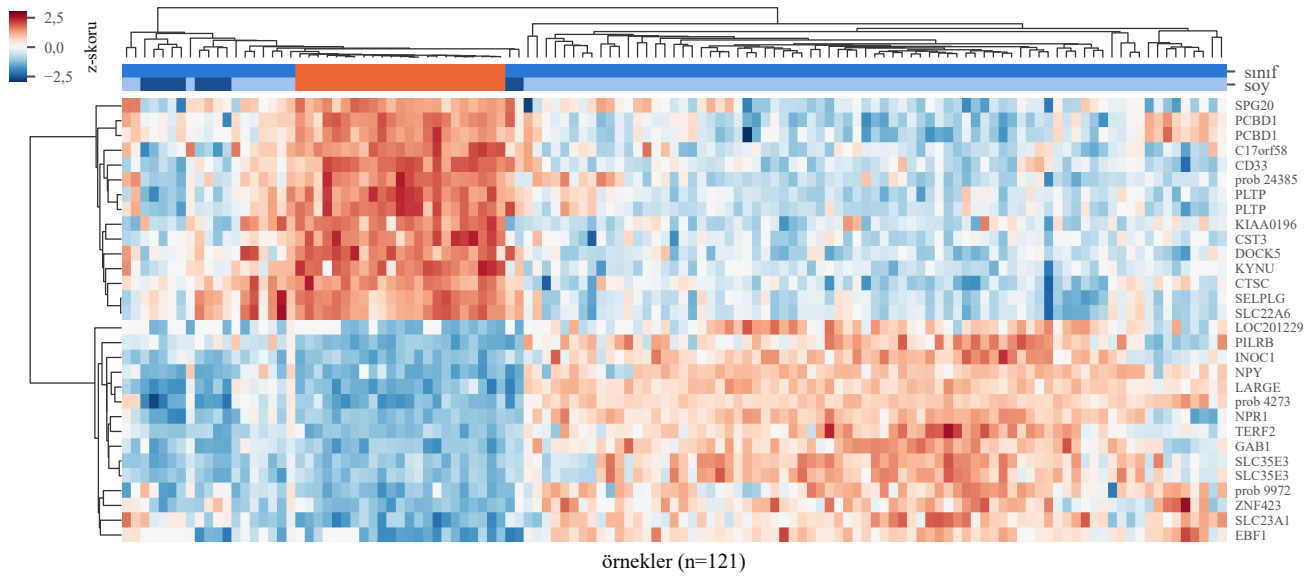
Şekil 15. Andersson: (a) dizi başına $\log_2$ oran dağılımları, lowess normalizasyonu ve merkezlemeden beklendiği gibi 0 yakınında ve benzer yayılımdadır; (b) raportör başına eksik değer: 12.084 raportörde boşluk vardır, 2.841 raportörde %20'den fazlası eksiktir; bu nedenle (kat içi) imputasyon gereklidir.



Şekil 16. Andersson: PCA varyans grafiği, PCA ve t-SNE (yalnızca görselleştirme için ortanca imputasyonu). PC1 %17,5 açıklar ve AML ile ALL'yi neredeyse kusursuz sıralar (AUC 0,999); t-SNE ayrı bir AML grubu ve birkaç ALL alt grubu gösterir.



Şekil 17. Andersson: (a) volkan grafiği (x: $\log_2$ oranlarının farkı); raportörlerin %42,8'si $q < 0{,}05$ düzeyine ulaşır ve AML'de yüksek (4.580) ile ALL'de yüksek (4.577) olarak eşit bölünür. (b) SNR–t uyumu.



Şekil 18. Andersson: ilk 30 genin kümelenmiş ısı haritası. Soy çubuğu: açık mavi B soylu ALL, koyu mavi T hücreli ALL, turuncu AML. T-ALL örnekleri AML'nin yanında kümelenir.