ALL ve AML Lösemi Alt Tip Sınıflandırmasında Sızıntısız Değerlendirme ve Platformlar Arası Aktarım

Ara Rapor: Literatür Taraması, Veri Setleri ve Keşifsel Veri Analizi

Enes AY
Öğrenci No. 503020260092
Yapay Zeka Programı, Fen Bilimleri Enstitüsü
Eskişehir Osmangazi Üniversitesi, Eskişehir, Türkiye
enes.ay.910@gmail.com

***Özet*—Akut lenfoblastik (ALL) ve akut miyeloid lösemi (AML) farklı tedaviler gerektirir; Golub vd. mikrodizi veri seti (72 hasta, 7.129 prob) bu iki sınıfı gen ifadesinden ayırmanın klasik kıyas setidir. Veri çok küçük ve çok yüksek boyutlu olduğundan ($p \gg n$), yayımlanmış ve %100'e yakın bazı doğruluklar bilgi sızdırıyor görünen doğrulama tasarımlarına dayanır. Bu ara rapor, makine öğrenmesi (ML) yöntemlerinin sızıntısız karşılaştırmasının temelini atar: (i) belgelenmiş bir arama protokolüyle 52 kaynak incelenmiş, (ii) aynı klinik soruyu taşıyan iki bağımsız açık kohort seçilmiş—çok merkezli MILE çalışması (GSE13159, 1.292 ALL/AML örneği, Affymetrix HG-U133 Plus 2.0) ve Andersson vd. pediatrik kohortu (GSE7186, 121 örnek, iki renkli cDNA dizileri)—ve (iii) tümüyle betiklenmiş bir keşifsel analiz yürütülmüştür. Golub verisinde eksik değer yoktur, ancak yoğunlukların %28,7'si negatiftir; bu durum kırpma ve $\log_2$ dönüşümünü gerekçelendirir. Dönüşümden sonra PC1 tek başına sınıfları AUC 0,984 ile ayırır. Eğitim ve bağımsız set arasında ölçülebilir bir kayma vardır. Gen bazlı t istatistikleri kohortlar arasında koreledir (Spearman $\rho = 0{,}56$ Golub–MILE, $\rho = 0{,}44$ Golub–Andersson); her kohort standartlaştırılana kadar birleşik varyansa sınıf değil, veri seti kimliği hâkimdir. Sabit ayarlı bir fizibilite pilotunda, gen seçimini çapraz doğrulama dışına almak rastgele etiketlerde bile dengeli doğruluğu 0,50 düzeyinden 0,91 düzeyine çıkarmış; sabit kohortlar arası aktarımda altı yönün 4'ünde AUC 0,965–0,992 iken dengeli doğruluk 0,50 olmuştur. Bu bulgular, kilitli dış test setlerini de içeren final makalesinin tasarımını belirler.**

***Anahtar Kelimeler*—lösemi, gen ifadesi, mikrodizi, keşifsel veri analizi, batch etkisi, iç içe çapraz doğrulama, küçük örneklemle öğrenme**

I. Giriş

Klinik problem. ALL lenfoid, AML miyeloid öncül hücrelerden kaynaklanır. Belirtiler ve kemik iliğindeki blastlar benzer olsa da indüksiyon kemoterapisi, risk sınıflaması ve nakil kararları önemli ölçüde farklıdır; bu yüzden yanlış soy ataması tedaviyi doğrudan etkiler. Rutin uygulamada ayrım morfoloji, sitokimya, immünfenotipleme ve sitogenetiğe dayanır; gen ifadesi profili, bu etiketleri tek ve nesnel bir testle yeniden üretebilen ve alt sınıfları ortaya çıkarabilen bir yöntem olarak önerilmiştir [1], [2]. Bu çalışmada görev *ALL ve AML alt tip sınıflandırması* olarak adlandırılır: iki sınıf da lösemidir, dolayısıyla ders modülünde ALL için kullanılan "non-cancer" etiketi biyolojik olarak yanlıştır ve burada kullanılmaz.

Mikrodizi teknolojisi. DNA mikrodizisi, işaretli cDNA/cRNA'yı sabitlenmiş problara hibritleştirerek binlerce mRNA transkriptinin miktarını paralel olarak ölçer. Affymetrix oligonükleotit dizileri (Golub ve MILE) prob seti başına bir yoğunluk verir; eski MAS 4 "average difference" değeri (perfect-match eksi mismatch) negatif olabilir ve Present/Marginal/Absent (P/M/A) saptama çağrısıyla birlikte gelir. İki renkli noktalı cDNA dizileri (Andersson) örneği (Cy3) ortak bir referans RNA (Cy5) ile birlikte hibritleştirir ve log oran verir.

Araştırma soruları (AS). Proje, yanlışlanabilir dört soruyu sınar:

- **AS1** (yöntem karşılaştırması): 72 Golub örneğinin tamamında sızıntısız 5×5 iç içe tabakalı çapraz doğrulama (CV) altında cezalandırılmış lojistik regresyon, destek vektör makinesi (SVM) ve rastgele orman dengeli doğrulukta farklı mıdır? H_0: ortalama dengeli doğruluklar eşittir; düzeltilmiş yeniden örnekleme t testi [3] ve Holm düzeltmesiyle ikili olarak sınanır.
- **AS2** (protokol): Ders modülündeki tek 38/34 bölmesi, iç içe CV'nin %95 güven aralığı içinde bir tahmin mi verir? Gen seçimini CV dışına almak doğruluğu ne kadar şişirir?
- **AS3** (genellenebilirlik): ALL/AML sinyali kohortlar ve platformlar arasında ortak mıdır; yani gen bazlı test istatistiklerinin korelasyonu $\rho > 0$ ve ilk 100 gen örtüşmesi şanstan büyük müdür? Final raporunda: bir kohortta eğitilen model, kilitli dış setlerde hem sıralamayı (AUC) hem karar eşiğini (dengeli doğruluk $\geq 0{,}90$) koruyor mu?
- **AS4** (bonus): Derin model (MLP/otokodlayıcı) ve tablosal transformer (TabPFN), aynı protokolde en iyi klasik modeli geçer mi?

AS3, Bölüm IV'teki keşifsel analizle kısmen yanıtlanmıştır.

Video: https://youtu.be/WWjyMpgxolk. Kod: https://github.com/mrayenesay/leukemia-all-aml-ml. Bu rapordaki her sayı `scripts/run_eda.py` tarafından üretilir ve LaTeX makrosu olarak alınır; bkz. Bölüm VI.

Bu ara raporun katkıları. (1) 52 kaynağın belgelenmiş taraması (Bölüm II); (2) uyumlaştırılmış iki dış kohort, toplam üç veri seti (Bölüm III); (3) numaralı modelleme çıkarımları içeren betiklenmiş keşifsel veri analizi (EDA) (Bölüm IV); (4) makalenin ana iddialarını sınayan fizibilite pilotu ve önceden belirlenmiş plan (Bölüm V).

II. Literatür Taraması

Arama protokolü. Crossref (dergi makalelerine süzülmüş anahtar kelime araması), Europe PMC (tam metin) ve PubMed/NCBI E-utilities 3 Kasım 2026'da sorgulanmıştır. Keşif 2021–2026 ile sınırlandırılmış; klasik çalışmalar (1995–2020) tanımlayıcıyla eklenmiş ve aynı şekilde doğrulanmıştır. Sorgulardan bazıları: *"golub leukemia gene expression classification"*, *"machine learning cancer classification gene expression data review"* ve tam metin sorgusu *"7129" AND "72 samples" AND (leukemia OR leukaemia) AND classification*. *Dahil etme:* kullanılan veri setleri, ifade verisinde sınıflandırma veya öznitelik seçimi, doğrulama yanlılığı, batch etkileri ya da güncel tablosal öğrenme üzerine hakemli dergi veya konferans makaleleri. Golub sonucu olan makalelerde bildirilen örnek ve gen sayıları kaydedilmiştir. *Dışlama:* konferans özetleri, görüntü tabanlı lösemi çalışmaları, Golub etiketli sonucu doğrulanamayan makaleler ve dizinlenmeyen yayın organları. İlk taramada başlığına göre 152 kayıt elenmiş, 24 özet değerlendirilmiştir. 6 Kasım 2026'da sızıntı, dış doğrulama, platform aktarımı ve lösemi transkriptomu için Europe PMC ve Crossref'te yaklaşık 35 sorguyla hedefli ek tarama yapılmıştır. Sonuçta 46 çalışma ve 6 yöntem kaynağı dahil edilmiştir: 52 kaynağın 31'i 2021 ve sonrasına, 28'i 2022 ve sonrasına aittir; klasikler veri ve özgün yöntemlerle sınırlı tutulmuştur. DOI'ler Crossref ile doğrulanmış; 47 çalışmaya tam metin, 4'üne özet, 1'ine künye düzeyinde başvurulmuş ve aşağıdaki iddialar yapay zekâ desteğiyle bu metinlere göre denetlenmiştir (`reports/literature/`).

Veri setleri ve lösemi sınıflandırması. Golub vd. [1], 38 örnekte öğrenilip 34 bağımsız örneğe uygulanan 50 genli ağırlıklı oylama öngörücüsünü tanıtmıştır. MILE, protokolleri 11 laboratuvarda standartlaştırmış [4]; 18 sınıfta %92,2 çapraz doğrulanmış uyuma, bağımsız ileriye dönük kohortta %88,1'e ulaşmıştır [2]. Andersson vd. [5] ardışık 121 çocukluk çağı lösemisini k-NN ile sınıflandırmıştır. Güncel çalışmalar RNA-seq'e geçmiştir: AML, B-ALL ve T-ALL'yi ayıran bir sınıflandırıcı dış veride %97,5 duyarlılık ve %93,7 kesinlik [6], ALLCatchR dışarıda tutulan kohortlarda 21 B-ALL alt tipinde 0,957 doğruluk [7], sıra dönüşümlü bir derin model AML içermeyen görülmemiş bir kohortta %99,38 soy doğruluğu bildirmiştir [8]. AML'de IDH tahmininde yüksek ayrıma rağmen yüksek olasılıklar fazla tahmin edilmiştir [9].

Sınıflandırıcılar ve gen seçimi. Golub verisinde SVM [10], SVM-RFE [11], diyagonal diskriminant analizi [12], küçültülmüş merkezler [13], elastic net [14] ve rastgele orman [15] denenmiş; basit yöntemler karmaşık olanlarla yarışmıştır [12]. Bir derleme 132 makalede hibrit seçimi en sık araştırma yönü bulmuş (%34,9) [16], bir başkası seçimi filtre, sarmalayıcı, gömülü ve hibrit olarak gruplamıştır [17].

Sızıntı ve doğrulama yanlılığı. Genleri CV'den önce tüm örneklerde seçmek iyimser hata üretir [18]; iç içe CV benzetimde neredeyse yansız, hafif kötümser tahminler vermiştir [19]. Bir tarama sızıntının 17 alanda en az 294 makaleyi etkilediğini ve tüm veride öznitelik seçiminin bir sızıntı türü olduğunu bildirir [20]; biyolojik verideki bağımlılıklar yanlılığı fark etmeyi zorlaştırır [21], [22]. On radyomik veri setinde CV öncesi seçim AUC'de 0,15'e kadar yanlılık üretmiş [23], bağlantısal modellerde dikkat sorunları tahmininde r değerini 0,01'den 0,48'e çıkarmıştır [24]. Doğrusal modelde CV, eldeki modelin değil başka eğitim kümeleriyle kurulan modellerin ortalama hatasını tahmin eder ve olağan aralıklar fazla dar olabilir [25]. [3] düzeltmesi rastgele alt örnekleme için türetilmiştir; çoklu veri setlerinde sıra testleri önerilir [26].

Dış doğrulama ve platform aktarımı. Klinik modellerde kalibrasyon, heterojenliğe ayrımdan daha açıktır [27]; dış doğrulamada tek ölçüt yetmez [28], [29] ve TRIPOD+AI eşiğin nasıl belirlendiğini raporlamayı ister [30]. Batch etkileri ifade verisine hâkim olabilir [31]; ComBat bunları düzeltmek için önerilmiştir [32], karışık platform eğitiminde ise z-skor en değişken yöntem olmuştur [33]. 12.029 transkriptomda AML diğer tüm örneklerden ayrılmış, U133A'dan RNA-seq'e ham aktarım başarısız kalmış, gen bazlı sıra dönüşümü bunu çözmüştür [34]. Sepsis sınıflandırıcılarında mikrodiziden RNA-seq'e aktarımda AUROC 0,999 iken 0,5 eşiğinde dengeli doğruluk 0,50 bulunmuş, örnek içi sıra dönüşümü eşiği kurtarmıştır [35]. Akciğerde harmonizasyonsuz aktarımda AUROC da çökmüş (0,58) [36], eşleşmiş pankreas örneklerinde olasılıklar kaymış [37], meme kanserinde kalibrasyon eğimi 0,96'dan 1,57–2,74'e çıkmış [38], sepsiste karşılaştırma grubu değişince dengeli doğruluk 0,527'ye inmiştir [39].

Golub ve tablosal öğrenmede güncel sonuçlar. Golub etiketli güncel sonuçlar çok yüksektir [40]–[43]. Ancak protokol anlatımlarına göre [40], [43] genleri CV'den önce seçmekte, [42] aynı veride seçim ve ayar yapan rastgele ayırmalar kullanmakta (ve Golub'da bulunmayan CML, CLL ve sağlıklı sınıflarını listelemekte), [41] seçimin her katta yinelenip yinelenmediğini belirtmemektedir. Swarm learning benzetimli çok merkezli bölümlerde tek düğümlü modelleri geçmiştir [44]. Tablosal kıyaslarda ağaçlar orta boyutlu, düşük boyutlu veride derin ağları geçmiş [45], FT-Transformer en iyi derin model olmuş ama her zaman artırılmış ağaçları geçememiş [46], TabPFN 10.000 örnek ve 500 özniteliğe kadar ayarlı ağaçları geçmiş [47], GenePT ise gen metin özetlerini dil modeliyle gömmüştür [48].

Boşluk. Tablo I'deki dört güncel çalışmada doğruluklar %97 ile neredeyse %100 arasındadır; önceki çalışmalar daha düşük değerler bildirir (ör. 34 testte 2 hata [13], seçim yanlılığı düzeltildikten sonra yaklaşık %5 hata [18]). Sayıları karşılaştırmak güçtür: protokoller farklıdır, bazı çalışmalar genleri tüm veride seçer [11], [40], [43] ve dört güncel çalışmanın hiçbiri güven aralığı bildirmez. Okuduğumuz Golub tabanlı sınıflandırma makalelerinde hiçbir model veya gen listesi bağımsız bir lösemi kohortuna ya da platforma aktarılmaz. AUC ile karar eşiğinin ayrışması sepsiste gösterilmiştir [35], ama taramamızda ALL/AML için ikisini birlikte raporlayan

Tablo I
Literatür özeti (alt küme; 46 çalışmalık tam tablo Ek A'dadır). Sızıntı riski, bildirilen protokol sırasına ilişkin bizim okumamızdır.

Kaynak (yıl)	Veri seti	Ön işleme / öznitelik seçimi	Yöntem	Doğrulama	En iyi sonuç	Sızıntı riski
[1] (1999)	Golub 38/34	sınıf korelasyonuyla (SNR) gen seçimi	50 genli ağırlıklı oylama	LOOCV + sabit bağımsız test	test: 29/34 tahmin, tümü doğru	düşük (seçim eğitimde)
[12] (2002)	Golub, NCI60, lenfoma	kırpma, log, tek değişkenli filtre	DLDA, k-NN, ağaçlar	150 tekrarlı 2:1 bölme	DLDA ortanca hata 0	düşük
[18] (2002)	kolon, Golub	CV içinde ve dışında seçim	SVM-RFE; Fisher + ileri seçim	dış 10 kat, .632+	seçim yanlılığı yaklaşık %5	– (sızıntıyı inceler)
[40] (2022)	Golub + 3	GNN tabanlı sıralama	SVM	10 kat CV	doğruluk 0,971 (2 gen)	muhtemelen yüksek (seçim CV'den önce)
[41] (2022)	Golub + 2	topluluk sarmalayıcı (k-NN)	yığılmış DNN	k kat CV	doğruluk %99,6	belirsiz (seçim sırası)
[42] (2022)	"Golub" (UCI)†	PSO (2.323 gen)	optimize CNN	rastgele 70/30, 80/20	doğruluk %99,9	yüksek (CV yok)
[43] (2024)	Golub + CuMiDa	RF önemi $\geq 0{,}04$	süper öğrenici	10 kat CV + %20 test	doğruluk 0,98	yüksek (sıralama CV'den önce)

†Makale, Golub verisinde bulunmayan CML, CLL ve sağlıklı sınıflarını da listelemektedir.

bir çalışma bulunmamıştır (bu "ilk" anlamına gelmez). Proje bu boşlukları tek bir sızıntısız protokol, aralık tahminleri ve dış kohortlarla ele alır.

III. Veri Setleri

Tablo II üç veri setini özetler; sınıf dağılımları Ek C'de (Şekil 7) verilmiştir.

Golub (ana veri seti). Golub vd. [1] (DOI 10.1126/science.286.5439.531); özgün Broad Institute dosyalarının Kaggle kopyasından alınmıştır ("Gene expression data set (Golub et al.)", lisans CC0). Platform: Affymetrix Hu6800/HuGeneFL (GEO GPL80), 7.129 prob seti (58 AFFX kontrolü; 6.434 tanesi bir gen sembolüne eşlenir), P/M/A çağrılı MAS 4 average difference. Hastaların çoğu çocuktur (47 ALL'nin tamamı ve 25 AML'nin 10'u) ve 72 örneğin 62'si kemik iliğidir; bağımsız set daha heterojendir (periferik kan, çocukluk çağı AML'si, farklı referans laboratuvarları) [1]. Referans bölme 38 eğitim (27 ALL / 11 AML) ve 34 bağımsız örnek (20 / 14) içerir; genel oran %65/%35'tir.

MILE (benzer veri seti 1). Microarray Innovations in LEukemia, aşama 1, GEO GSE13159 (DOI 10.1200/JCO.2009.23.4732, 10.1111/j.1365-2141.2008.07261.x) [2], [4]. 18 sınıfta 2.096 tanı örneği içerir; örnekler 11 laboratuvarda standart protokollerle Affymetrix HG-U133 Plus 2.0 (GPL570, 54.675 prob seti) üzerinde profillenmiş ve kantil normalize sinyalden türetilmiştir [2]. 14 ALL ve AML sınıfı ikili etikete eşlenmiş; CLL, CML, MDS ve lösemik olmayan örnekler dışlanmıştır. Geriye 1.292 örnek kalır (750 ALL / 542 AML; 1.211 kemik iliği, 81 periferik kan). *Seçilme nedeni:* aynı klinik soru, çok daha büyük çok merkezli kohort, Affymetrix teknolojisi ve ön eğitime (bonus B1) yetecek büyüklük.

Andersson (benzer veri seti 2, bonus B4). İsveç'in Lund kentinden ardışık 121 çocukluk çağı akut lösemisi, GEO GSE7186 (DOI 10.1038/sj.leu.2404688) [5]: 87 B soylu ALL, 11 T hücreli ALL ve 23 AML (6 normal kemik iliği kontrolü dışlanmıştır). GEO'ya göre 108 örnek kemik iliği, 13 örnek periferik kandır. Platform: Swegene Human 27K RAP iki renkli noktalı cDNA dizisi (GPL4861, 21.370 raportör). Değerler lowess normalize $\log_2$(örnek/Universal Human Reference) oranlarıdır; hastane bazında merkezlenmiş ve %40 varlık ölçütüyle önceden süzülmüştür, bu nedenle değerlerin %7,19'u eksiktir. *Seçilme nedeni:* aynı soru ama farklı teknoloji, tümüyle pediatrik seri ve gerçek eksik değerler.

Tablo II
Üç veri setinin karşılaştırması.

	Golub	MILE	Andersson
Kaynak	[1], Kaggle (CC0)	GSE13159	GSE7186
Platform	Hu6800 (GPL80)	U133 Plus 2.0 (GPL570)	27K cDNA (GPL4861)
Teknoloji	tek renk oligo	tek renk oligo	iki renk cDNA
Ölçü	MAS4 avg. diff.	aralık ölçekli log	$\log_2$ oran
Popülasyon	çoğunlukla pediatrik	çok merkezli	pediatrik
Örnek n	72	1.292	121
Öznitelik p	7.129	54.675	21.370
ALL / AML	47 / 25	750 / 542	98 / 23
Bölme	38 eğitim / 34 test	yok	yok
Eksik değer	0	%0,08	%7,19
Gen (sembol)	5.268	20.848	9.677

Kilitli dış test setleri (final). Sonuçların yalnızca görülmüş veriye uymadığını göstermek için iki bağımsız set final değerlendirmesine kadar kapalı tutulmuştur: (i) MILE aşama 2 (GEO GSE13164, Roche AmpliChip Leukemia, GPL7473, 1.480 prob seti): bu serideki 1.152 örneğin 693'ü akut lösemidir (436 ALL / 257 AML; metaveriden sayılmış, ifade değerlerine bakılmamıştır) [2]; (ii) TARGET-ALL-P2 ve TARGET-AML (NCI GDC, açık erişimli STAR sayımları), mikrodiziden RNA-seq'e geçişi sınar. TARGET'ta sınıf ile proje karıştığından bu set yalnızca dışarıda eğitilmiş modelin testinde kullanılacaktır. Golub'un 34 bağımsız örneği EDA'da incelenmiş, ama hiçbir modele girmemiştir.

Lisanslar. NCBI, GEO verilerine kısıtlama koymaz, ancak veri sahiplerinin hakları olabilir; tüm setler atıfla akademik araştırmada kullanılmıştır.

Uyumlaştırma. Problar GEO platform açıklamalarıyla (GPL80/GPL570/GPL4861) HGNC sembollerine eşlenmiştir. Belirsiz problar ("`A///B`") çıkarılmış, gen başına birden çok prob en yüksek ortalama ifadeli proba indirgenmiştir. Sonuçta 5.268, 20.848 ve 9.677 gen elde edilir; 5.207 gen Golub ve MILE'da, 3.487 gen Golub ve Andersson'da, 3.469 gen üçünde ortaktır.

IV. Keşifsel Veri Analizi

Tüm analizler Python'da (pandas, SciPy, scikit-learn [49], seaborn) `scripts/run_eda.py` ile, tohum 42 kullanılarak yürütülmüştür. *Sızıntı notu:* bu bölümdeki denetimli gen sıralamaları yalnızca veriyi betimler. Modeller için öznitelik seçmekte asla yeniden kullanılmamalıdır; aksi hâlde [18] seçim yanlılığı yeniden üretilir.

A. Veri kalitesi

Golub. 513.288 değer arasında 0 eksik veya sonsuz değer vardır; bu nedenle modüldeki "INF'yi ortalamayla doldur" adımının özgün dosyalarda etkisi yoktur (yalnızca pozitif olmayan değerlerin log'u alındığında önem kazanır, kırpma bunu önler). Buna karşılık değerlerin %28,7'si negatif, %32,7'si 20'nin altında, %0,83'ü 16.000'in üstündedir (aralık -28.400 ile 71.369; Şekil 1a). Negatif average difference, mismatch sinyali perfect-match sinyalini aştığında, yani transkript yokken ortaya çıkar. Çağrılar bunu doğrular: ölçümlerin %70,2'si Absent, %28,2'si Present ve %1,6'sı Marginal'dır. Ortanca değer Absent için 33, Present için 662'dir (Şekil 1c) ve 1.971 prob hiç Present çağrısı almaz. Dizi başına Present oranı %19,1 ile %40,5 arasında değişir ve görünür bir sınıf örüntüsü yoktur (Şekil 1b). **Etiket eşleme:** hasta sütunları sayısal sırada *değildir* (eğitim sırası 1–27, 34–38, 28–33). Bu yüzden etiketler hasta numarasıyla birleştirilmiş; betik eğitim kimliklerinin tam 1–38, test kimliklerinin 39–72 ve sınıf sayılarının 27/11 ile 20/14 olduğunu doğrular.

MILE ve Andersson. GEO, MILE değerlerini normalize sinyal olarak tanımlasa da her dizi tam olarak 0,00–1,00 aralığını kaplar. Bir dizinin ArrayExpress örnek tablosuyla karşılaştırılması, değerlerin $\log_2$ sinyalin monoton (Spearman 1,000) ve neredeyse doğrusal bir fonksiyonu olduğunu gösterir (Pearson 0,998; doğrusal sinyalle 0,51): bunlar dizi başına aralık ölçekli log yoğunluklardır, bu nedenle ek log dönüşümü uygulanmaz. 45 prob seti tüm dizilerde boştur ve çıkarılmıştır (tüm değerlerin %0,08'i); sonsuz değer yoktur. Andersson'da değerlerin %7,19'u eksiktir: 12.084 raportörde en az bir boşluk, 2.841 raportörde %20'den fazla eksik vardır; bir dizide değerlerin %24,3'ü yoktur (Ek C, Şekil 15). Bu nedenle imputasyon gereklidir ve eğitim katlarının içinde öğrenilmelidir.

B. Dağılımlar ve dönüşüm

Değerler ders rehberinde verilen $[20, 16000]$ penceresine kırpılmış ve $\log_2$ dönüşümü uygulanmıştır (Dudoit vd. [12] 100 tabanı, aynı tavanı ve 10 tabanlı log kullanmıştır). Birleşik çarpıklık 7,08 değerinden 0,55 değerine düşer; gen ortalaması ile standart sapma arasındaki Spearman korelasyonu 0,95 değerinden 0,18 değerine iner (Ek C, Şekil 8). Dönüşüm, aksi hâlde birkaç yüksek yoğunluklu genin uzaklık tabanlı yöntemlere (SVM, k-NN, PCA) hâkim olmasına yol açacak ortalama–varyans bağımlılığının çoğunu giderir. Kırpmadan sonra değerlerin yaklaşık üçte biri tabanda ($\log_2 20$) toplanır; bu, yoğunlukta bir sivrilme olarak görünür. [12] filtresi (maks/min >5 ve maks$-$min >500) 7.129 probun 3.859'unu korur; 100 tabanıyla 3.571'ini korur ki bu, [12] çalışmasındaki gen sayısının tam olarak aynısıdır. MILE (aralık ölçekli log) ve Andersson ($\log_2$ oran, ortanca $-0,04$) zaten log ölçeğindedir.

C. Boyut indirgeme

Merkezlenmiş, filtrelenmiş $\log_2$ veri üzerindeki PCA (Ek C, Şekil 6) varyansın dağınık olduğunu gösterir: PC1 %10,8, ilk on PC %49,6 açıklar ve %80 için 37 PC gerekir. Yine de PC1 tek başına ALL ve AML'yi AUC 0,984 ile sıralar; yani sınıf farkı en büyük tekil varyasyon kaynağıdır. t-SNE (perplexity 10) [50] iki belirgin grup gösterir (siluet 0,40; 10 boyutlu PCA uzayında 0,17) ve bağımsız örnekler (siyah kenarlı) eğitim örnekleriyle karışır. MILE'da (en değişken 5.000 prob) en iyi tek PC AUC 0,987 verir. Andersson'da PC1 %17,5 açıklar ve AUC 0,999 verir.

D. Ayırt edici genler

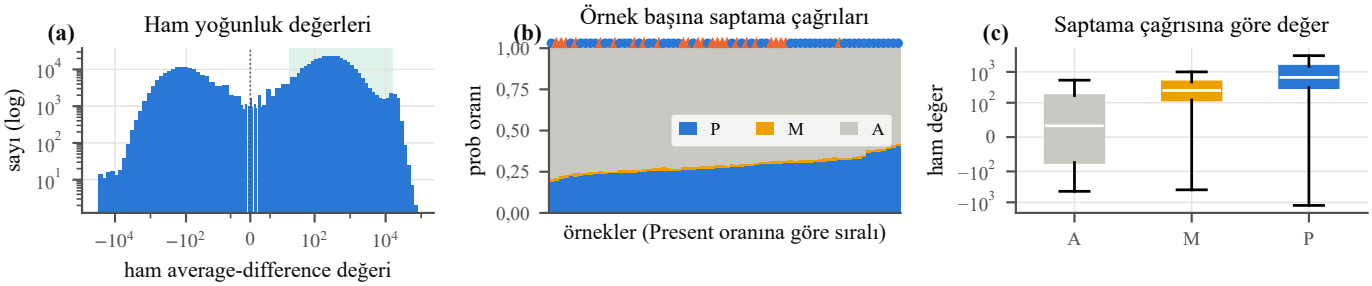
Her gen için Welch t testi, Mann–Whitney U testi (ikisi de Benjamini–Hochberg FDR [51] ile) ve Golub'un sinyal-gürültü oranı (SNR) hesaplanmıştır. Golub'da 3.859 genden 945'i $q < 0,05$ düzeyinde anlamlıdır ($q < 0,01$'de 567; Mann–Whitney ile 1.014); 462 gen AML'de, 483 gen ALL'de yüksektir. SNR ve t genleri neredeyse aynı sıralar ($\rho = 0,999$; Ek C). Üst sıradaki genler (Ek C, Tablo V) bilinen biyolojiyle uyumludur: miyeloid genler (CST3, CD33, MPO, ZYX, MGST1) AML'de, lenfoid/B hücre genleri (TCF3, CD79B, CD19, DNTT, VPREB1, CCND3) ALL'de yüksektir. CST3, ZYX ve CD33, [1] çalışmasının 50 bilgilendirici geni arasında da yer alır. Örneklerin ilk 30 gen üzerinde hiyerarşik kümelenmesi (Ek C, Şekil 5) sınıfları geri kazanır (düzeltilmiş Rand indeksi ARI = 0,89). Andersson'da ARI yalnızca 0,41'dir: T-ALL örnekleri AML'nin yanında kümelenir, çünkü ALL'de yüksek genlerin çoğunu süren B hücre programından yoksundurlar. 1.292 örnekle MILE prob setlerinin %69,1'i anlamlıdır, kümeleme yine sınıfları geri kazanır (ARI 0,86) ve sıralamanın başında LEF1 (lenfoid) ile MGST1, CFD, APLP2 (miyeloid) yer alır.

E. Eğitim ve bağımsız set (batch etkisi)

Ortalama Present oranı eğitim setinde %29,0, bağımsız sette %27,3'tür (Mann–Whitney $p = 0,071$). Dizi parlaklığının vekili olan 75. yüzdelik yoğunluk bağımsız sette daha düşüktür (ortanca 421; eğitimde 482, $p = 0,016$; Ek C, Şekil 4). Batch etkisini sınıf bileşiminden ayırmak için eğitim ve test her sınıfın *içinde*, gen bazlı Kolmogorov–Smirnov testleriyle karşılaştırılmıştır. Kayma yoksa genlerin %5'inde $p < 0,05$ beklenir. ALL için %17,7 (FDR sonrası 28 gen anlamlı), AML için %8,0 (0 gen) gözlenmiştir. Yani orta düzeyde, ALL'ye özgü bir kayma vardır. Bu, bağımsız örneklerin daha heterojen toplanmasıyla tutarlıdır ve tek bir 34 örneklik test skorunun CV tahminlerinden sapmasının nedenlerinden biri olabilir (**AS2**); yine de [12] bu bölmede belirgin bir doğruluk kaybı görmemiştir.

F. Kohortlar arası karşılaştırma

Ortak genlerde gen bazlı t istatistikleri kohortlar arasında pozitif koreledir (Şekil 2a,b): Golub–MILE $\rho = 0,56$, Golub–Andersson $\rho = 0,44$, MILE–Andersson $\rho = 0,67$. İlk



Şekil 1. Golub veri kalitesi. (a) Simetrik log eksende ham average-difference değerleri; gölgeli bant [20, 16000] kırpma penceresidir. (b) Dizi başına Present/Marginal/Absent çağrı oranları (üstteki işaretler: sınıf). (c) Saptama çağrısına göre ham değer: Absent çağrıları negatif veya sıfıra yakın değerlerle örtüşür.

100 genden 33'ü Golub ve MILE'da (hipergeometrik $p = 3{,}6 \times 10^{-28}$; %100 aynı yönde), 28'i Golub ve Andersson'da ($p = 1{,}5 \times 10^{-21}$) ortaktır. 18 gen üç kohortun da ilk 100 geni arasındadır (CST3, CD33, CTSA, POU2AF1, CD79A, PYGL, PCBD1, NPY, ASAH1, MAPKAPK3, CD19, CSTA). Ancak *ölçekler* uyumsuzdur: ortanca ifade üç log ölçekte 7,31, 0,46 ve −0,03'tür. Uyumlaştırma yapılmayan birleşik PCA'da PC1 varyansının η^2 = %99,8 kadarını kohort, yalnızca %0,0 kadarını sınıf açıklar (Şekil 2c). Kohort içi gen bazlı z-skorlamadan sonra kohort %0,0, sınıf %61,4 açıklar (Şekil 2d). Biyoloji kohortlar arasında taşınır, ölçüm ölçeği taşınmaz; bu yüzden kohortlar arası modeller, test etiketleri kullanılmadan kestirilen kohort içi standardizasyon veya ComBat [32] kullanacaktır. Sınıf oranları kohortlar arasında farklı olduğundan bu düzeltmeler sınıf sinyalini de silebilir; bu ayrıca kontrol edilecektir.

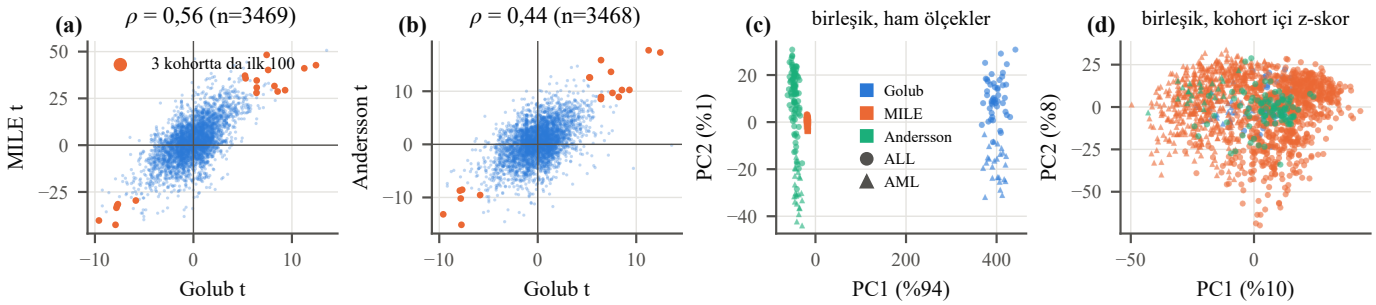
G. Numaralı bulgular ve modelleme çıkarımları

1) *Negatif ve taban düzeyi yoğunluklar* (%28,7 < 0) ⇒ ölçeğe duyarlı her modelden önce $[20, 16000]$ kırpma ve $\log_2$.
2) $p \gg n$ (7.129 öznitelik, 72 örnek) ⇒ öznitelik seçimi (varyans veya kat değişimi filtresi, ardından tek değişkenli k-best) her eğitim katının *içinde*; k iç CV'de ayarlanır.
3) *Güçlü düşük boyutlu sinyal* (PC1 AUC 0,984) ⇒ neredeyse kusursuz skorlar olasıdır; yöntemler arası farklar küçük kalacağından güven aralıkları ve eşleştirilmiş testler şarttır (**AS1**).
4) *Sınıf dengesizliği* (65/35, MILE 750/542, Andersson 98/23) ⇒ tabakalı katlar, `class_weight=balanced`; doğruluğun yanında dengeli doğruluk, F1 ve ROC-AUC. SMOTE kullanılırsa yalnızca eğitim katlarında.
5) Golub'da *eğitim/test kayması* ⇒ 38/34 sonucu ve iç içe CV ayrı raporlanır, fark açıklanır (**AS2**).
6) *Eksik değerler* (Andersson) ve *ölçek duyarlılığı* ⇒ LR, SVM ve sinir ağları için kat içi ortanca/k-NN imputasyonu ve kat içi z-skorlama (ağaçlar ölçekten bağımsızdır).
7) *Ortak biyoloji, farklı ölçekler* ($\rho > 0$, anlamlı örtüşme, PC1'e kohort hâkim) ⇒ kohortlar arası aktarımda 3.469 ortak gende kohort içi standardizasyon (**AS3**). Soy heterojenliği (T-ALL) olası bir hata kaynağıdır ve ayrıca incelenecektir.

V. Fizibilite Pilotu, Final ve Makale Planı

Fizibilite pilotu. Planın ana iddialarının sınanabilir olduğunu görmek için hiperparametreleri önceden sabitlenmiş küçük bir deneme yapılmıştır (`scripts/run_feasibility.py`). Bu bir model karşılaştırması değildir: sonuçlara göre ayar yapılmamış, kilitli setler kullanılmamıştır. *Sızıntı.* 38 Golub eğitim örneğinde doğrusal SVM ve 50 genle, gen seçimi katların içinde yapıldığında dengeli doğruluk (DD) 0,91, CV'den önce tüm örneklerde yapıldığında 1,00 çıkmıştır. Etiketler karıştırıldığında (200 permütasyon) gerçek bilgi olmamasına rağmen dışarıda seçim 0,91, içeride seçim şans düzeyinde 0,50 vermiştir: sızıntılı protokol, sinyal yokken de yüksek skor üretebilir. *Aktarım.* Tek kohortta eğitilen sabit lojistik regresyon (100 gen) diğer kohortlarda denenmiştir (Tablo III; Golub yalnızca 38 eğitim örneğidir). Yalnızca eğitim istatistikleriyle ölçeklenen sabit aktarımda altı yönün 4'ünde model tek sınıfa yığılır: AUC 0,965–0,992 iken DD 0,50'dir; kalan iki yönde DD 0,84 ve 0,92'dir. Bu desen sepsiste bildirilenle aynıdır [35] ve ölçek farkından da beklenir; yeni bulgu değildir. Hedef kohortun kendi istatistiklerini kullanan z-skor, etiketsiz bir kohort uyarlamasıdır: DD'yi 0,59–0,94'e çıkarır, ama tek hastaya uygulanamaz ve hedef setin sınıf oranına bağlıdır. Örnek içi sıra dönüşümü [35]'da eşiği kurtarırken (0,95–1,00) burada kurtarmaz (DD 0,50–0,70; MILE→Golub AUC 0,66). Göreli gen sırasının platforma göre değişmesi [37] olası bir açıklamadır; Andersson'un oran ölçeği de ayrıca etkili olabilir. T-ALL'de hata daha yüksek görünür (MILE→Andersson z-skorda %27,3, B soylu ALL'de %12,6, $n = 11$; Golub→MILE %6,9 ve %3,3, $n = 174$). Bunlar tek çalışmalık ön bulgudur; kalibrasyon henüz ölçülmemiştir.

Makale hedefi ve özgün katkı. Çalışma ne "en iyi modeli" ne de sızıntı şişmesini veya AUC–eşik ayrışmasını ilk kez gösterdiğini iddia eder; ikisi de başka alanlarda gösterilmiştir [23], [24], [35]. Katkılar: (K1) ALL/AML'de sızıntı şişmesinin tek işlem hattında ölçümü; (K2) iç içe CV ve güven aralıklarıyla yöntem karşılaştırması; (K3) kilitli dış setlerde sabit aktarım, etiketsiz uyarlama ve sıra dönüşümünün karşılaştırılması; (K4)



Şekil 2. Ortak genlerde kohortlar arası uyum. (a,b) Golub'un MILE ve Andersson ile gen bazlı Welch t istatistikleri (turuncu: üç kohortta da ilk 100 gen). (c) Uyumlaştırılmamış birleşik PCA sınıfları değil kohortları ayırır; (d) kohort içi z-skorlama ALL/AML eksenini ortaya çıkarır (renk: kohort, işaret: sınıf).

Tablo III
Aktarım pilotu. Ham: yalnızca eğitim istatistikleri; z: hedef kohort istatistikleri; sıra: örnek içi. DD: dengeli doğruluk. Sabit model, ayar yok.

Eğitim → test	AUC ham	DD ham	AUC z	DD z	DD sıra
Golub → MILE	0,97	0,50	0,97	0,89	0,69
Golub → Andersson	0,97	0,50	0,97	0,94	0,70
MILE → Golub	0,87	0,84	0,93	0,93	0,64
MILE → Andersson	1,00	0,92	0,99	0,93	0,52
Andersson → Golub	0,98	0,50	0,97	0,59	0,50
Andersson → MILE	0,99	0,50	0,99	0,74	0,50

[35]'nın ayıramadığını belirttiği eşik kaymasının kaynağı: prevalansı sabitleyen alt örnekleme ile platform ve sınıf bileşimi etkisinin ayrılması; (K5) $n = 72$ düzeyinde TabPFN ve derin modeller. Eşik gerekçesi ve kalibrasyon eğimi, kesişimi ile O/E de raporlanacaktır [29], [30]. [34] GSE13159'u içerir, ama görevi AML'ye karşı diğerleridir ve AUC bildirmez. Birincil sonlanım noktaları önceden sabittir: kilitli setlerde %95 güven aralıklı DD ve AUC. Kilitli setler model seçimi bittikten sonra bir kez açılır; olumsuz sonuç da aynen raporlanır. **Hedef konferans:** IEEE EMBC 2027 adaydır (son tarih 24 Ocak 2027; 4 sayfa içerik + 1 sayfa kaynak, en çok 20 kaynak; resmî sayfa, 6 Kasım 2026). Öğretim üyesinin yazılı onayı alınacak, makale İngilizce yazılacak ve tek konferansa gönderilecektir. Final tarihinde başvuru kapalıysa bildirileri IEEE Xplore'da yayımlanan başka bir konferans seçilecektir.

Yöntemler (henüz sonuç yok). Farklı tümevarımsal yanlılıkları kapsayan üç ML yöntemi: (M1) yorumlanabilir katsayılı seyrek doğrusal model olan *elastic-net cezalı lojistik regresyon* [14]; (M2) mikrodiziler için tarihsel referans olan, doğrusal ve RBF çekirdekli *SVM* [10], [11]; (M3) etkileşimleri modelleyen ve permütasyon önemi sunan [15], [52] *rastgele orman*. Modüldeki karar ağacı taban modeldir.

İşlem hattı ve doğrulama. Veriye bağlı her adım her katta yeniden öğrenilir (Ek B, Şekil 3; arama uzayları da oradadır). (a) 38/34 bölme: 38 örnekte 5 katlı tabakalı CV ile ayar, model seçiminden sonra 34 örnekte *bir kez* değerlendirme; (b) 72 örnekte iç içe CV: dış 5 kat, 5 tohum (42, 7, 123, 2024, 31337), iç 5 katlı arama, tüm yöntemlerde aynı dış katlar. MILE ve Andersson aynı protokolü izler.

Metrikler ve istatistik. Doğruluk, dengeli doğruluk, kesinlik, duyarlılık, özgüllük, F1, ROC-AUC ve karışıklık matrisleri; 25 dış katta ortalama ± SS ve düzeltilmiş yeniden örnekleme t'sinden [3] yaklaşık %95 güven aralıkları; kohort içinde Holm düzeltmeli ikili testler, kohortlar arası betimsel ortalama sıralar [26], sabit bölmede McNemar; ROC/PR, kayıp ve k–performans eğrileri, ablasyon, gen önemi ve çalışma süresi.

Bonuslar. *B1:* MLP ve otokodlayıcı + sınıflandırıcı (erken durdurma ve mimari iç katlarda, isteğe bağlı MILE ön eğitimi). *B2:* TabPFN [47] ($\leq$ 500 genin kat içi seçiminden sonra) ve GenePT tarzı gömmeler [48]. *B3:* yukarıdaki konferans gönderimi. *B4:* Andersson. **Takvim:** 1–2. haftalar Golub iç içe CV ve sızıntı deneyi; 3–4 MILE/Andersson ve aktarım; 5–6 B1/B2, yorumlanabilirlik, kilitli setler; 7 makale, video, B3. **Riskler:** $n = 72$'de varyans; batch/platform etkileri; sinir ağı aşırı uyumu; TabPFN'in doğrulanmış aralığı; gen metinlerinden hastalık bilgisi sızması (B2); konferans takvimi.

VI. Tekrarlanabilirlik ve Sonuç

`python run_all.py` bu PDF'i ham veriden yeniden üretir (tohum 42, sabit `requirements.txt`); metindeki her sayı kodun yazdığı bir LaTeX makrosudur. Üç kohort da güçlü bir ALL/AML sinyali taşır; engeller $p \gg n$, eğitim/test kayması ve platform farklarıdır. Pilot, ölçümlerin mümkün olduğunu gösterir; final **AS1**–**AS4**'ü kilitli setlerle sınayacaktır.

Yapay Zekâ Kullanım Beyanı

Anthropic'in Claude (Opus 5.5) modeli kod, literatür arama, okuma, iddia denetimi ve metin taslağında yardımcı olmuştur. Yazar içeriği gözden geçirmiş ve sorumluluğu üstlenmektedir (tam beyan ayrıca sunulmuştur).

Kaynaklar

[1] T. R. Golub, D. K. Slonim, P. Tamayo *et al.*, "Molecular classification of cancer: Class discovery and class prediction by gene expression monitoring," *Science*, vol. 286, no. 5439, pp. 531–537, 1999, doi: 10.1126/science.286.5439.531.

[2] T. Haferlach, A. Kohlmann, L. Wieczorek *et al.*, "Clinical utility of microarray-based gene expression profiling in the diagnosis and subclassification of leukemia: Report from the International Microarray Innovations in Leukemia Study Group," *Journal of Clinical Oncology*, vol. 28, no. 15, pp. 2529–2537, 2010, doi: 10.1200/JCO.2009.23.4732.

[3] C. Nadeau and Y. Bengio, "Inference for the generalization error," *Machine Learning*, vol. 52, no. 3, pp. 239–281, 2003, doi: 10.1023/A:1024068626366.

[4] A. Kohlmann, T. J. Kipps, L. Z. Rassenti *et al.*, "An international standardization programme towards the application of gene expression profiling in routine leukaemia diagnostics: the Microarray Innovations in LEukemia study prephase," *British Journal of Haematology*, vol. 142, no. 5, pp. 802–807, 2008, doi: 10.1111/j.1365-2141.2008.07261.x.

[5] A. Andersson, C. Ritz, D. Lindgren *et al.*, "Microarray-based classification of a consecutive series of 121 childhood acute leukemias: prediction of leukemic and genetic subtype as well as of minimal residual disease status," *Leukemia*, vol. 21, no. 6, pp. 1198–1203, 2007, doi: 10.1038/sj.leu.2404688.

[6] R. Mulet-Lazaro, A. Sijs-Szabó, R. M. Hoogenboezem, S. van Herk, C. Exalto, J. E. Koenders, P. G. Hoogeveen, F. G. Kavelaars, A. M. Schelen, W. van den Ancker, A. A. van de Loosdrecht, C. G. Mullighan, H. B. Beverloo, V. van der Velden, J. J. Cornelissen, P. J. M. Valk, A. W. Rijneveld, and M. A. Sanders, "Transcriptional profiling directs the classification of acute leukemias of ambiguous lineage into AML, B-ALL, or T-ALL," *HemaSphere*, vol. 9, no. 8, p. e70195, 2025, doi: 10.1002/hem3.70195.

[7] T. Beder, B.-T. Hansen, A. M. Hartmann, J. Zimmermann, E. Amelunxen, N. Wolgast, W. Walter, M. Zaliova, Ž. Antić, P. Chouvarine, L. Bartsch, M. J. Barz, M. Bultmann, J. Horns, S. Bendig, J. Kässens, C. Kaleta, G. Cario, M. Schrappe, M. Neumann, N. Gökbuget, A. K. Bergmann, J. Trka, C. Haferlach, M. Brüggemann, C. D. Baldus, and L. Bastian, "The Gene Expression Classifier ALLCatchR Identifies B-cell Precursor ALL Subtypes and Underlying Developmental Trajectories Across Age," *HemaSphere*, vol. 7, no. 9, p. e939, 2023, doi: 10.1097/hs9.0000000000000939.

[8] B. Cui, H. Sun, S. Zhao, R. Fan, J. Rao, W. Wu, Y. Zhong, R. Wang, Y. Wang, Q. Shi, Y. Guo, J. Lin, Y. Huang, Y. Han, H. Liu, X. Chen, S. Shen, H. Wang, and Y. Liu, "Deep learning based individualized cross-platform molecular subtype classification of B-lineage acute lymphoblastic leukemia," *npj Precision Oncology*, vol. 10, no. 1, p. 355, 2026, doi: 10.1038/s41698-026-01556-1.

[9] I. Jung, A.-L. Vitte, F. Chuffart, S. Chevalier, P. Mossuz, S. Khochbin, and E. Bourova-Flin, "Predicting isocitrate dehydrogenase mutation status in acute myeloid leukemia from gene expression profiles by machine learning," *NAR Genomics and Bioinformatics*, vol. 8, no. 2, p. lqag058, 2026, doi: 10.1093/nargab/lqag058.

[10] T. S. Furey, N. Cristianini, N. Duffy, D. W. Bednarski, M. Schummer, and D. Haussler, "Support vector machine classification and validation of cancer tissue samples using microarray expression data," *Bioinformatics*, vol. 16, no. 10, pp. 906–914, 2000, doi: 10.1093/bioinformatics/16.10.906.

[11] I. Guyon, J. Weston, S. Barnhill, and V. Vapnik, "Gene selection for cancer classification using support vector machines," *Machine Learning*, vol. 46, no. 1–3, pp. 389–422, 2002, doi: 10.1023/A:1012487302797.

[12] S. Dudoit, J. Fridlyand, and T. P. Speed, "Comparison of discrimination methods for the classification of tumors using gene expression data," *Journal of the American Statistical Association*, vol. 97, no. 457, pp. 77–87, 2002, doi: 10.1198/016214502753479248.

[13] R. Tibshirani, T. Hastie, B. Narasimhan, and G. Chu, "Diagnosis of multiple cancer types by shrunken centroids of gene expression," *Proceedings of the National Academy of Sciences*, vol. 99, no. 10, pp. 6567–6572, 2002, doi: 10.1073/pnas.082099299.

[14] H. Zou and T. Hastie, "Regularization and variable selection via the elastic net," *Journal of the Royal Statistical Society Series B: Statistical Methodology*, vol. 67, no. 2, pp. 301–320, 2005, doi: 10.1111/j.1467-9868.2005.00503.x.

[15] R. Díaz-Uriarte and S. Alvarez de Andrés, "Gene selection and classification of microarray data using random forest," *BMC Bioinformatics*, vol. 7, p. 3, 2006, doi: 10.1186/1471-2105-7-3.

[16] E. Alhenawi, R. Al-Sayyed, A. Hudaib, and S. Mirjalili, "Feature selection methods on gene expression microarray data for cancer classification: A systematic review," *Computers in Biology and Medicine*, vol. 140, p. 105051, 2022, doi: 10.1016/j.compbiomed.2021.105051.

[17] F. Alharbi and A. Vakanski, "Machine learning methods for cancer classification using gene expression data: A review," *Bioengineering*, vol. 10, no. 2, p. 173, 2023, doi: 10.3390/bioengineering10020173.

[18] C. Ambroise and G. J. McLachlan, "Selection bias in gene extraction on the basis of microarray gene-expression data," *Proceedings of the National Academy of Sciences*, vol. 99, no. 10, pp. 6562–6566, 2002, doi: 10.1073/pnas.102102699.

[19] S. Varma and R. Simon, "Bias in error estimation when using cross-validation for model selection," *BMC Bioinformatics*, vol. 7, p. 91, 2006, doi: 10.1186/1471-2105-7-91.

[20] S. Kapoor and A. Narayanan, "Leakage and the reproducibility crisis in machine-learning-based science," *Patterns*, vol. 4, no. 9, p. 100804, 2023, doi: 10.1016/j.patter.2023.100804.

[21] S. Whalen, J. Schreiber, W. S. Noble, and K. S. Pollard, "Navigating the pitfalls of applying machine learning in genomics," *Nature Reviews Genetics*, vol. 23, no. 3, pp. 169–181, 2022, doi: 10.1038/s41576-021-00434-9.

[22] J. Bernett, D. B. Blumenthal, D. G. Grimm, F. Haselbeck, R. Joeres, O. V. Kalinina, and M. List, "Guiding questions to avoid data leakage in biological machine learning applications," *Nature Methods*, vol. 21, no. 8, pp. 1444–1453, 2024, doi: 10.1038/s41592-024-02362-y.

[23] A. Demircioğlu, "Measuring the bias of incorrect application of feature selection when using cross-validation in radiomics," *Insights into Imaging*, vol. 12, no. 1, p. 172, 2021, doi: 10.1186/s13244-021-01115-1.

[24] M. Rosenblatt, L. Tejavibulya, R. Jiang, S. Noble, and D. Scheinost, "Data leakage inflates prediction performance in connectome-based machine learning models," *Nature Communications*, vol. 15, no. 1, p. 1829, 2024, doi: 10.1038/s41467-024-46150-w.

[25] S. Bates, T. Hastie, and R. Tibshirani, "Cross-Validation: What Does It Estimate and How Well Does It Do It?" *Journal of the American Statistical Association*, vol. 119, no. 546, pp. 1434–1445, 2024, doi: 10.1080/01621459.2023.2197686.

[26] J. Demšar, "Statistical comparisons of classifiers over multiple data sets," *Journal of Machine Learning Research*, vol. 7, pp. 1–30, 2006.

[27] B. Van Calster, E. W. Steyerberg, L. Wynants, and M. van Smeden, "There is no such thing as a validated prediction model," *BMC Medicine*, vol. 21, no. 1, p. 70, 2023, doi: 10.1186/s12916-023-02779-w.

[28] G. S. Collins, P. Dhiman, J. Ma, M. M. Schlussel, L. Archer, B. Van Calster, F. E. Harrell, G. P. Martin, K. G. M. Moons, M. van Smeden, M. Sperrin, G. S. Bullock, and R. D. Riley, "Evaluation of clinical prediction models (part 1): from development to external validation," *BMJ*, vol. 384, p. e074819, 2024, doi: 10.1136/bmj-2023-074819.

[29] R. D. Riley, L. Archer, K. I. E. Snell, J. Ensor, P. Dhiman, G. P. Martin, L. J. Bonnett, and G. S. Collins, "Evaluation of clinical prediction models (part 2): how to undertake an external validation study," *BMJ*, vol. 384, p. e074820, 2024, doi: 10.1136/bmj-2023-074820.

[30] G. S. Collins, K. G. M. Moons, P. Dhiman, R. D. Riley, A. L. Beam, B. Van Calster, M. Ghassemi, X. Liu, J. B. Reitsma, M. van Smeden, A.-L. Boulesteix, J. C. Camaradou, L. A. Celi, S. Denaxas, A. K. Denniston, B. Glocker, R. M. Golub, H. Harvey, G. Heinze, M. M. Hoffman, A. P. Kengne, E. Lam, N. Lee, E. W. Loder, L. Maier-Hein, B. A. Mateen, M. D. McCradden, L. Oakden-Rayner, J. Ordish, R. Parnell, S. Rose, K. Singh, L. Wynants, and P. Logullo, "TRIPOD+AI statement: updated guidance for reporting clinical prediction models that use regression or machine learning methods," *BMJ*, vol. 385, p. e078378, 2024, doi: 10.1136/bmj-2023-078378.

[31] J. T. Leek, R. B. Scharpf, H. C. Bravo, D. Simcha, B. Langmead, W. E. Johnson, D. Geman, K. Baggerly, and R. A. Irizarry, "Tackling the widespread and critical impact of batch effects in high-throughput data," *Nature Reviews Genetics*, vol. 11, no. 10, pp. 733–739, 2010, doi: 10.1038/nrg2825.

[32] W. E. Johnson, C. Li, and A. Rabinovic, "Adjusting batch effects in microarray expression data using empirical Bayes methods," *Biostatistics*, vol. 8, no. 1, pp. 118–127, 2007, doi: 10.1093/biostatistics/kxj037.

[33] S. M. Foltz, C. S. Greene, and J. N. Taroni, "Cross-platform normalization enables machine learning model training on microarray and RNA-seq data simultaneously," *Communications Biology*, vol. 6, no. 1, p. 222, 2023, doi: 10.1038/s42003-023-04588-6.

[34] S. Warnat-Herresthal, K. Perrakis, B. Taschler *et al.*, "Scalable prediction of acute myeloid leukemia using high-dimensional machine learning and blood transcriptomics," *iScience*, vol. 23, no. 1, p. 100780, 2020, doi: 10.1016/j.isci.2019.100780.

[35] H. Zheng and W. Chen, "High AUROC can mask decision failure in sepsis transcriptomic classifiers: Preprocessing stability outweighs post hoc calibration across cohorts," *PLOS One*, vol. 21, no. 9, p. e0357585, 2026, doi: 10.1371/journal.pone.0357585.

[36] I. S. Kervancı and G. Ö. Yiğit, "Multi-Platform Transcriptomic Classification of LUAD Driver Mutation Subtypes via Heterogeneous Ensemble Learning," *Diagnostics*, vol. 16, no. 20, p. 3413, 2026, doi: 10.3390/diagnostics16203413.

[37] J. J. Lee, M. Aldakkak, A. B. Morrison, S. Z. Thalji, X. L. Peng, Y. Li, M. L. Gulley, E. H. Borazanci, S. Tsai, N. U. Rashid, and J. J. Yeh, "Cross-platform comparison of gene expression-based cancer molecular subtyping reveals discrepancies with exome capture methods," *npj Precision Oncology*, vol. 10, no. 1, p. 37, 2025, doi: 10.1038/s41698-025-01228-6.

[38] R. de Negreiros Botan and J. B. de Sousa, "CorePAM: a 24-gene PAM50-derived expression score with cross-platform external validation for breast cancer prognosis," *Breast Cancer Research*, vol. 28, no. 1, p. 142, 2026, doi: 10.1186/s13058-026-02298-5.

[39] M. Kolev, I. Naskinova, M. Lazarova, V. Klisurov, and H. Kalinov, "What a Near-Perfect AUROC Does Not Show: Random-Panel and Label-Permutation Controls for a Sepsis Blood-Transcriptome Signature," *International Journal of Molecular Sciences*, vol. 27, no. 20, p. 9273, 2026, doi: 10.3390/ijms27209273.

[40] W. Xie, W. Li, S. Zhang, L. Wang, J. Yang, and D. Zhao, "A novel biomarker selection method combining graph neural network and gene relationships applied to microarray data," *BMC Bioinformatics*, vol. 23, no. 1, p. 303, 2022, doi: 10.1186/s12859-022-04848-y.

[41] K. Rezaee, G. Jeon, M. R. Khosravi, H. H. Attar, and A. Sabzevari, "Deep learning-based microarray cancer classification and ensemble gene selection approach," *IET Systems Biology*, vol. 16, no. 3–4, pp. 120–131, 2022, doi: 10.1049/syb2.12044.

[42] J. B. Awotunde, A. L. Imoize, O. B. Ayoade, M. K. Abiodun, D.-T. Do, A. Silva, and S. N. Sur, "An enhanced hyper-parameter optimization of a convolutional neural network model for leukemia cancer diagnosis in a smart healthcare system," *Sensors*, vol. 22, no. 24, p. 9689, 2022, doi: 10.3390/s22249689.

[43] S. Selvaraj, A. O. Alsayed, N. A. Ismail, B. P. Kavin, E. M. Onyema, G. H. Seng, and A. Q. Uchechi, "Super learner model for classifying leukemia through gene expression monitoring," *Discover Oncology*, vol. 15, no. 1, p. 499, 2024, doi: 10.1007/s12672-024-01337-x.

[44] S. Warnat-Herresthal, H. Schultze, K. L. Shastry *et al.*, "Swarm learning for decentralized and confidential clinical machine learning," *Nature*, vol. 594, no. 7862, pp. 265–270, 2021, doi: 10.1038/s41586-021-03583-3.

[45] L. Grinsztajn, E. Oyallon, and G. Varoquaux, "Why do tree-based models still outperform deep learning on typical tabular data?" in *Advances in Neural Information Processing Systems (Datasets and Benchmarks Track)*, vol. 35, 2022, pp. 507–520, arXiv:2207.08815. [Online]. Available: https://proceedings.neurips.cc/paper_files/paper/2022/hash/0378c7692da36807bdec87ab043cdadc-Abstract-Datasets_and_Benchmarks.html

[46] Y. Gorishniy, I. Rubachev, V. Khrulkov, and A. Babenko, "Revisiting deep learning models for tabular data," in *Advances in Neural Information Processing Systems*, vol. 34, 2021, pp. 18 932–18 943, arXiv:2106.11959. [Online]. Available: https://proceedings.neurips.cc/paper/2021/hash/9d86d83f925f2149e9edb0ac3b49229c-Abstract.html

[47] N. Hollmann, S. Müller, L. Purucker, A. Krishnakumar, M. Körfer, S. B. Hoo, R. T. Schirrmeister, and F. Hutter, "Accurate predictions on small data with a tabular foundation model," *Nature*, vol. 637, no. 8045, pp. 319–326, 2025, doi: 10.1038/s41586-024-08328-6.

[48] Y. Chen and J. Zou, "Simple and effective embedding model for single-cell biology built from ChatGPT," *Nature Biomedical Engineering*, vol. 9, no. 4, pp. 483–493, 2025, doi: 10.1038/s41551-024-01284-6.

[49] F. Pedregosa, G. Varoquaux, A. Gramfort *et al.*, "Scikit-learn: Machine learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.

[50] L. van der Maaten and G. Hinton, "Visualizing data using t-SNE," *Journal of Machine Learning Research*, vol. 9, pp. 2579–2605, 2008.

[51] Y. Benjamini and Y. Hochberg, "Controlling the false discovery rate: A practical and powerful approach to multiple testing," *Journal of the Royal Statistical Society: Series B (Methodological)*, vol. 57, no. 1, pp. 289–300, 1995, doi: 10.1111/j.2517-6161.1995.tb02031.x.

[52] L. Breiman, "Random forests," *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001, doi: 10.1023/A:1010933404324.

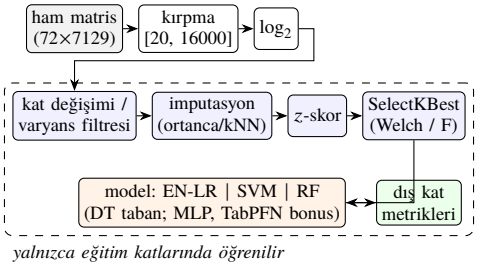
Ek A
Tam literatür tablosu

Tablo IV: Tam literatür özet tablosu (dahil edilen 46 çalışmanın tamamı, kronolojik).

Kaynak	Yıl	Veri seti	Ön işleme/öznitelik seçimi	Yöntem	Doğrulama	En iyi sonuç	Not
[1]	1999	Golub ALL/AML (Affymetrix Hu6800)	Sınıf korelasyonuyla bilgilendirici gen seçimi	Sınıf keşfi + ağırlıklı oylama sınıf öngörücüsü	38 örnekte LOOCV ve sabit 34	LOOCV 36/38 tahmin; test 29/34 tahmin, tümü doğru; 5 belirsiz	Özgün veri seti; çoğunlukla pediatrik
[10]	2000	Yumurtalık, Golub, kolon	bildirilmedi	SVM	Birini dışarıda bırakma ve 38/34	Golub testi 30-32/34 doğru	Teknikler arasında belirgin fark yok
[11]	2002	Lösemi ve kolon mikrodizileri	SVM-RFE gen sıralaması	Doğrusal SVM	LOO ve 38/34	Golub testi 8 veya 16 genle 0/34 hata	Seçimin LOO içinde yapıldığı belirtilmemiş
[12]	2002	Golub, NCI60, lenfoma	Taban 100, tavan 16000, filtre, log10	LDA/DLDA, kNN, ağaçlar, birleştirme	150 tekrarlı 2:1 bölme	DLDA ortanca hata 0 (iki sınıflı lösemi)	Teknik rapor 576 okundu, JASA sürümü değil
[13]	2002	SRBCT ve lösemi	Küçültülmüş merkez yumuşak eşikleme	En yakın küçültülmüş merkezler (PAM)	38 örnekte 10 kat CV ve sabit 34	CV 1/38, test 2/34, 21 gen	En yakın küçültülmüş merkezler
[18]	2002	Kolon ve Golub	CV içinde ve dışında gen seçimi	SVM-RFE; Fisher ve ileri seçim	Dış 10 kat CV; .632+ bootstrap	Seçim yanlılığı yaklaşık %5 (38/34), %2-3 (72 örnek)	Seçim yanlılığı; CV hatası sıfır değil
[14]	2005	Metodoloji (mikrodizi örneği dahil)	Elastic net cezası	Cezalı regresyon	bildirilmedi	10 kat CV 3/38, test 0/34, 45 gen	0-1 yanıtta kare kayıp
[15]	2006	Golub eğitim 38 x 3.051 + 8 diğer set	RF geriye gen eleme	Rastgele orman; SVM/kNN/DLDA/SC	.632+ bootstrap	SVM 0,014; RF seçimsiz 0,051, seçimle 0,075-0,087	Lösemide RF 2 gen seçiyor
[19]	2006	Yalnızca benzetim (40 örnek, 6.000 öznitelik)	CV içinde ayar	İç içe CV	İç içe ve iç içe olmayan CV	İç içe tahminler gerçek hataya yakın	Neredeyse yansız, hafif kötümser
[5]	2007	121 çocukluk çağı lösemisi (GSE7186)	bildirilmedi	k en yakın komşu öngörücüleri	Bağımsız veri setiyle doğrulama	T-ALL MRD durumu %100 doğrulukla sınıflandı	Dış doğrulama kaynağı (pediatrik)
[32]	2007	İki örnek veri seti	Deneysel Bayes konum/ölçek düzeltmesi	ComBat	uygulanamaz	bildirilmedi	ComBat adı makalede geçmiyor
[4]	2008	MILE ön aşaması (çok laboratuvarlı)	Laboratuvarlar arası standart protokoller	Laboratuvarlar arası tekrarlanabilirlik çalışması	Laboratuvarlar arası karşılaştırma	bildirilmedi	GEO'da GSE13159 ile bağlantılı
[2]	2010	MILE aşama I/II (GSE13159 = aşama I)	Tüm genom HG-U133 Plus 2.0 profili	Tüm çiftler doğrusal SVM	Aşama I CV; aşama II ileriye dönük, özel çip	Aşama I 3x30 kat CV %92,2; aşama II %88,1	Dış doğrulama kaynağı; 11 laboratuvar
[31]	2010	Derleme ve dokuz veri setinin yeniden analizi	Batch etkisi tanılaması	Derleme	uygulanamaz	bildirilmedi	Kohortlar arası batch işlemeyi gerekçelendirir
[34]	2020	105 çalışmadan 12.029 örnek	Yüksek boyutlu tüm genom girdi	AML tahmini için ML	100 rastgele 80/20 bölme; çalışma-ayrık; platformlar arası	bildirilmedi	ALL dahil diğer tüm örneklere karşı AML
[44]	2021	>16.400 kan transkriptomu (lösemi dahil)	bildirilmedi	Swarm Learning (merkeziyetsiz ML)	Birleşik verinin benzetimli siloları; genel test düğümü	bildirilmedi	Merkezî model AML'de biraz daha iyi
[46]	2021	11 veri seti, n 20.640 ile 1,2M	bildirilmedi	FT-Transformer / ResNet ve GBDT	Kıyas protokolü	bildirilmedi	Çoğunda en iyi derin model; bazılarında GBDT kazanıyor
[23]	2021	10 radyomik veri seti	CV öncesi ve kat içi 7 seçim yöntemi	Çeşitli sınıflandırıcılar, 50.000'den fazla model	Tabakalı 10 kat CV	AUC-ROC'ta 0,149'a kadar yanlılık	Başka alan; gerçek etiketler
[45]	2022	45 veri seti, n>=3.000, d<500	bildirilmedi	Ağaç modelleri ve derin öğrenme	Kıyas protokolü	bildirilmedi	Rejim p»n mikrodizileri kapsamıyor
[16]	2022	132 incelenen çalışma	Öznitelik seçim yöntemleri	Sistematik derleme	uygulanamaz	bildirilmedi	En sık araştırma yönü (%34,9)
[40]	2022	Golub lösemi (72 x 7129) + 3 diğer	GNN tabanlı öznitelik sıralaması birleştirme	SVM sınıflandırıcı	10 kat CV	Lösemi doğruluğu 2 genle 0,971	Seçim 10 kat CV'den önce anlatılıyor
[41]	2022	Golub lösemi (72 x 7129) + DLBCL + prostat	Yumuşak topluluk sarmalayıcı gen seçimi (kNN)	Yığılmış derin sinir ağı	k kat CV (K=5-20)	Lösemi ortalama doğruluğu %99,6	Gen seçimi ile CV sırası belirsiz
[42]	2022	Golub lösemi (72 x 7129; UCI)	PSO 7129 genden 2323'ünü seçti	HORD ile optimize CNN	Rastgele 70/30 ve 80/20 bölmeler	Lösemi doğruluğu %99,9 (karşılaştırma tablosu)	CV yok; CML, CLL, sağlıklı sınıfları bildiriliyor, Golub'da yok
[21]	2022	Genomik derlemesi	bildirilmedi	ML tuzakları derlemesi	uygulanamaz	bildirilmedi	Yalnızca özet; genel arka plan
[17]	2023	Mikrodizi ve RNA-seq (derleme)	Öznitelik mühendisliği + ön işleme	ML/DL sınıflandırıcı derlemesi	uygulanamaz	bildirilmedi	MLP, CNN, RNN, GNN, transformer kapsanıyor
[20]	2023	17 alanda 294 makale (22 derleme taraması)	Sızıntı sınıflaması; L1.3 tüm veride öznitelik seçimi	Tarama ve yeniden üretim	Düzeltilmiş yeniden çalıştırma (iç savaş tahmini)	En az 294 makale etkilenmiş	Dışarıda seçim kolumuzun adı
[33]	2023	TCGA BRCA ve GBM, eşleşmiş platformlar	LOG, NPN, QN, TDM, z-skor	LASSO, doğrusal SVM, RF	5 kat CV, tek platformlu testler	QN, TDM, NPN iyi; z-skor en değişken	Karışık platform eğitimi
[27]	2023	Kavramsal; yayımlanmış örnekler	uygulanamaz	Metodolojik tartışma	uygulanamaz	bildirilmedi	Kalibrasyon ayrımdan daha açık
[7]	2023	2.998 B-ALL RNA-seq örneği	LASSO gen seçimi; log, z, 0-1 ölçekleme	Doğrusal SVM ve en yakın komşu	10 kat CV ve dışarıda tutulan kohortlar	Dışarıda tutulanlarda doğruluk 0,957 (21 alt tip)	RNA-seq içinde; ALL/AML değil

Kaynak	Yıl	Veri seti	Ön işleme/öznitelik seçimi	Yöntem	Doğrulama	En iyi sonuç	Not
[43]	2024	Golub ALL/AML + CuMiDa lösemi	RF öznitelik önemi (FI >= 0,04)	Süper öğrenici (RF üst öğrenici)	%20 testle tabakalı 10 kat CV	AML-ALL doğruluğu 0,98 (Tablo 2)	FI sıralaması CV'den önce yapılmış görünüyor
[22]	2024	Biyolojik ML örnekleri	bildirilmedi	Yedi yönlendirici soru	uygulanamaz	bildirilmedi	Yalnızca özet; genel arka plan
[24]	2024	ABCD, HBN, HCPD, PNC bağlantı verileri	Katlar içinde en iyi %5 özellik ve sızıntılı seçim	Ridge regresyon, 400'den fazla işlem hattı	5 kat CV, 100 tekrar	Dikkat sorunlarında sızıntıyla r 0,01'den 0,48'e	Etki sinyal zayıfken en büyük
[25]	2024	Kuram ve benzetim	uygulanamaz	İç içe CV varyans tahmini	Kapsama benzetimi	Olağan CV aralıkları fazla dar olabilir	Kabul edilmiş el yazması okundu; ispat doğrusal model için
[28]	2024	Yöntem rehberi	uygulanamaz	İç ve dış doğrulama	uygulanamaz	bildirilmedi	Eğim ve kalibrasyon-büyük-ölçeği tanımlar
[29]	2024	İki örnekli yöntem rehberi	uygulanamaz	Dış doğrulamanın beş adımı	uygulanamaz	bildirilmedi	Tek ölçüt yetmez
[30]	2024	Raporlama kılavuzu	uygulanamaz	27 maddelik liste	uygulanamaz	bildirilmedi	Eşiğin nasıl belirlendiğini ister
[47]	2025	10.000 örnek, 500 öznitelik, 10 sınıfa kadar	bildirilmedi	TabPFN temel modeli	Kıyas karşılaştırmaları	bildirilmedi	n yaklaşık 72 sınanmamış
[48]	2025	Gen düzeyi ve scRNA-seq görevleri	NCBI özetleri, text-embedding-ada-002	GenePT gömme modeli	Alt görev kıyasları	bildirilmedi	Ön baskı okundu, dergi sürümü değil
[37]	2025	79 eşleşmiş pankreas örneği; 40'ı NanoString	Gen çiftleri (PurIST)	Tek örnek sınıflandırıcı	Eşleşmiş örneklerde karşılaştırma	Uyum %81,0, kappa 0,402	Göreli gen sırası platformla değişiyor
[6]	2025	RNA-seq AML 145, B-ALL 223, T-ALL 85	log TPM, en değişken 8.000 gen	Lasso çok terimli lojistik	İç içe CV ve dış set	Dış duyarlılık %97,5, kesinlik %93,7	En yakın güncel ALL/AML görevi; tek platform
[35]	2026	Dört sepsis kohortu, mikrodizi ve RNA-seq	Eğitim ölçekleme, dayanıklı, örnek içi sıra, dış ölçekleme	L2 lojistik regresyon	Sabit dış test, eşik 0,5	AUROC 0,999 iken DD 0,50; sıra 0,95-1,00	Pilotumuzla aynı AUC-eşik deseni
[36]	2026	Akciğer mikrodizi n=774, TCGA RNA-seq n=508	Referanslı ComBat, SHAP 500 gen	Beş öğrenicili topluluk	5 kat CV ve dış test	ComBat'sız AUROC 0,580, ComBat'lı 0,850	Burada sıralama da çöküyor
[38]	2026	Beş meme kanseri kohortu	Kohort içi z-skor; dondurulmuş z-skor duyarlılığı	Cox elastic net, 24 gen	Dört dış kohort	Kalibrasyon eğimi 0,96'dan 1,57-2,74'e	Sağkalım görevi, eşik değil
[39]	2026	Sepsis GSE65682, GSE57065	İç içe CV, 10 gen	L1 lojistik regresyon	1.000 permütasyon, rastgele paneller	Sağlıklılara karşı AUROC 1,000; yoğun bakımda 0,730, DD 0,527	Aynı platform; karşılaştırma grubu değişiyor
[8]	2026	St. Jude 1.606, SCMC 1.144, Bld.2020 138	Örnek içi sıra, 229-476 gen	LSTM	%80/%20 ve görülmemiş kohortlar	SCMC'de soy doğruluğu %99,38	Görülmemiş kohortlarda AML yok
[9]	2026	19 AML kohortu; TCGA-LAML n=150	pyComBat	Sinir ağı, lojistik regresyon	İç içe CV ve TCGA testi	Lojistik AUC 0,994, DD 0,979	Yüksek olasılıklar fazla tahmin edilmiş

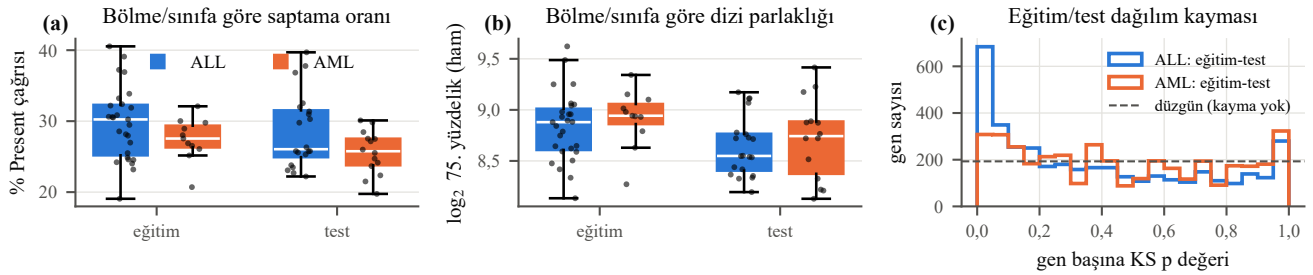
Ek B
Planlanan işlem hattı



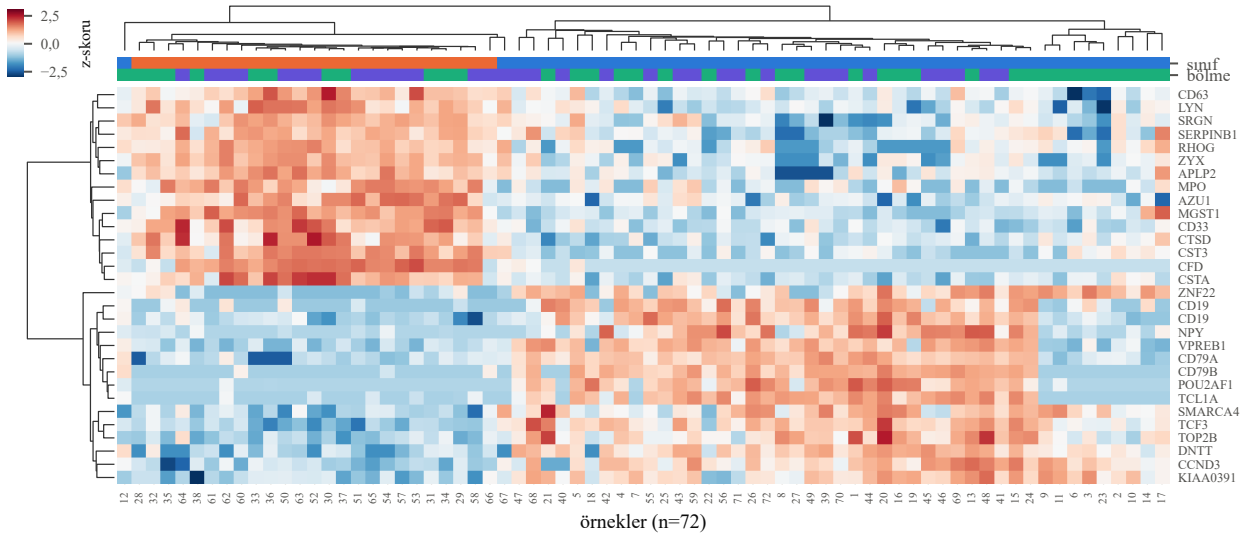
Şekil 3. Planlanan sızıntısız işlem hattı. Durumsuz adımlar (kırpma, $\log_2$) bölmeden önce gelebilir; veriden öğrenen her adım (kesikli kutu), her iç ve dış eğitim katında yeniden öğrenilen bir `sklearn` `Pipeline` aşamasıdır.

Arama uzayları. EN-LR: $C \in [10^{-3}, 10^{2}]$ (log), ℓ_1 oranı $\in \{0{,}1;\ 0{,}5;\ 0{,}9;\ 1\}$. SVM: $C \in [10^{-3}, 10^{3}]$ (log), $\gamma \in [10^{-5}, 10^{-1}]$. RF: ağaç sayısı $\in \{300, 1000\}$, maks. öznitelik $\in \{\sqrt{p};\ 0{,}1p;\ 0{,}3p\}$, min. yaprak $\in \{1, 2, 4\}$. Hepsinde $k \in \{10, \ldots, 500\}$. Izgara arama (EN-LR, SVM), rastgele arama (RF) ve Optuna TPE (sinir ağları) maliyet ve iç CV skoruyla karşılaştırılacaktır.

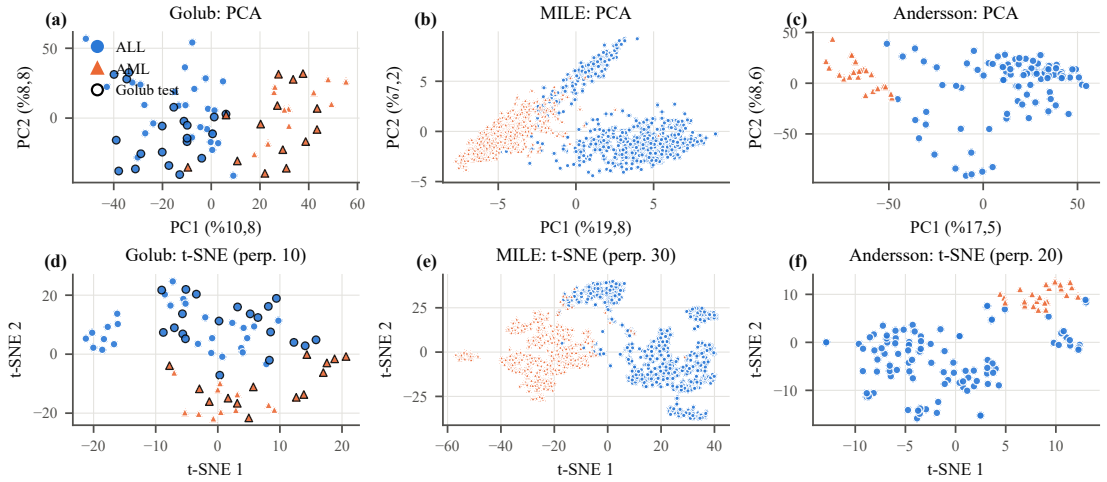
Ek C
Ek EDA şekilleri



Şekil 4. Golub eğitim ve bağımsız set. (a) Present çağrı oranı ve (b) bölme ve sınıfa göre dizi parlaklığı. (c) Her sınıf içinde eğitim ve testi karşılaştıran gen bazlı KS p değerleri; ALL'de 0 yakınındaki fazlalık dağılım kaymasına işaret eder.



Şekil 5. Golub: AML'de en yüksek 15 ve ALL'de en yüksek 15 genin (Welch t) z-skorlu ifadesi; ortalama bağlantı, 1−Pearson uzaklığı. Sütun çubukları: sınıf (mavi ALL, turuncu AML) ve bölme (yeşil eğitim, mor test). Tabana kırpılmış değerler tekdüze açık mavi bloklar olarak görünür.

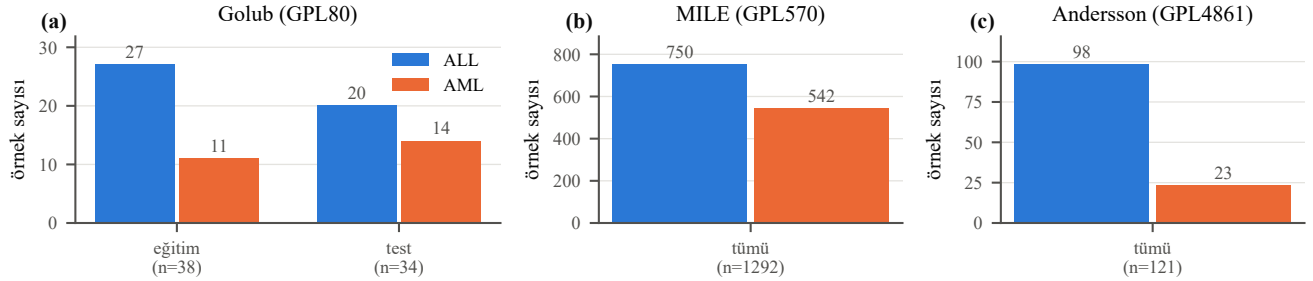


Şekil 6. Üç kohortun denetimsiz gömmeleri (üst: PCA, alt: t-SNE; renk/işaret: sınıf). Golub bağımsız set örnekleri siyah kenarlıdır. Tüm kohortlarda baskın bir ALL/AML ekseni görülür; varyans grafikleri Ek C'dedir.

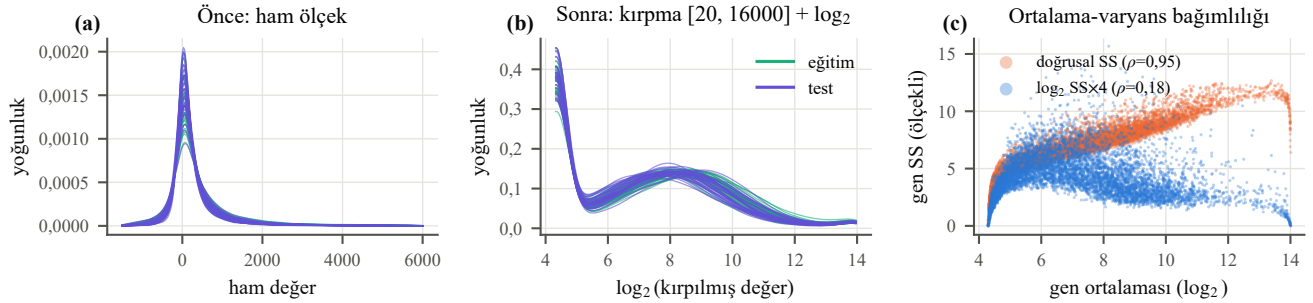
Tablo V

Her kohortta Welch p değerine göre ilk 12 gen (Δ: kohortun log ölçeğinde AML−ALL ortalama farkı; $t > 0$: AML'de yüksek).

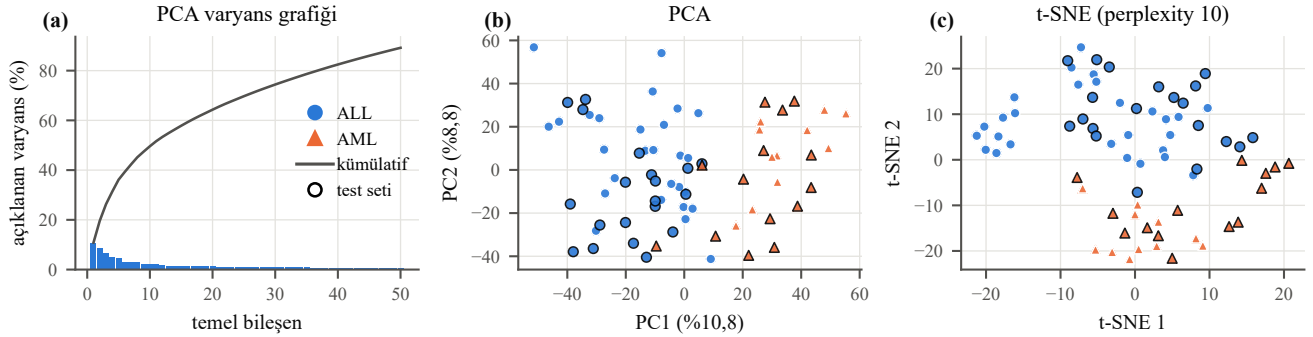
	Golub			MILE			Andersson		
#	gen	Δ	t	gen	Δ	t	gen	Δ	t
1	MGST1	+4,10	+13,5	PNKD	+0,25	+56,8	PILRB	−2,95	−16,0
2	CST3	+5,82	+12,4	LEF1-AS1	−0,35	−59,5	INOC1	−1,61	−15,0
3	TCF3	−2,07	−11,8	LEF1	−0,31	−52,5	NPY	−5,62	−15,1
4	ZYX	+3,83	+11,0	CFD	+0,43	+49,8	–	–	–
5	CD33	+2,26	+11,3	APLP2	+0,21	+49,3	NPR1	−3,31	−14,4
6	APLP2	+2,77	+9,6	LOC101928615	+0,22	+48,8	PCBD1	+2,98	+15,9
7	CD79B	−4,45	−9,2	MGST1	+0,38	+53,2	C17orf58	+2,11	+16,7
8	POU2AF1	−3,09	−9,6	MGST1	+0,41	+50,7	SPG20	+3,07	+13,9
9	DNTT	−4,44	−9,4	LEF1	−0,37	−55,1	LOC201229	−3,50	−14,7
10	CCND3	−2,06	−9,2	CTSA	+0,20	+48,2	CTSC	+2,38	+14,8
11	VPREB1	−4,24	−8,6	FUCA2	+0,24	+47,9	PCBD1	+2,99	+14,6
12	RHOG	+3,17	+8,6	LEF1-AS1	−0,25	−47,3	CD33	+3,87	+17,7



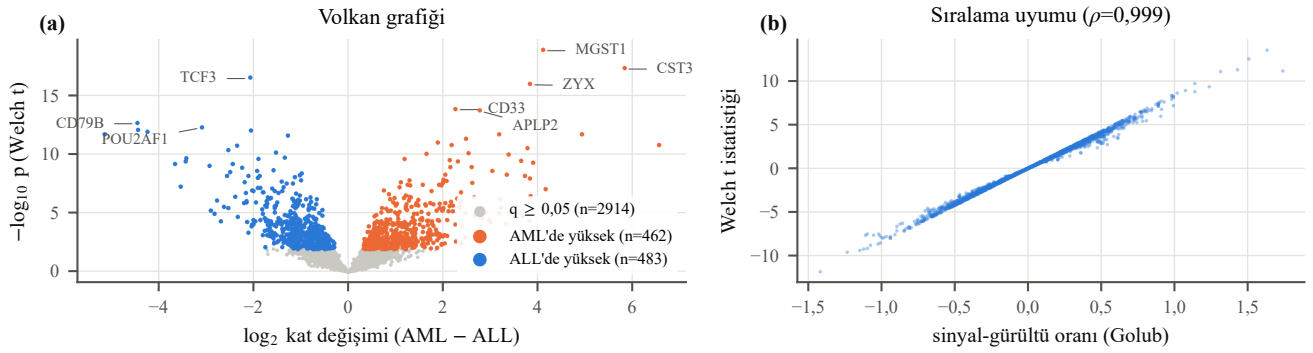
Şekil 7. Sınıf dağılımı. (a) Golub referans bölmesi; (b) 14 ALL/AML alt sınıfının iki etikete eşlenmesinden sonra MILE; (c) normal kontroller çıkarıldıktan sonra Andersson. Tüm setler ALL yönünde dengesizdir.



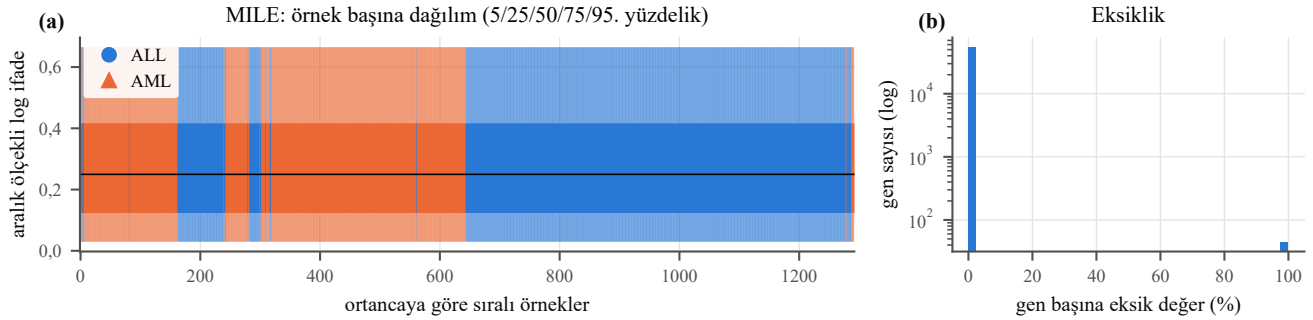
Şekil 8. Dizi başına Golub yoğunlukları: (a) kırpma ve $\log_2$ öncesi, (b) sonrası (renk: referans bölme). (c) Gen standart sapması ve ortalaması: doğrusal ölçekte SS ortalamayla büyür ($\rho = 0{,}95$), $\log_2$ sonrası bağımlılık büyük ölçüde kaybolur ($\rho = 0{,}18$).



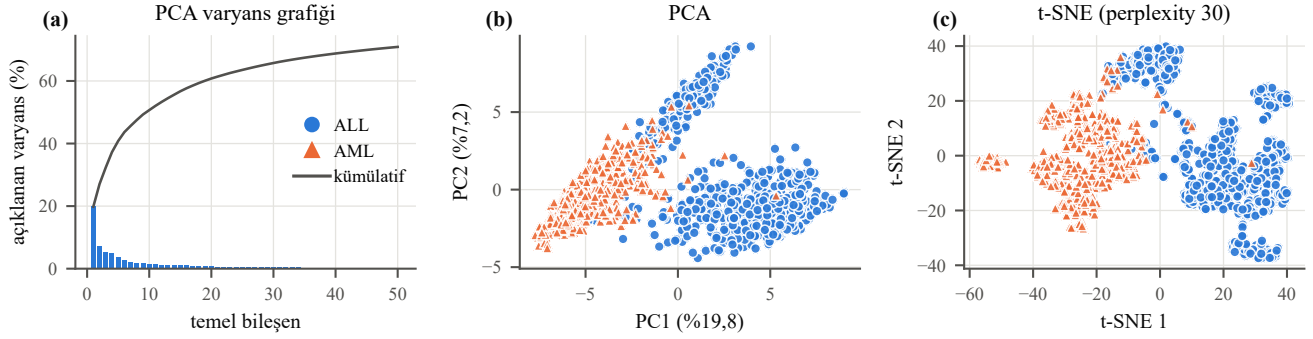
Şekil 9. Golub: PCA varyans grafiği (çubuk: bileşen başına, çizgi: kümülatif), PCA ve t-SNE. PC1 %10,8, on PC %49,6 açıklar; %80 için 37 PC gerekir. Varyans çok sayıda yöne yayılmıştır, yine de PC1 tek başına sınıfları ayırır.



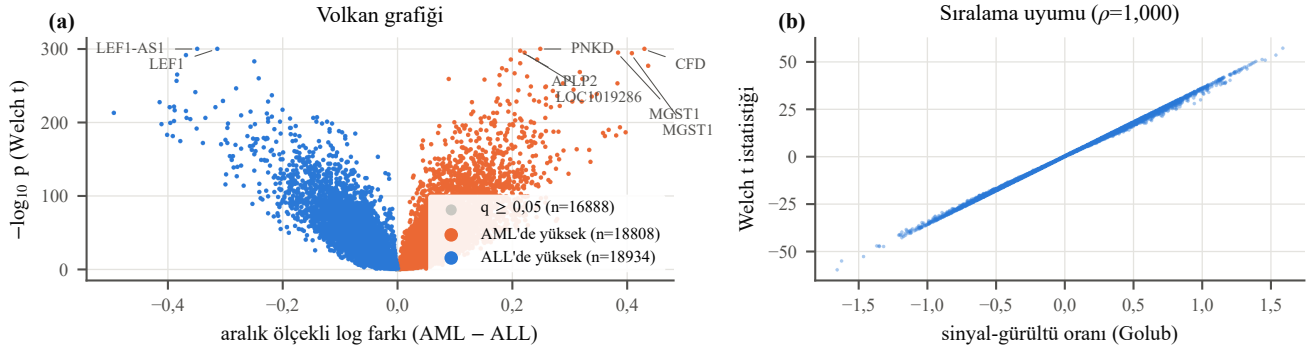
Şekil 10. Golub: (a) Welch testlerinin volkan grafiği (renk: BH $q < 0{,}05$): 462 gen AML'de, 483 gen ALL'de yüksektir; yani farklar tek yönlü değildir. (b) Golub'un sinyal-gürültü oranı ile Welch t genleri neredeyse aynı sıralar ($\rho = 0{,}999$); tek değişkenli filtrede aralarındaki seçim önemsizdir.



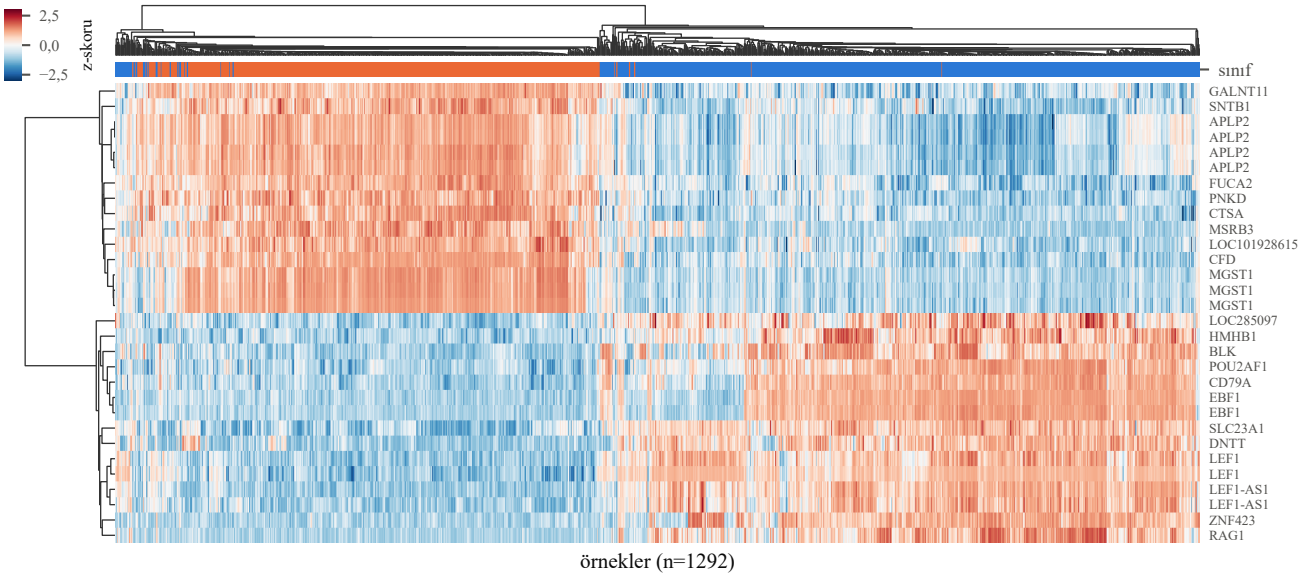
Şekil 11. MILE: (a) aralık ölçekli log değerlerinin dizi başına kantilleri (ortancaya göre sıralı). Kantil normalizasyonundan beklendiği gibi tüm dizilerin kantilleri aynıdır, dizi düzeyinde aykırı değer yoktur. (b) Prob seti başına eksik değer: 45 prob seti tüm dizilerde boştur (çıkarıldı); diğerleri tamdır.



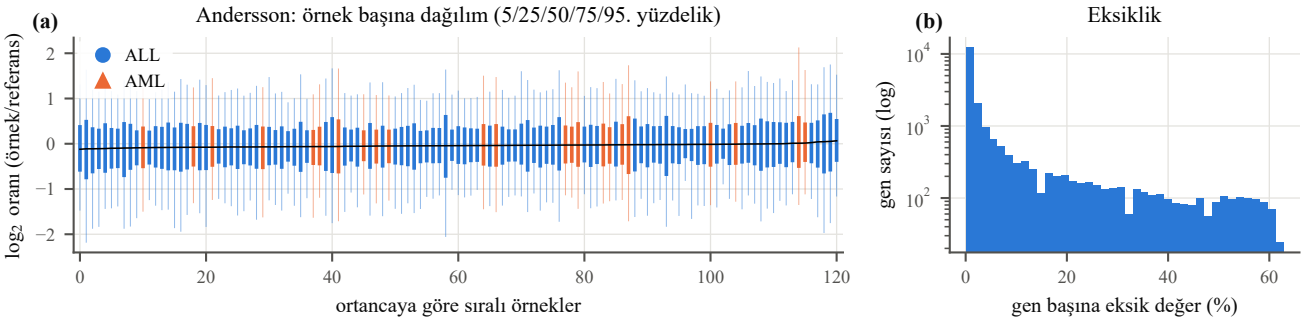
Şekil 12. MILE: PCA varyans grafiği, PCA ve t-SNE (en değişken 5.000 prob). PC1 %19,8 açıklar ve ALL'yi AML'den ayırır (AUC 0,987); t-SNE'de ALL örnekleri, MILE'daki çok sayıda ALL alt tipiyle uyumlu olarak birkaç alt küme oluşturur.



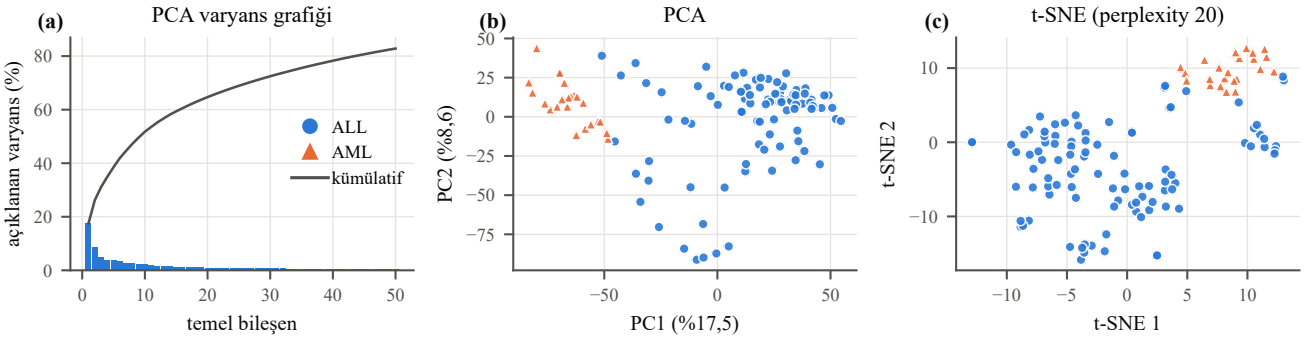
Şekil 13. MILE: (a) volkan grafiği; x ekseni aralık ölçekli log değerlerinin farkıdır, $p < 10^{-300}$ değerleri 300'de çizilmiştir. $n = 1.292$ ile prob setlerinin %69,1'i $q < 0{,}05$ düzeyine ulaşır; bu nedenle gen seçiminde p değil etki büyüklüğü yol göstermelidir. (b) SNR–t uyumu.



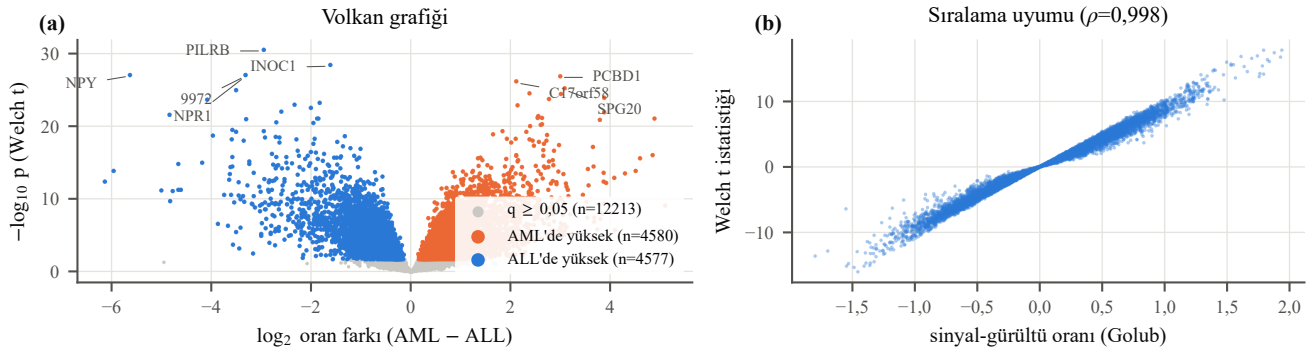
Şekil 14. MILE: ilk 30 genin kümelenmiş ısı haritası. En üst düzeydeki iki küme ALL/AML ile örtüşür (ARI 0,86); ALL içinde bir alt küme B hücre genlerinden (EBF1, CD79A, BLK, POU2AF1) yoksundur, bu T-ALL ile tutarlıdır.



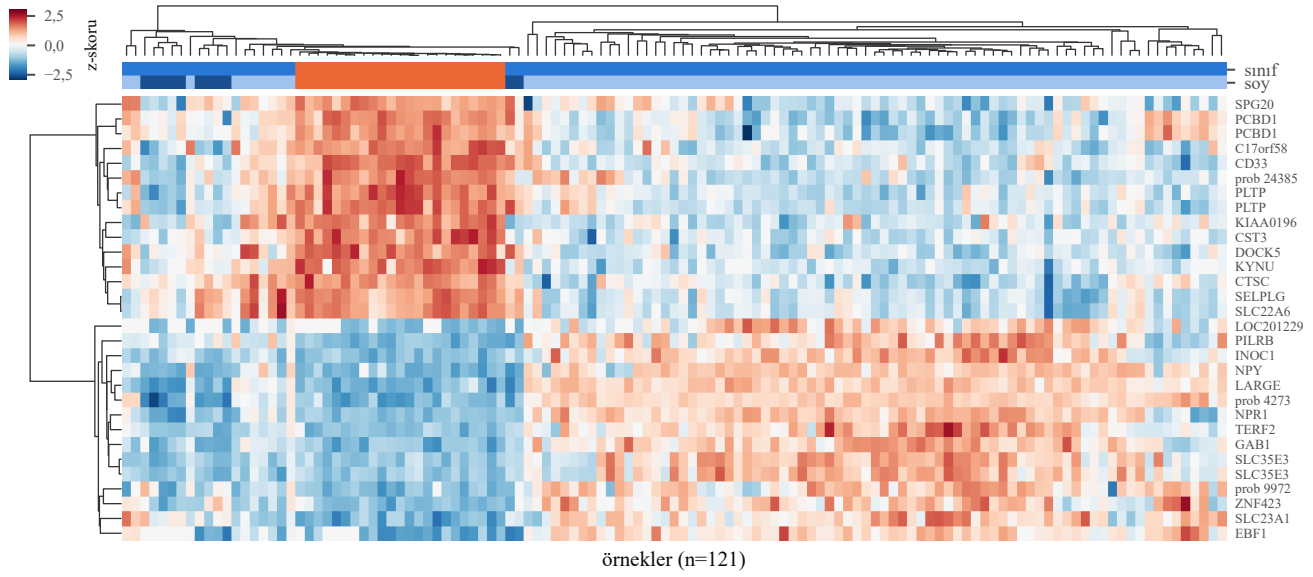
Şekil 15. Andersson: (a) dizi başına $\log_2$ oran dağılımları, lowess normalizasyonu ve merkezlemeden beklendiği gibi 0 yakınında ve benzer yayılımdadır; (b) raportör başına eksik değer: 12.084 raportörde boşluk vardır, 2.841 raportörde %20'den fazlası eksiktir; bu nedenle (kat içi) imputasyon gereklidir.



Şekil 16. Andersson: PCA varyans grafiği, PCA ve t-SNE (yalnızca görselleştirme için ortanca imputasyonu). PC1 %17,5 açıklar ve AML ile ALL'yi neredeyse kusursuz sıralar (AUC 0,999); t-SNE ayrı bir AML grubu ve birkaç ALL alt grubu gösterir.



Şekil 17. Andersson: (a) volkan grafiği (x: $\log_2$ oranlarının farkı); raportörlerin %42,8'si $q < 0{,}05$ düzeyine ulaşır ve AML'de yüksek (4.580) ile ALL'de yüksek (4.577) olarak eşit bölünür. (b) SNR–t uyumu.



Şekil 18. Andersson: ilk 30 genin kümelenmiş ısı haritası. Soy çubuğu: açık mavi B soylu ALL, koyu mavi T hücreli ALL, turuncu AML. T-ALL örnekleri AML'nin yanında kümelenir.