ALL ve AML Lösemi Alt Tip Sınıflandırmasında Sızıntısız Değerlendirme ve Platformlar Arası Aktarım

Ara Rapor: Literatür, Veri Setleri ve Keşifsel Veri Analizi

Enes AY 503020260092

Eskişehir Osmangazi Üniversitesi, Fen Bilimleri Enstitüsü, Yapay Zeka Programı
Makine Öğrenmesi ve Anomali Tespiti

Kasım 2026

Problem ve motivasyon

- ALL (lenfoid) ve AML (miyeloid): ikisi de akut **lösemi alt tipi**; tedavi protokolleri farklı.
- Modüldeki “non-cancer” etiketi biyolojik olarak yanlış $\Rightarrow$ *ALL vs. AML alt tip sınıflandırması*.
- Mikrodizi: binlerce genin mRNA düzeyini tek deneyde ölçer.
- Golub: 72 hasta, 7.129 prob $\Rightarrow p \gg n$.

Araştırma soruları (AS)

1. Nested CV’de 3 yöntem farklı mı?
2. 38/34 CV ile tutarlı mı? Sızıntı ne kadar şişirir?
3. Sinyal kohortlar arası taşınıyor mu?
4. (Bonus) DL / TabPFN daha iyi mi?

Literatür taraması

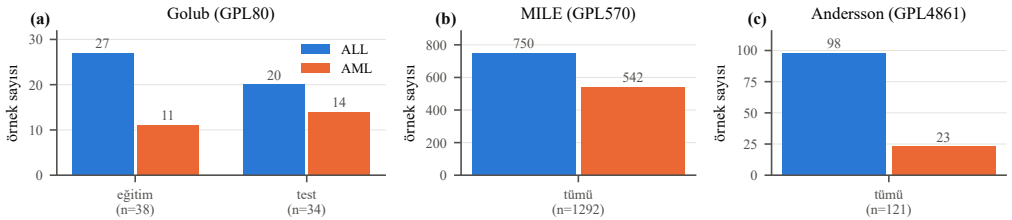
- Crossref, Europe PMC, PubMed; 6 Kasım'da hedefli ek tarama
- 47 kaynak tam metin, 4 özet, 1 künye (yapay zekâ destekli okuma)
- **52 kaynak**, 31'i 2021+; DOI'ler Crossref ile doğrulandı
- Sızıntı: Kapoor 2023, Rosenblatt 2024
- Dış doğrulama: Zheng 2026, Riley 2024; lösemi: Mulet 2025

Boşluk

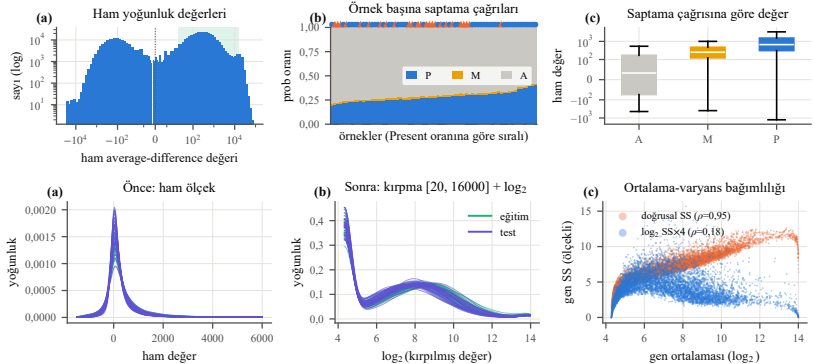
- Yeni 4 çalışmada %97–99,9 doğruluk, ama protokoller karşılaştırılamaz
- Bazı çalışmalarda gen seçimi CV *dışında* $\Rightarrow$ seçim yanlılığı
- Yeni 4 çalışmada güven aralığı yok; okunan Golub çalışmalarında aktarım yok
- AUC–eşik ayrışması sepsiste gösterildi; ALL/AML'de bulamadık

Veri setleri

	Golub	MILE (GSE13159)	Andersson (GSE7186)
Platform	Hu6800	U133 Plus 2.0	27K cDNA (2 renk)
Ölçü	MAS4 avg. diff.	ölçekli log [0,1]	$\log_2$ oran
n (ALL/AML)	72 (47/25)	1.292 (750/542)	121 (98/23)
p	7.129	54.675	21.370
Eksik değer	0	%0,08	%7,19
Rol	ana	benzer 1	benzer 2 (B4)

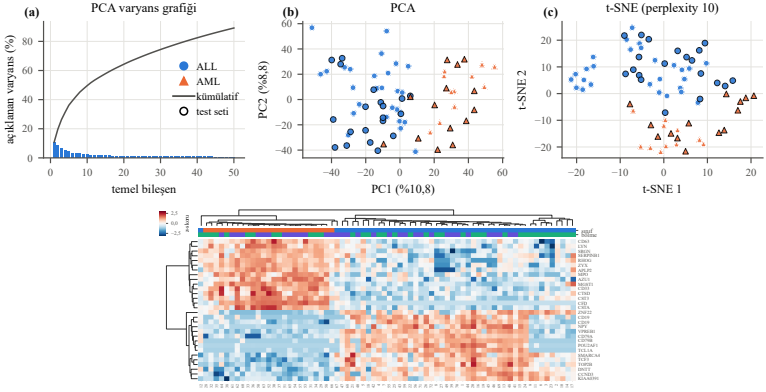


Veri kalitesi ve dönüşüm (Golub)



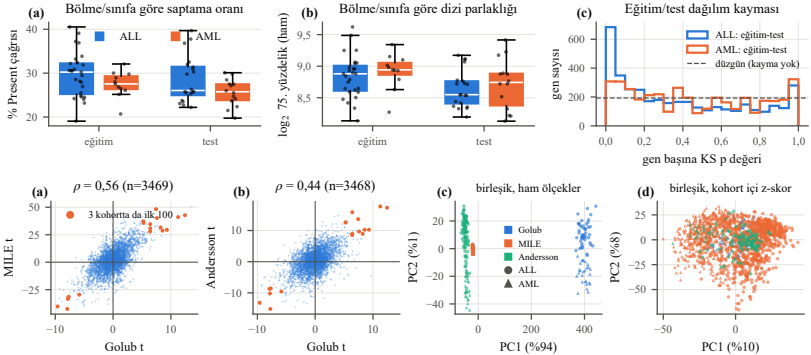
- NaN/INF yok; değerlerin **%28,7**'si negatif (PM − MM), Absent çağrılarıyla (%70,2) örtüşüyor.
- $[20, 16000]$ kırpma + $\log_2$: çarpıklık 7,08 $\rightarrow$ 0,55; ortalama–SS korelasyonu 0,95 $\rightarrow$ 0,18.

Sinyal: boyut indirgeme ve ayırt edici genler



- PC1 varyansın %10,8'ini açıklıyor, ama tek başına AUC 0,984 $\Rightarrow$ güven aralığı ve test şart.
- $q < 0{,}05$: 945 gen. AML: CST3, CD33, MPO; ALL: CD19, CD79B, TCF3.
- **Uyarı:** sıralama tüm veriyle yapıldı, yalnızca betimsel; modelde kullanılırsa sızıntı.

Batch etkisi ve kohortlar arası farklar



- Sınıf içi KS: ALL'de genlerin %17,7'si $p < 0{,}05$ (beklenen %5) $\Rightarrow$ 34 örneklik test skoru sapabilir.
- Biyoloji taşınıyor ($\rho = 0{,}56$, ilk 100 genin 33'ü ortak); ölçek taşınmıyor (PC1'de kohort $\eta^2 = \%99{,}8$).

Fizibilite pilotu: planlanan ölçümler mümkün mü?

Sızıntı (38 Golub eğitim örneği, DD)

- Gerçek etiket: içeride 0,91, dışarıda 1,00
- Rastgele etiket: içeride 0,50, dışarıda **0,91**

Sabit aktarım

- 4/6 yönde AUC 0,965–0,992, DD 0,50
- Sepsiste de bildirildi (Zheng 2026)
- Sıra dönüşümü burada kurtarmıyor: özgün soru

Sabit ayar, ön bulgu; kilitli setlere dokunulmadı.

Eğitim → test	AUC ham	DD ham	AUC z	DD z	DD sıra
Golub → MILE	0,97	0,50	0,97	0,89	0,69
Golub → Andersson	0,97	0,50	0,97	0,94	0,70
MILE → Golub	0,87	0,84	0,93	0,93	0,64
MILE → Andersson	1,00	0,92	0,99	0,93	0,52
Andersson → Golub	0,98	0,50	0,97	0,59	0,50
Andersson → MILE	0,99	0,50	0,99	0,74	0,50

Kilitli dış testler: Golub 34 örnek; MILE aşama 2 (693 akut lösemi, özel çip); TARGET (RNA-seq)

Bulgulardan final planına

Bulgular $\Rightarrow$ kararlar

- $p \gg n \Rightarrow$ öznitelik seçimi **her eğitim katının içinde**
- Güçlü sinyal $\Rightarrow$ güven aralığı, eşleştirilmiş testler
- Dengesizlik $\Rightarrow$ tabakalı katlar, dengeli doğruluk
- Eksik değer $\Rightarrow$ kat içi imputasyon
- Platform farkı $\Rightarrow$ etiketsiz düzeltmeler ve ortak 3.469 gen

Yöntemler: elastic-net LR, SVM, random forest (+ karar ağacı)

Protokol: 38/34, test *bir kez*; 72 örnekte 5×5 iç içe CV, 5 tohum

İstatistik: düzeltilmiş t + Holm, McNemar

Bonuslar: B1 MLP/otokodlayıcı; B2 TabPFN, GenePT; B3 İngilizce makale (aday IEEE EMBC 2027, hocanın yazılı onayıyla); B4 Andersson

Tekrarlanabilirlik: `python run_all.py`, tohum 42

Teşekkürler

Kod: `github.com/mrayenesay/leukemia-all-aml-ml`

GenAI beyanı: Claude (Opus 5.5) kullanıldı; ayrıntılar Ek A'da.