ALL ve AML Lösemi Alt Tip Sınıflandırması

Ara Rapor: Literatür, Veri Setleri ve Keşifsel Veri Analizi

Enes AY 503020260092

Makine Öğrenmesi ve Anomali Tespiti

Kasım 2026

Problem ve motivasyon

- ALL (lenfoid) ve AML (miyeloid): ikisi de akut **lösemi alt tipi**; tedavi protokolleri farklı.
- Modüldeki “non-cancer” etiketi biyolojik olarak yanlış $\Rightarrow$ *ALL vs. AML alt tip sınıflandırması*.
- Mikrodizi: binlerce genin mRNA düzeyini tek deneyde ölçer.
- Golub: 72 hasta, 7,129 prob $\Rightarrow p \gg n$.

Araştırma soruları

1. Nested CV’de 3 yöntem farklı mı?
2. 38/34 tek bölme CV ile tutarlı mı?
3. Sinyal kohortlar arası taşınıyor mu?
4. (Bonus) DL / TabPFN daha iyi mi?

Literatür taraması

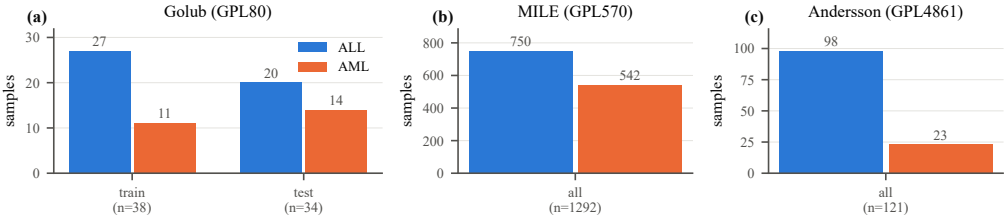
- Crossref, Europe PMC, PubMed; keşif 2021–2026 + klasikler
- 152 kayıt $\rightarrow$ 24 özet $\rightarrow$ 5 tam metin
- **38 kaynak**, hepsi hakemli, 11'i 2021+; tüm DOI'ler Crossref ile doğrulandı
- Klasikler: Golub 1999, SVM, SVM-RFE, DLDA, RF
- Yeni: TabPFN, GenePT, swarm learning

Boşluk

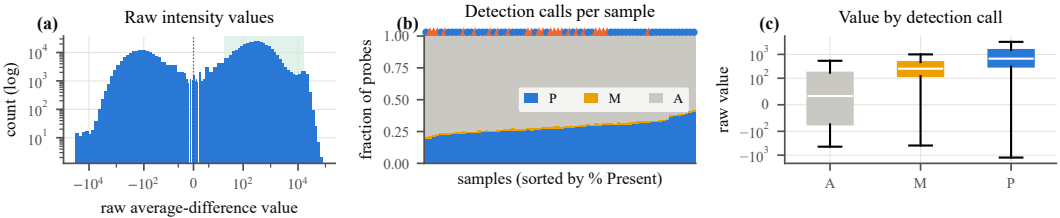
- Golub'da %97–99,9 doğruluk, ama protokoller karşılaştırılamaz
- Gen seçimi çoğu zaman CV *dışında* $\Rightarrow$ seçim yanlılığı
- Güven aralığı ve bağımsız kohort testi nadir

Veri setleri

	Golub	MILE (GSE13159)	Andersson (GSE7186)
Platform	Hu6800	U133 Plus 2.0	27K cDNA (2 renk)
Ölçü	MAS4 avg. diff.	ölçekli log [0,1]	$\log_2$ oran
n (ALL/AML)	72 (47/25)	1,292 (750/542)	121 (98/23)
p	7,129	54,675	21,370
Eksik değer	0	0.08%	7.19%
Rol	ana	benzer 1	benzer 2 (B4)

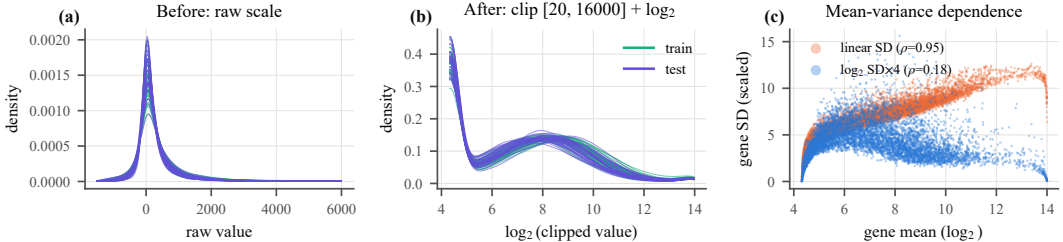


Veri kalitesi (Golub)



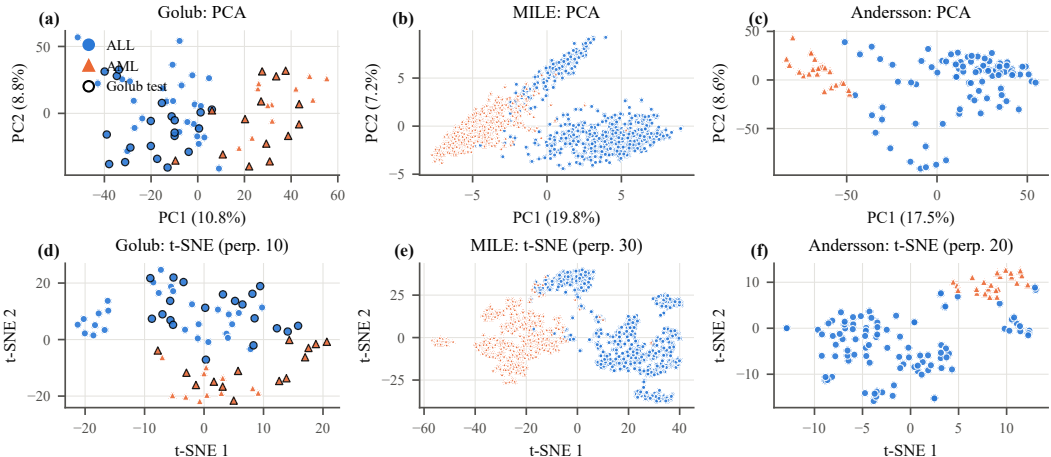
- NaN/INF yok; ama değerlerin **28.7%**'i negatif (PM − MM).
- Absent çağrıları (70.2%) negatif/düşük değerlerle örtüşüyor.
- Hasta sütunları sırasız ⇒ etiketler hasta numarasıyla eşlendi, `assert` ile doğrulandı.

Dönüşüm: clip [20, 16000] + $\log_2$



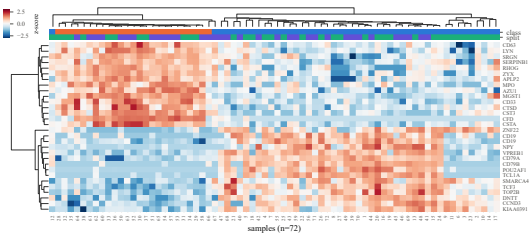
- Çarpıklık 7.08 $\rightarrow$ 0.55; ortalama–SD korelasyonu 0.95 $\rightarrow$ 0.18.
- Kat-değişim filtresi: 3,859 gen kalıyor.

Boyut indirgeme



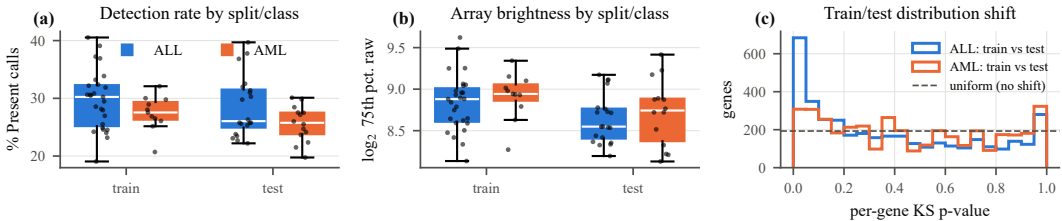
PC1 tek başına AUC 0.984 (Golub) $\Rightarrow$ güçlü sinyal, yöntem farkları küçük olacak.

Ayırt edici genler



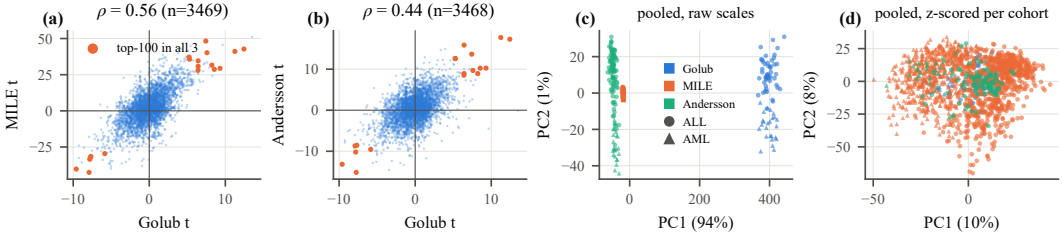
- Welch t, Mann–Whitney, BH-FDR, SNR
- $q < 0.05$: 945 gen
- AML: CST3, CD33, MPO, ZYX
- ALL: TCF3, CD79B, CD19, DNTT
- Kümeleme sınıfları buluyor (ARI 0.89)
- **Uyarı:** bu sıralama yalnızca betimsel; modelde kullanılırsa sızıntı!

Eğitim ve bağımsız test seti (batch etkisi)



- Test dizileri daha sönük (75. yüzdelik 421 vs. 482, $p = 0.016$).
- Sınıf içi KS: ALL'de genlerin 17.7%'i $p < 0.05$ (beklenen %5).
- $\Rightarrow$ tek 34 örneklik test skoru nested CV'den sapabilir (RQ2).

Kohortlar arası karşılaştırma



- *t* istatistikleri: $\rho = 0.56$ (Golub–MILE), $\rho = 0.44$ (Golub–Andersson); ortak üst genler şanstan fazla.
- Birleşik PCA'da PC1'i **kohort** belirliyor ($\eta^2 = 99.8\%$); kohort içi *z*-skor sonrası sınıf ekseni ortaya çıkıyor.

Bulgular $\Rightarrow$ modelleme kararları

1. Negatif/taban değerler $\Rightarrow$ clip + $\log_2$
2. $p \gg n \Rightarrow$ öznitelik seçimi **her eğitim katının içinde**, k iç CV'de ayarlanır
3. Güçlü sinyal $\Rightarrow$ güven aralığı + eşleştirilmiş testler şart
4. Dengesizlik (%65/35) $\Rightarrow$ stratified katlar, `class_weight`, balanced accuracy
5. Train/test kayması $\Rightarrow$ 38/34 ve nested CV ayrı raporlanır
6. Andersson'da eksik değer $\Rightarrow$ kat içi imputasyon (medyan vs. kNN)
7. Platform/ölçek farkı $\Rightarrow$ kohort içi standardizasyon, ortak 3,469 gen

Final planı

Yöntemler: elastic-net LR, SVM (lineer/RBF), random forest (+ karar ağacı tabanı)

Protokol: (a) 38/34, test *bir kez*; (b) 72 örnekte 5×5 nested CV, 5 seed

Metrikler: Acc, BAcc, Precision, Recall, Specificity, F1, ROC-AUC, karışıklık matrisi

İstatistik: Friedman/Nemenyi, düzeltilmiş t, McNemar

Bonuslar

- B1: MLP / autoencoder (+ MILE ön eğitim)
- B2: TabPFN v2, GenePT gömmeleri
- B3: IEEE konferansına gönderim
- B4: Andersson (3. veri seti)

Tekrarlanabilirlik: `python run_all.py`, seed 42, rapordaki her sayı betikten

Teşekkürler

Kod: `github.com/mrayenesay/leukemia-all-aml-ml`

GenAI beyanı: Claude (Opus 5.5) kullanıldı; ayrıntılar Ek A'da.